Aula 3 · Clusterização com k-Means

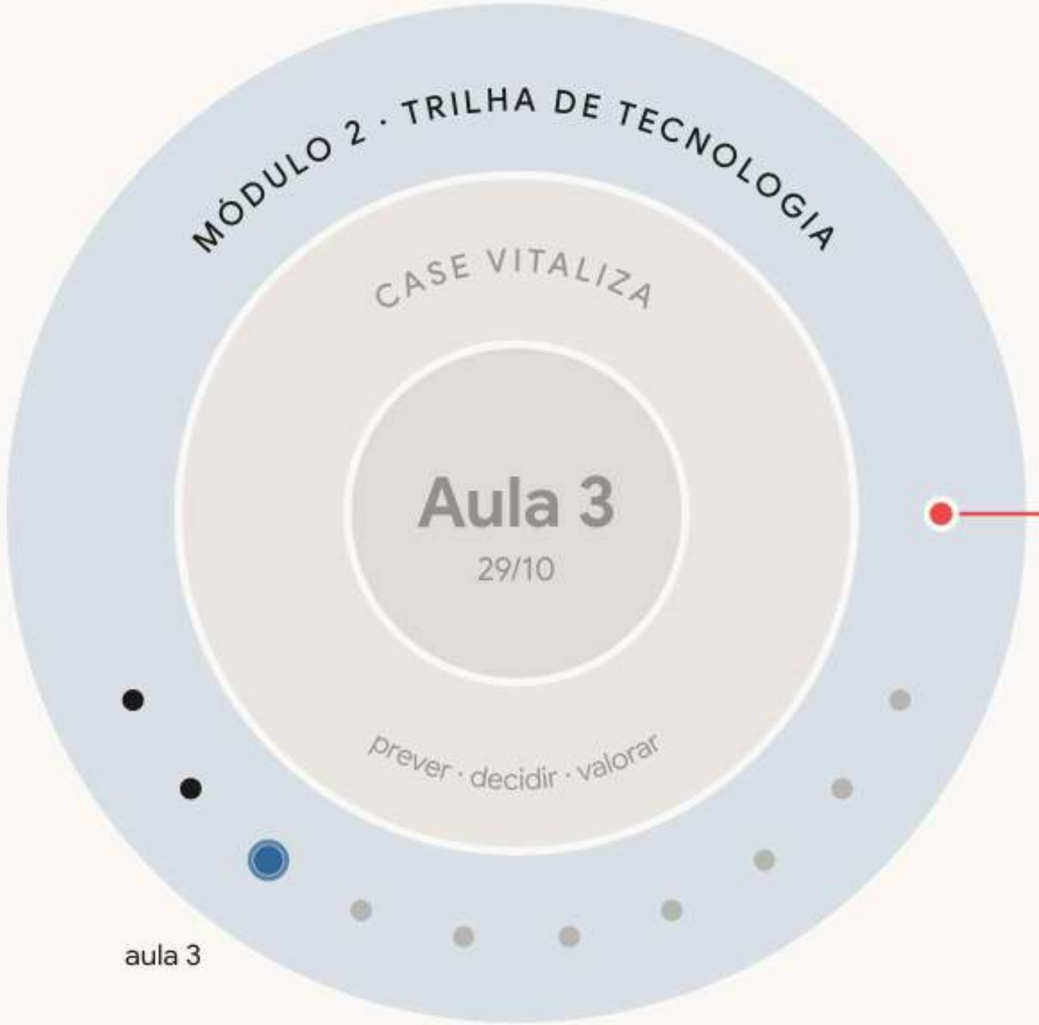
Trilha de Tecnologia

29 de outubro de 2026
MBA em IA e Dados para Negócios
Módulo 2

inteli

Do módulo à aula de hoje

Onde estamos



aula 3

Da etapa 1 à etapa 2

Fecha o entendimento dos dados e abre a segmentação

1 Entender

metodologia · ambiente · análise exploratória

2 Segmentar e comunicar

clusterização · visualização de dados

3 Preparar e prever

não estruturados · classificação · regressão · bagging e boosting

4 Implantar

deploy do modelo · fechamento

13/11 · a segmentação, a primeira entrega

inteli

Do módulo à aula de hoje

O que a turma sai sabendo fazer



aula 3

Clusterização com k-means

Ao sair daqui, vocês conseguem

1. **Descrever a base** pela qualidade, pela granularidade e pela estatística descritiva
2. **Explicar o k-means passo a passo** e preparar as variáveis que entram nele
3. **Avaliar um agrupamento** por quatro lentes: inércia, silhueta, estabilidade e negócio
4. **Transformar cluster em segmento**, com perfil, tamanho e consequência

Do módulo à aula de hoje

Como a aula anda



aula 3

Quatro capítulos

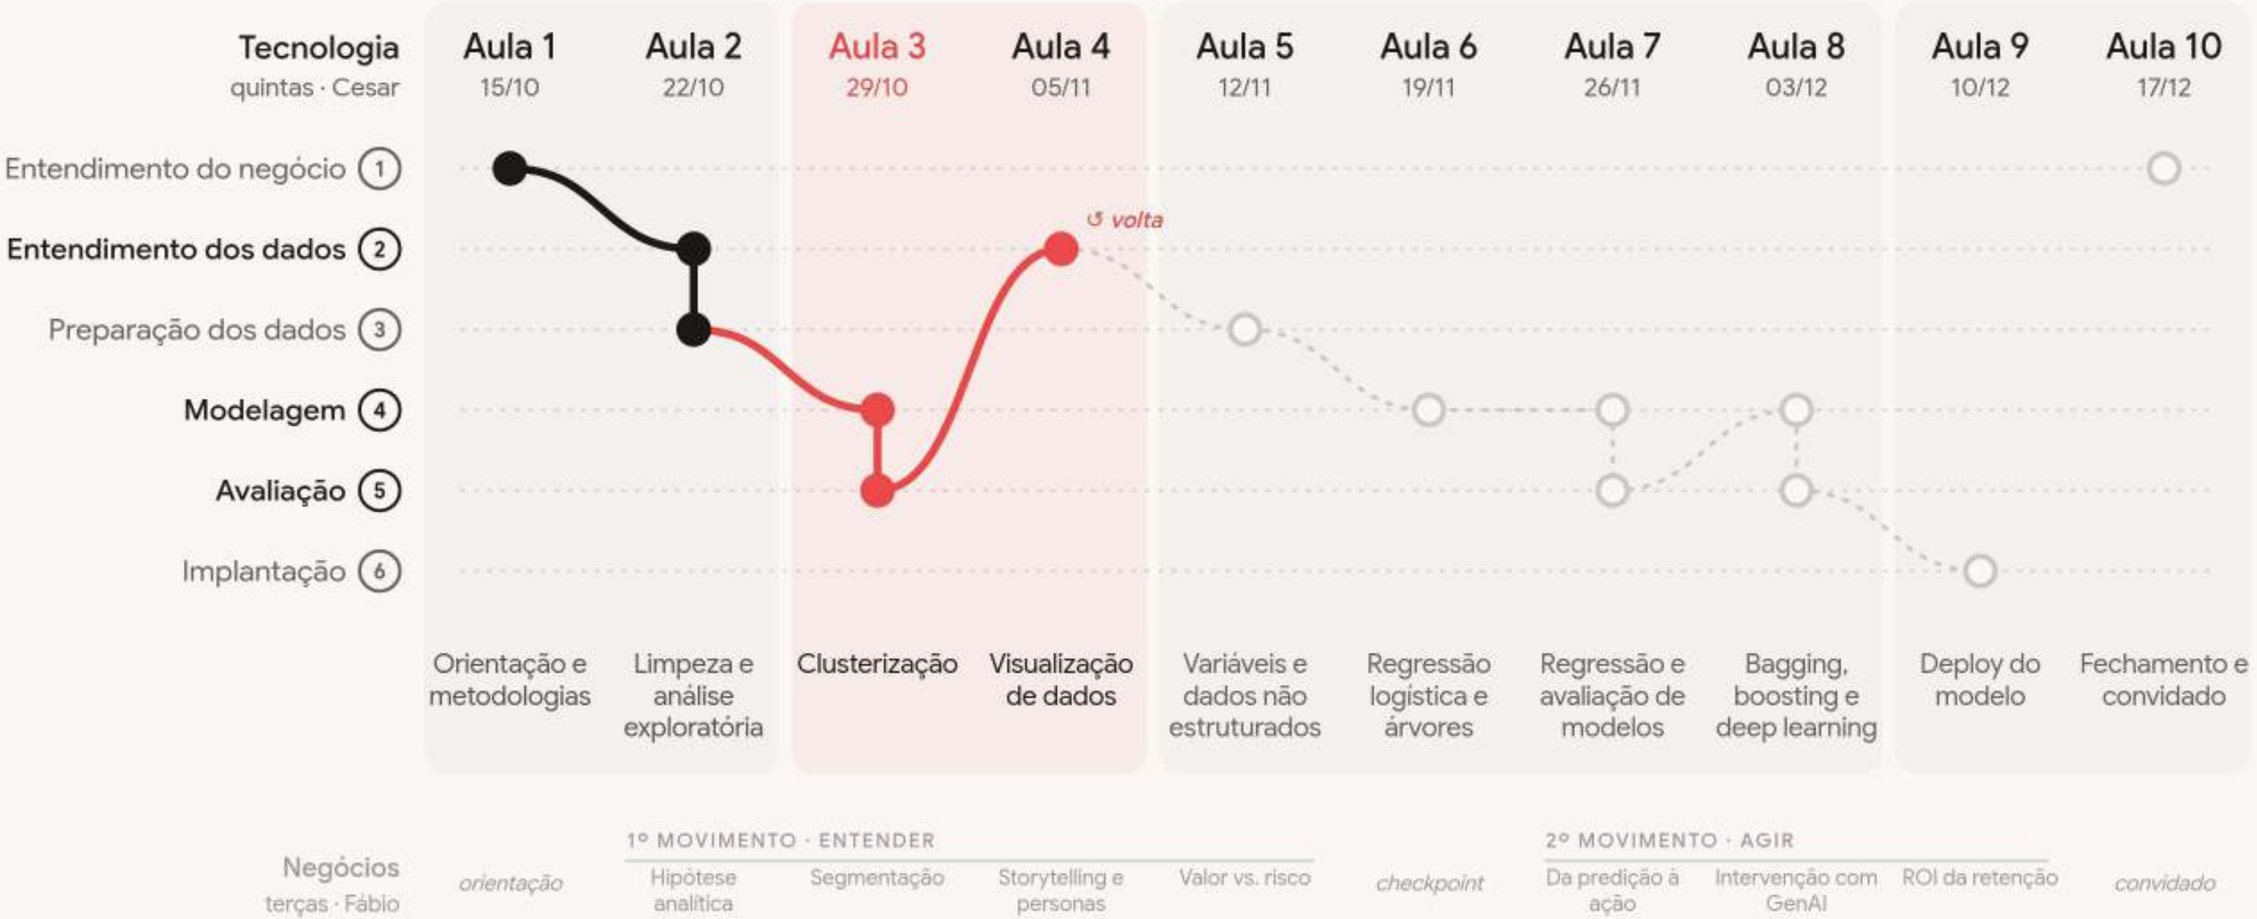
1. **Descrever a base**
   Qualidade, granularidade e estatística descritiva
2. **Segmentação**
   CRISP-DM, paradigmas de aprendizado e o k-means
3. **Avaliar o agrupamento**
   Inércia, silhueta, estabilidade e leitura de negócio
4. **Na prática**
   Sete passos em 30 minutos, num branch do grupo

No fim · os clusters do grupo, com perfil e registro, num branch do repositório

inteli

Na aula 3 começa a etapa 2 do módulo

Segmentar e comunicar, nas aulas 3 e 4

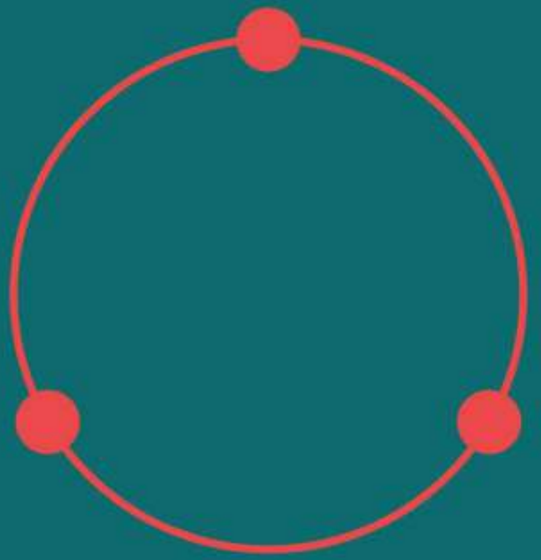


inteli

0

Recap

Onde nós paramos na última aula



inteli

O AMBIENTE

A pasta do projeto

O desenho da pasta já é uma regra: o bruto nunca é editado.

```
vitaliza-grupo-XX/
├── AGENTS.md                  (ou CLAUDE.md)
├── decisoes.md
├── docs/                      enunciado e dicionário de dados
├── dados/
│   ├── brutos/  só leitura    os 12 arquivos e heatmaps_90d/
│   └── processados/           tabelas intermediárias do grupo
├── notebooks/
├── src/
├── saidas/
└── .gitignore                 dados/ e .env fora do repositório
```

O AMBIENTE

Git como rede de segurança

Um commit antes de cada pedido grande deixa desfazer o que o agente fez.

- vitaliza-grupo-XX/
  - AGENTS.md
  - decisoes.md
  - docs/
  - dados/
    - brutos/ (só leitura)
    - processados/
  - notebooks/
  - src/
  - saidas/
  - .gitignore



O **.gitignore** tira os dados e qualquer arquivo de chave do repositório.

Um commit antes de cada pedido grande

Se o agente estragar algo, o grupo volta ao commit anterior



COMMIT

Uma foto do projeto inteiro

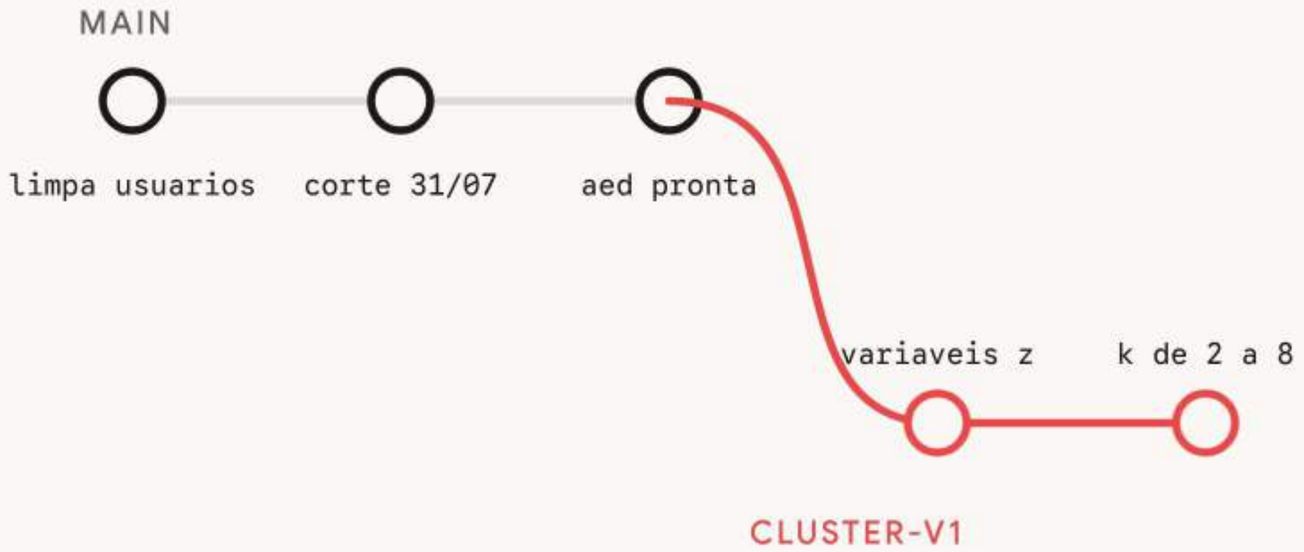
Antes de cada pedido grande ao agente, um commit. Se o agente estragar, desfazer é voltar à foto anterior.

REPLIT, JULHO DE 2025

O agente apagou o banco de produção. O que faltou: um ponto de volta e um lugar isolado para testar.

Um branch para o experimento do k-means

A main fica com a base limpa e a análise exploratória



BRANCH

Uma linha paralela

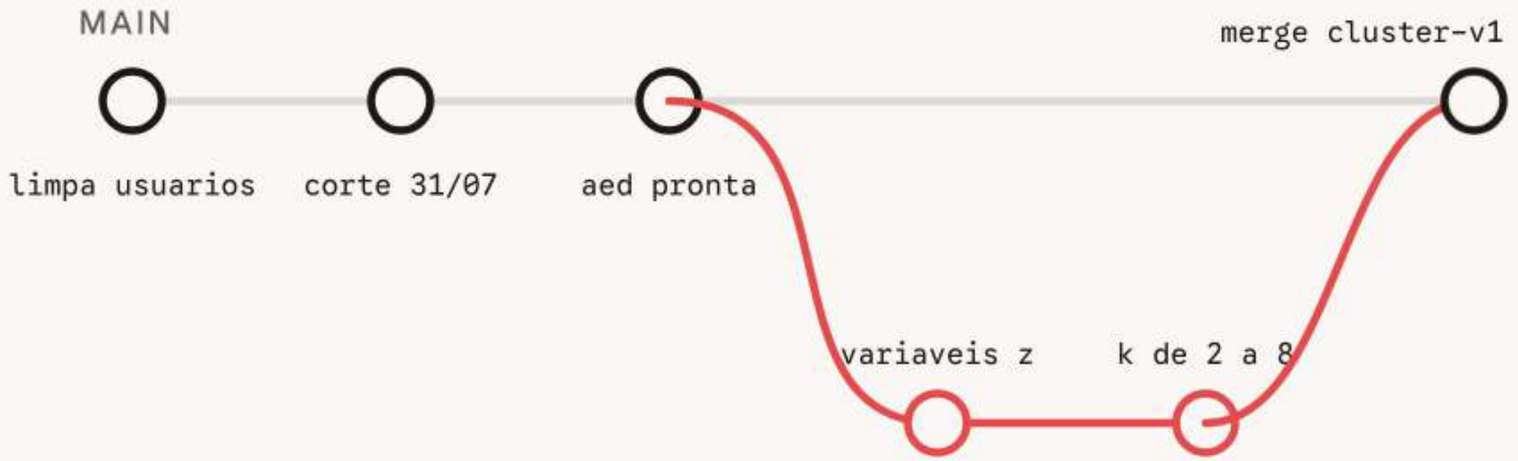
O experimento do k-means vive no cluster-v1. A main continua com a base limpa e a AED, intocada.

NA PRÁTICA

O primeiro comando do piloto é criar o branch. Um commit por passo.

Pull request antes de entrar na main

O auditor lê, pergunta e aprova o código do branch



CLUSTER-V1

PR #4: cluster-v1 → main
revisado pelo auditor
aprovado

PULL REQUEST

Pedir para entrar na main

O branch volta para a main por um pull request. Alguém que não escreveu o código lê, pergunta e aprova.

O AUDITOR

O auditor da aula 2 vira o revisor do PR. Só depois da aprovação o merge fecha o ramo.

Dois agentes em dois branches ao mesmo tempo

Com worktree, cada branch tem a própria pasta

`vitaliza/`

main

Agente 1

segue a análise exploratória

`claude`

`vitaliza-cluster/`

cluster-v1

Agente 2

roda o k-means de 2 a 8

`claude --worktree cluster-v1`

WORKTREE

Uma pasta para cada branch

Cada pasta é um branch; cada agente trabalha numa. Um não pisa no outro.

NO CLAUDE CODE E NO CODEX

claude --worktree cria a pasta e o branch; no app do Codex, cada tarefa já nasce na própria árvore.

1

Descrever a base

Qualidade, granularidade e estatística descritiva



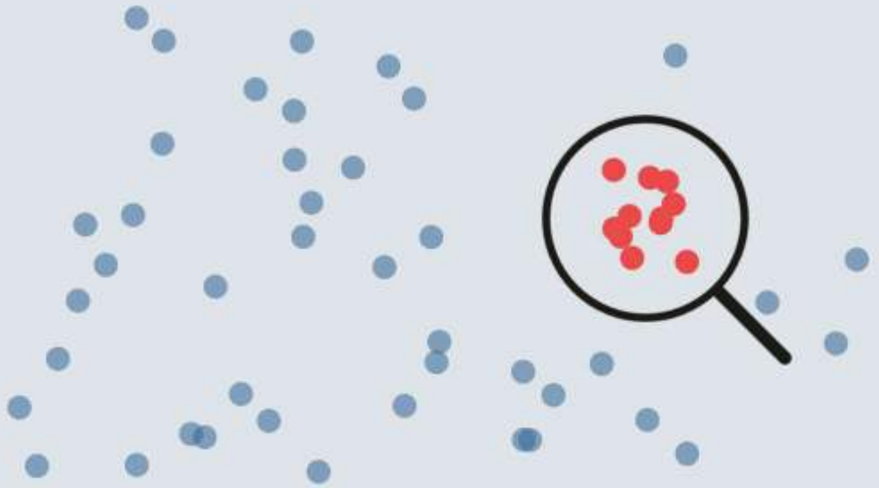
inteli

Detetive antes do juiz

Análise exploratória procura o que os dados mostram; análise confirmatória testa o que já se suspeita.

Exploratória

o detetive



Confirmatória

o juiz

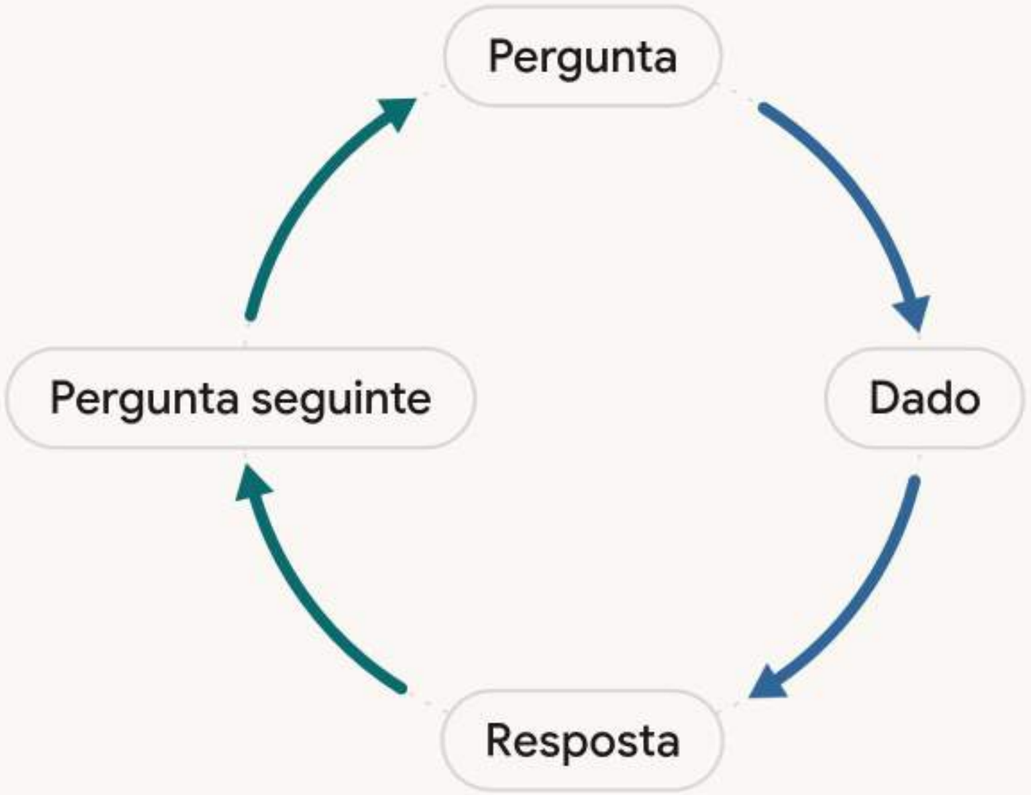


inteli

TUKEY (1977)

O ciclo da exploração

Em 2026, o agente acelera a parte mecânica; escolher a pergunta e julgar a resposta continua com o grupo.

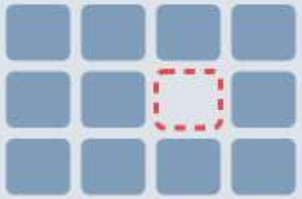


Agente
a parte mecânica

Grupo
a pergunta e o julgamento

Cinco dimensões da qualidade

A partir da pesquisa com usuários de dados de Wang e Strong (1996).



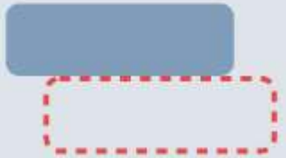
Completude



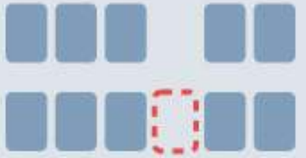
Validade



Consistência



Unicidade



Temporalidade

Um exemplo da base por dimensão

Os exemplos vêm de onboarding.csv, atividades.parquet e uso_mensal.csv.

Completude	8,6% `onboarding.csv`	das respostas do onboarding não têm o objetivo preenchido
Validade	951 treinos `atividades.parquet`	com mais de 200 km, e um de 10.013 km, para uma mediana de 6,5 km; 3.649 treinos têm duração zero
Consistência	corrida · run `atividades.parquet`	o mesmo tipo de treino aparece em português e em inglês, como caminhada e walk
Unicidade	9.383 treinos `atividades.parquet`	chegaram duas vezes, uma pelo app e outra pelo relógio (garmin ou apple_health)
Temporalidade	ausente · zero `uso_mensal.csv`	mês sem uso é linha ausente em 2025 e linha com zero em 2026

WANG; STRONG (1996)

Completude | Validade | Consistência | Unicidade | Temporalidade

Completude: 8,6% sem objetivo

onboarding.csv: 5.467 das 63.929 respostas não têm objetivo_texto.

OBJETIVO

Medir quanto falta em cada coluna e separar o vazio opcional do vazio que é problema.

PROMPT

```
Lê o docs/dicionario_dados.md e depois abre o
dados/brutos/onboarding.csv.
Quero saber quanto falta em cada coluna. Me mostra o plano
antes de rodar.
Conta as linhas e os user_id únicos. Depois, coluna por coluna,
quantos vazios tem, separando nulo de texto só com espaço, em
percentual, da mais vazia para a menos vazia.
No fim, me diz quais dessas colunas o dicionário marca como
opcionais.
Não mexe em nada de dados/brutos/.
```

CONFIRA

- 63.929 respostas, uma por conta.
- objetivo_texto: 5.467 vazias (8,6%), todas nulas; nenhuma só com espaços.
- Opcionais no dicionário: objetivo_texto e como_conheceu.
- Armadilha: nivel (7,1%) e dias_por_semana (10,0%) também têm vazios, e o dicionário não diz que são opcionais.

Validade: 951 treinos acima de 200 km

atividades.parquet: um treino de 10.013 km para uma mediana de 6,5 km, e 3.649 com duração zero.

OBJETIVO

Achar distâncias e durações de treino que não podem ser reais, sem confundir com o que só está vazio.

PROMPT

```
Agora o dados/brutos/atividades.parquet (lê com pandas e
pyarrow).
Quero achar distância e duração que não podem ser de verdade,
sem confundir com o que só está vazio. Plano antes de rodar.
Quantos treinos são e quantos têm distancia_km preenchida? Me
dá mínimo, mediana e máximo de distancia_km e de duracao_min,
quantos passam de 200 km e quantos têm duração zero ou
negativa.
E lista os cinco mais longos, com todas as colunas: quero olhar
um por um.
Não mexe em nada de dados/brutos/.
```

CONFIRA

- 1.254.475 treinos; 679.640 com distância.
- Mediana 6,47 km; 951 acima de 200 km. O maior, 10.012,75 km, é um pedal de 160 minutos do apple_health.
- 3.649 treinos com duração zero; nenhum negativo.
- Armadilha: os 574.835 sem distância não são erro; não tinham GPS.

Consistência: corrida e run

atividades.parquet: o mesmo tipo de treino aparece em português e em inglês.

OBJETIVO

Ver se a mesma categoria aparece escrita de mais de um jeito na coluna tipo.

PROMPT

```
Ainda no atividades.parquet: desconfio que a coluna tipo
escreve a mesma coisa de mais de um jeito.
Lista os valores de tipo com a contagem de cada um e cruza com
a origem.
Se tiver valor que parece a mesma categoria, me propõe um mapa
de padronização e diz quantas linhas cada troca mexeria. Só
propõe: não aplica nada ainda.
Plano antes de rodar, e dados/brutos/ intocado.
```

CONFIRA

- 11 valores para 7 tipos: corrida e run, caminhada e walk, forca e strength, pedal e ride.
- Os nomes em inglês (376.930 treinos, 30%) vêm todos da origem app.
- Armadilha: contar só corrida deixa de fora 162.108 corridas.

Unicidade: 9.383 treinos em dobro

atividades.parquet: o mesmo treino chega pelo app e pelo relógio.

OBJETIVO

Contar os treinos que chegaram duas vezes, uma pelo app e outra pelo relógio.

PROMPT

```
Acho que tem treino contado duas vezes, uma pelo app e outra
pelo relógio.
Procura pares da mesma conta, mesmo tipo e mesma duração, com
início a até 5 minutos um do outro: um do app e o outro do
garmin ou do apple_health.
Antes de rodar, me explica como vai tratar o horário de cada
origem.
Quero os pares contados por origem e cinco deles lado a lado.
Não remove nada e não mexe em dados/brutos/.
```

CONFIRA

- 9.383 pares: 4.184 com o apple_health e 5.199 com o garmin.
- Nos pares, a distância também é igual.
- Armadilha: o garmin grava o início 3 horas à frente (UTC). Sem corrigir o fuso, só aparecem os 4.184 do apple_health.

Temporalidade: ausente em 2025, zero em 2026

uso_mensal.csv: o mês sem treino muda de forma na virada do ano.

OBJETIVO

Ver se o mês sem treino é registrado do mesmo jeito em 2025 e em 2026, antes de comparar médias.

PROMPT

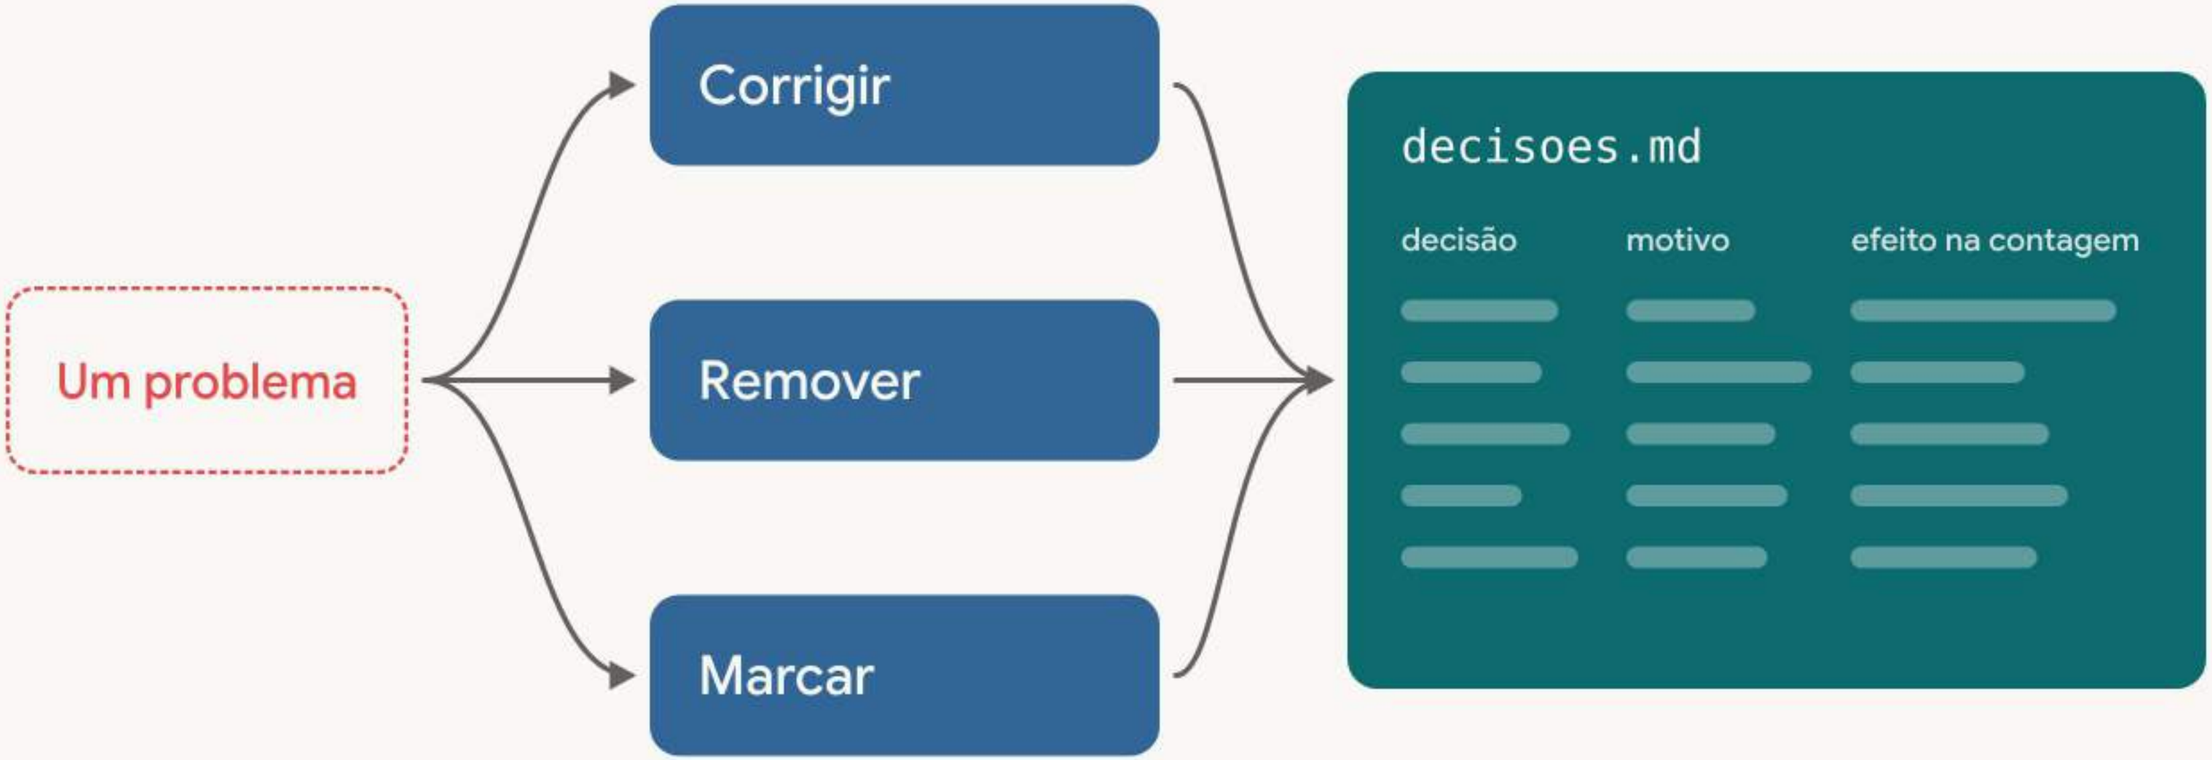
```
Antes de comparar a média de um ano com a do outro, quero ver
se o mês sem treino é registrado igual em 2025 e em 2026.
No dados/brutos/uso_mensal.csv, mês a mês de jan/2025 a
set/2026: quantas linhas, quantas com minutos = 0, a média e a
mediana de minutos.
Depois me explica o que muda na virada de 2025 para 2026 e o
que isso faz com uma média calculada no arquivo do jeito que
está.
Plano antes de rodar, e nada alterado em dados/brutos/.
```

CONFIRA

- 2025: nenhum mês com linha zerada; dez/2025 tem 13.624 linhas.
- jan/2026: 41.130 linhas, 25.697 com zero.
- A média cai de 265 para 118 minutos na virada só por isso; contando só quem treinou, jan/2026 dá 314.

Limpar é decidir

Cada problema tem três saídas, e cada escolha entra em decisoes.md com o motivo e o efeito na contagem.

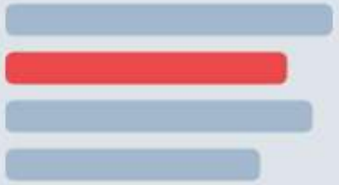


REDMAN (2016)

Uma linha por quê?

Cada arquivo tem sua granularidade, e uma tabela arrumada tem uma observação por linha.

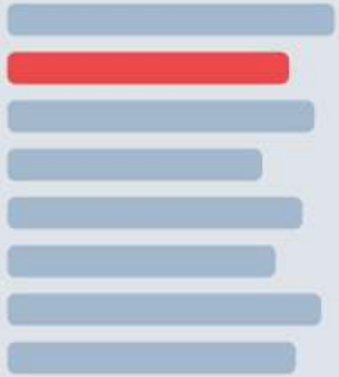
uma linha por
conta
usuarios.csv



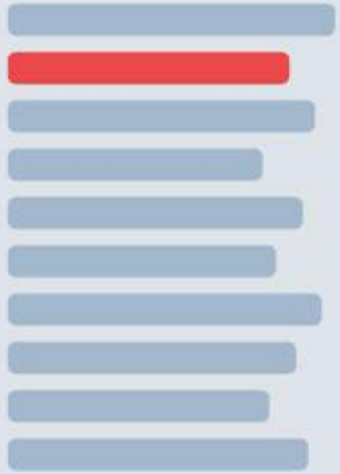
uma linha por
assinatura
assinaturas.csv



uma linha por
evento
eventos_assinatura.csv



uma linha por
treino
atividades.parquet



uma linha por
mês
uso_mensal.csv

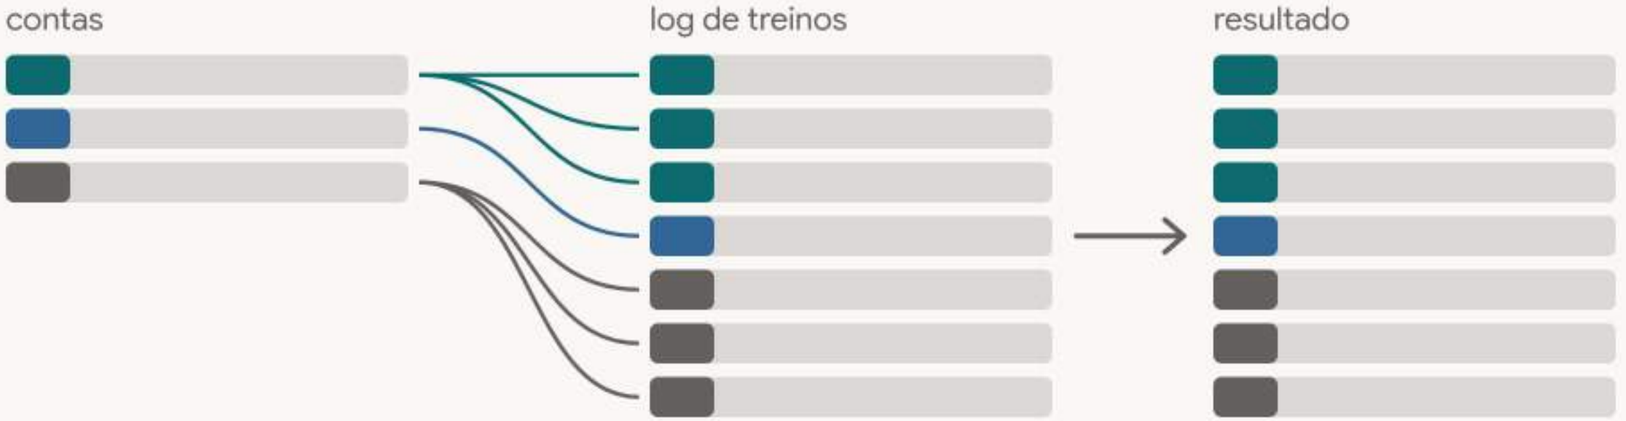


WICKHAM (2014)

Juntar sem multiplicar

Resumir o log por assinante antes de juntar; contar as linhas antes e depois de cada junção.

Juntar o log direto um para muitos pelo user_id



3 → 7 linhas

as contas se repetem

Resumir antes de juntar um para um pelo user_id



3 → 3 linhas

uma linha por conta

Na base: contar antes e depois

usuarios.csv e atividades.parquet, ligados pelo user_id.

OBJETIVO

Juntar os treinos às contas sem multiplicar linhas, contando antes e depois da junção.

PROMPT

```
Lê o docs/dicionario_dados.md antes de começar.
Quero uma base com uma linha por conta: cada conta de
dados/brutos/usuarios.csv com quantos treinos fez e quantos
minutos somou no dados/brutos/atividades.parquet.
Me mostra o plano antes, dizendo qual é o grão de cada arquivo.
Conta as linhas dos dois, resume os treinos por user_id e só
depois junta, pela esquerda. Conta as linhas de novo e confere
se ficou um user_id por linha. Conta sem treino fica com zero.
Salva em dados/processados/contas.csv e não mexe em nada de
dados/brutos/.
```

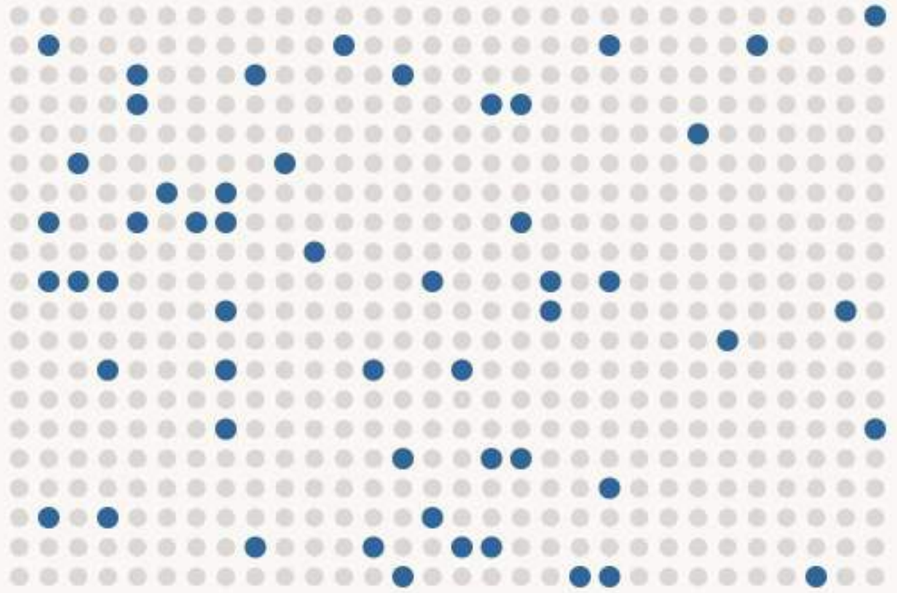
CONFIRA

- 64.948 contas e 1.254.475 treinos.
- Juntar o log direto daria 1.282.872 linhas: as contas se repetem.
- Resumindo antes: 36.551 contas com treino; depois da junção, 64.948 linhas, 28.397 com zero.
- Armadilha: mais linhas que contas no resultado é sinal de que a junção multiplicou.

Cada amostra dá uma média diferente

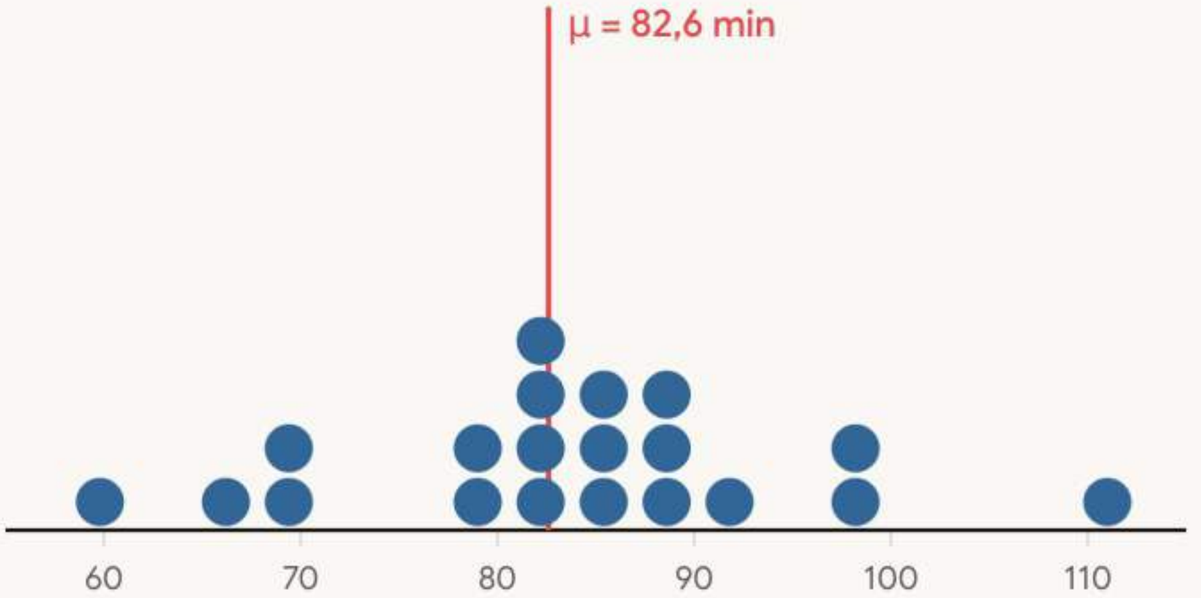
Minutos de treino por conta em setembro de 2026: a base inteira e 20 sorteios de 500 contas.

População: 56.565 contas



● sorteio de 500 contas

Média de cada sorteio



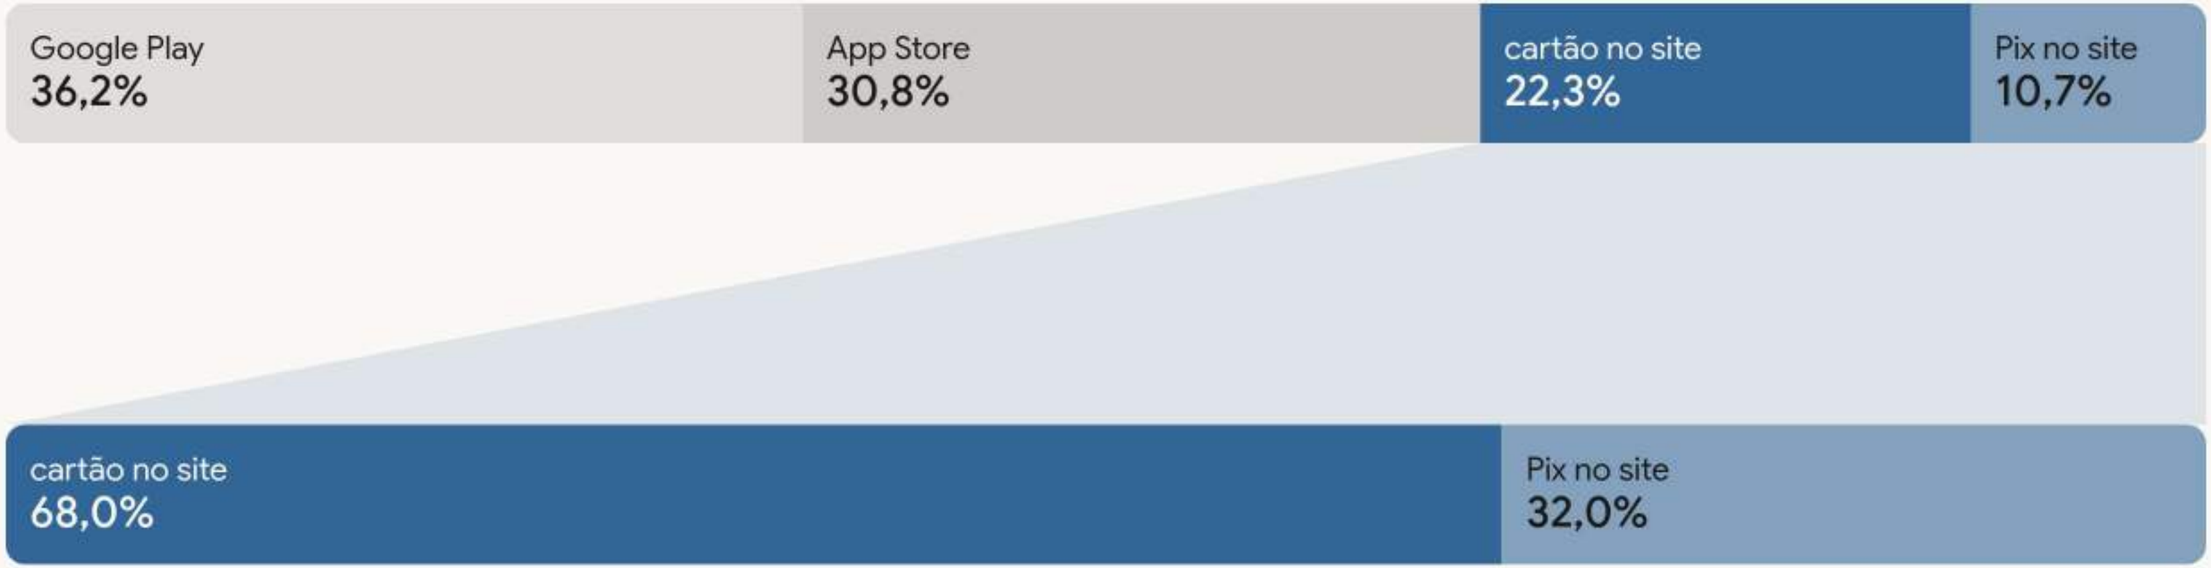
média de minutos por conta

de 60,2 a 109,5 min em 20 sorteios

Amostra que não foi sorteada engana

Quem cancelou de junho a setembro de 2026 e quem respondeu à pesquisa de saída, por canal de cobrança.

Fins de assinatura de junho a setembro de 2026: 3.389



Respostas da pesquisa de saída: 641 contas

As lojas são 67% dos fins e nenhuma resposta veio delas.

Sortear amostras com o agente

20 sorteios de 500 contas contra a média da base inteira.

OBJETIVO

Ver quanto a média muda de uma amostra para outra, contra a média da base inteira.

PROMPT

```
No dados/brutos/uso_mensal.csv, fica só com mes = 2026-09.
Primeiro me dá a média de minutos da base inteira.
Depois sorteia 20 amostras de 500 contas, com semente fixa para
eu conseguir repetir, e me mostra a média de cada uma.
Quero ver a menor, a maior e o quanto elas se afastam da média
da base.
Me mostra o plano antes de rodar e não mexe em nada de
dados/brutos/.
```

CONFIRA

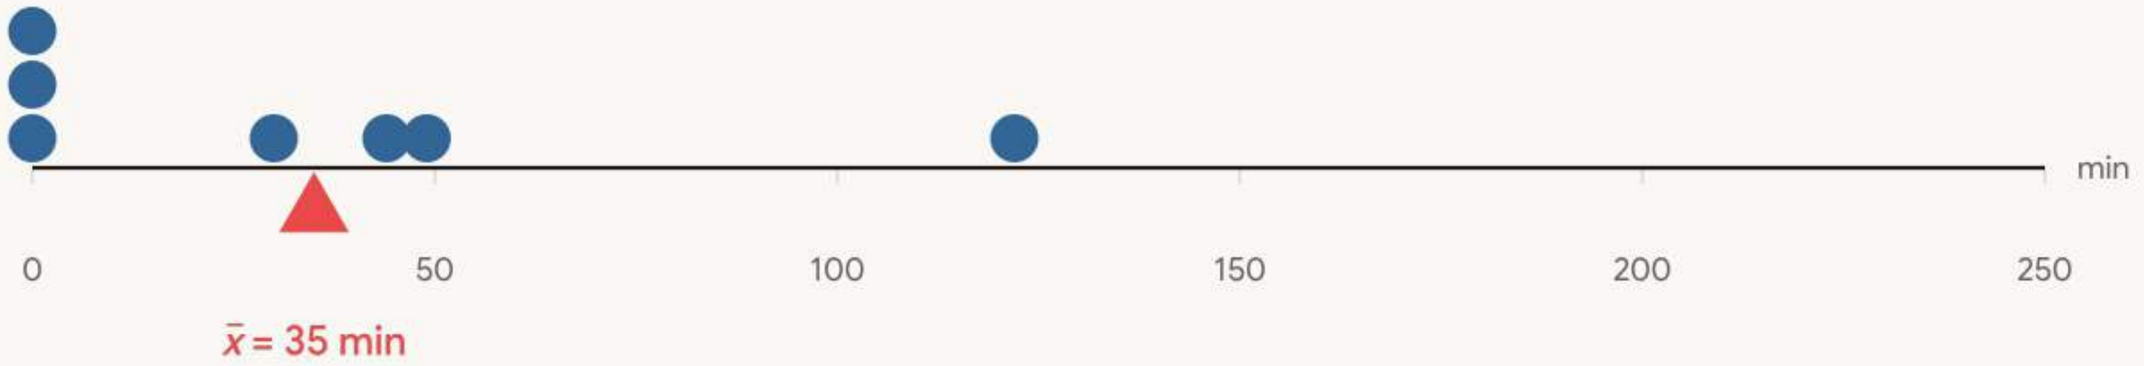
- 56.565 contas; média da base de 82,6 minutos.
- Cada sorteio dá uma média; com 500 contas, quase todas ficam entre 64 e 103 minutos.
- Armadilha: se as 20 médias saírem iguais, o agente fixou a semente dentro do laço e sorteou 20 vezes a mesma amostra.

A média é o ponto de equilíbrio

Minutos de treino de uma conta em sete dias de setembro de 2026.

seg 7	ter 8	qua 9	qui 10	sex 11	sáb 12	dom 13
122	30	44	49	0	0	0

$$\bar{x} = \frac{\Sigma x_i}{n} = \frac{245}{7} = 35$$



O extremo puxa a média; a mediana fica

A mesma semana, em ordem; o dia mais longo esticado para 240 minutos.

sex 11	sáb 12	dom 13	ter 8	qua 9	qui 10	seg 7
0	0	0	30	44	49	240
	moda		mediana			

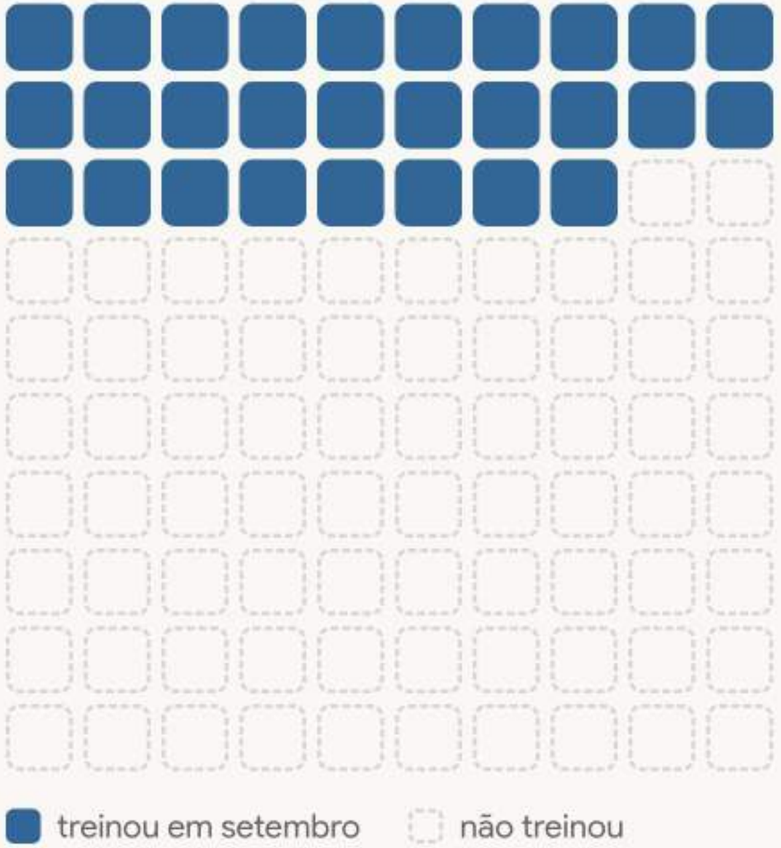
$$\bar{x} = \frac{\Sigma x_i}{n} = \frac{245}{7} = 35$$

média	35 → 51,9
mediana	30 → 30
moda	0 → 0



Média de 83 minutos, mediana zero

Minutos de treino por conta em setembro de 2026, em uso_mensal.csv.



treinou em setembro não treinou

72%

das contas não treinaram

mediana	moda	média
0 min	0 min	83 min

A média sozinha descreve uma conta que quase não existe.

Centro e posição com o agente

Minutos de treino por conta em setembro de 2026, em uso_mensal.csv.

OBJETIVO

Achar a medida que descreve a conta típica em setembro.

PROMPT

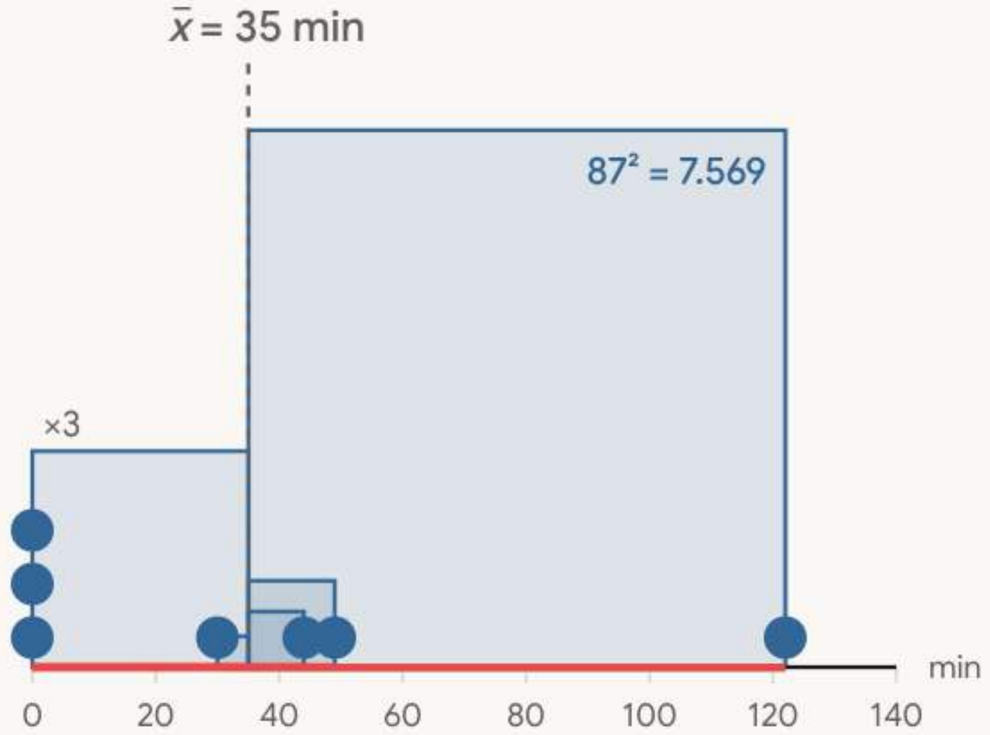
```
Ainda no uso_mensal.csv, só mes = 2026-09.
Conta as linhas e os user_id únicos, para eu ter certeza de que
é uma linha por conta.
Para minutos, me dá a média, a mediana, a moda e a proporção de
contas com zero. Depois os quartis, o p90, o p99 e o máximo.
Fecha com duas frases: qual dessas medidas descreve a conta
típica, e por quê.
Não mexe em nada de dados/brutos/.
```

CONFIRA

- 56.565 linhas, uma por conta.
- Média 82,6 min; mediana 0; moda 0; 72,3% das contas com zero.
- p75 = 40, p90 = 284, p99 = 1.074; máximo 4.294 minutos.
- Armadilha: se a conta típica treina 83 minutos, a resposta leu só a média.

O desvio padrão é a distância típica até a média

Cada desvio em relação à média vira um quadrado.



122	− 35 =	87 →	7.569
30	− 35 =	−5 →	25
44	− 35 =	9 →	81
49	− 35 =	14 →	196
0	− 35 =	−35 →	1.225
0	− 35 =	−35 →	1.225
0	− 35 =	−35 →	1.225
			Σ = 11.546

$$s = \sqrt{\frac{\Sigma(x_i - \bar{x})^2}{n - 1}}$$

$$= \sqrt{\frac{11.546}{6}} = 43{,}9 \text{ min}$$

Mesmo desvio padrão, variação relativa diferente

Treinos de janeiro a setembro de 2026, em atividades.parquet.

Duração do treino

média 46,4 min · desvio padrão 23,8 min



$CV = 51\%$

Frequência cardíaca média

média 130,3 bpm · desvio padrão 22,3 bpm



$CV = 17\%$

O CV divide o desvio pela média: compara variáveis em escalas diferentes.

$$CV = \frac{s}{\bar{x}}$$

Desvio padrão e CV com o agente

A base inteira e só as contas que treinaram, lado a lado.

OBJETIVO

Medir a dispersão dos minutos e ver quanto dela vem das contas sem treino.

PROMPT

```
Mesmo recorte, setembro de 2026.
Calcula o desvio padrão e o coeficiente de variação dos minutos
e me diz se dividiu por n ou por n - 1.
Depois refaz as mesmas contas só com quem treinou pelo menos um
minuto e põe as duas lado a lado, com a média e a mediana.
Quero entender o quanto os zeros puxam esses números.
Não mexe em nada de dados/brutos/.
```

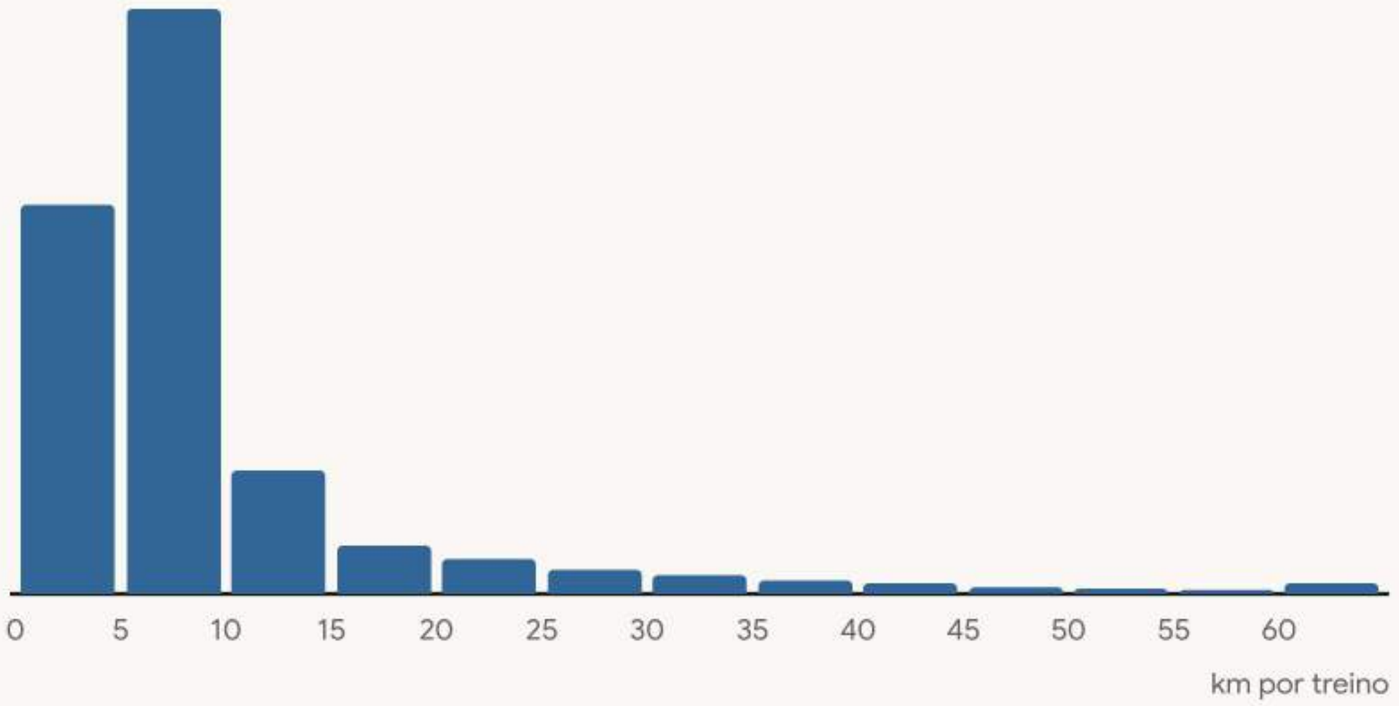
CONFIRA

- Base inteira: desvio padrão 221,3 min e CV de 268%; com n ou n − 1, a diferença some.
- Só quem treinou: 15.685 contas, média 298, mediana 173, desvio 335,2 e CV de 112%.
- Armadilha: CV acima de 100% aqui não é erro de conta; são os zeros e a cauda longa.

A tabela de frequências vira histograma

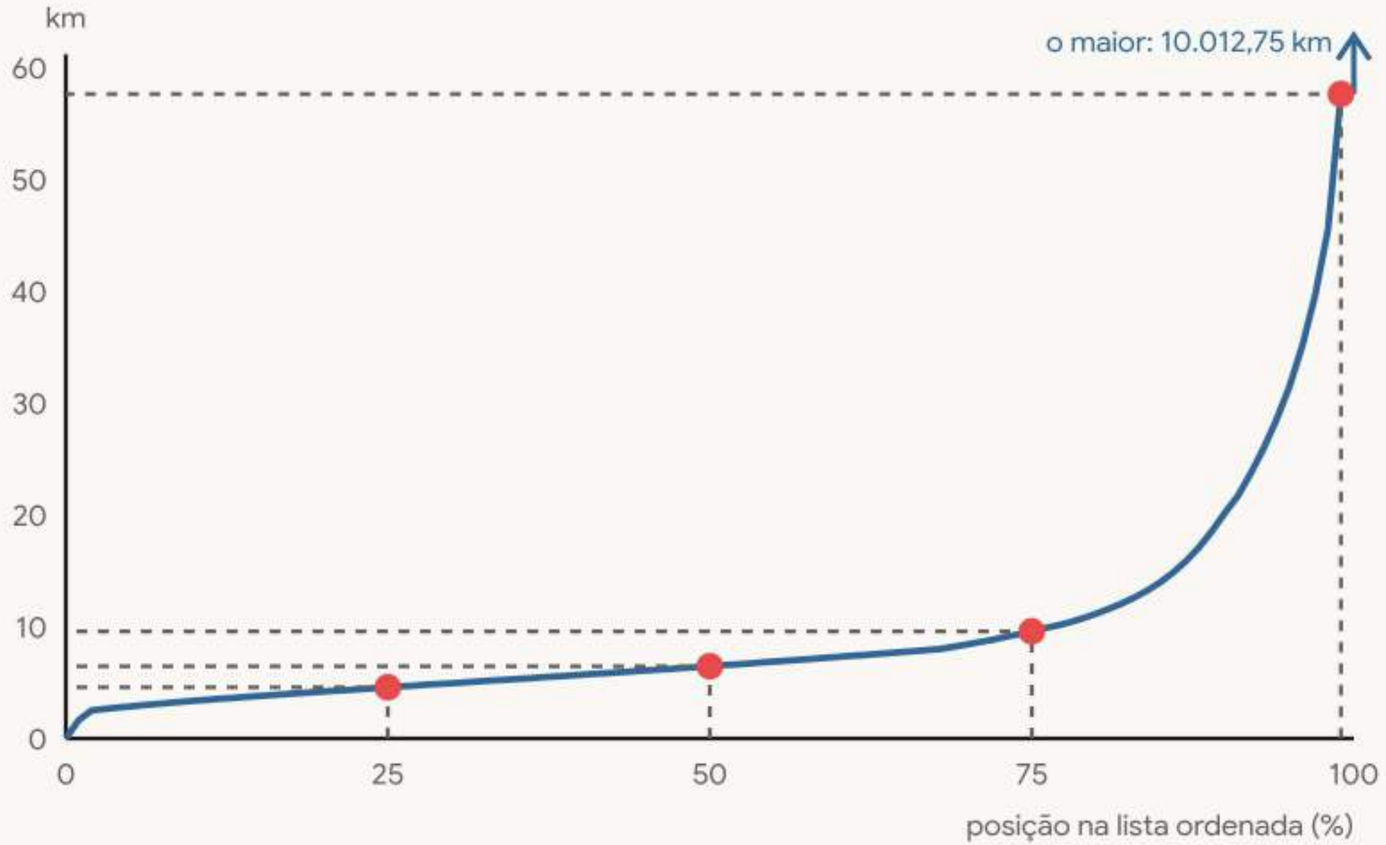
Distância dos 679.640 treinos com GPS, de janeiro a setembro de 2026.

km	treinos	%
0 a 5	207.759	30,6
5 a 10	311.836	45,9
10 a 15	65.775	9,7
15 a 20	25.485	3,7
20 a 25	18.334	2,7
25 a 30	13.214	1,9
30 a 35	9.853	1,4
35 a 40	7.413	1,1
40 a 45	5.861	0,9
45 a 50	3.695	0,5
50 a 55	2.609	0,4
55 a 60	1.838	0,3
60 ou mais	5.968	0,9



Percentil é posição na lista ordenada

Os 679.640 treinos em ordem crescente de distância.



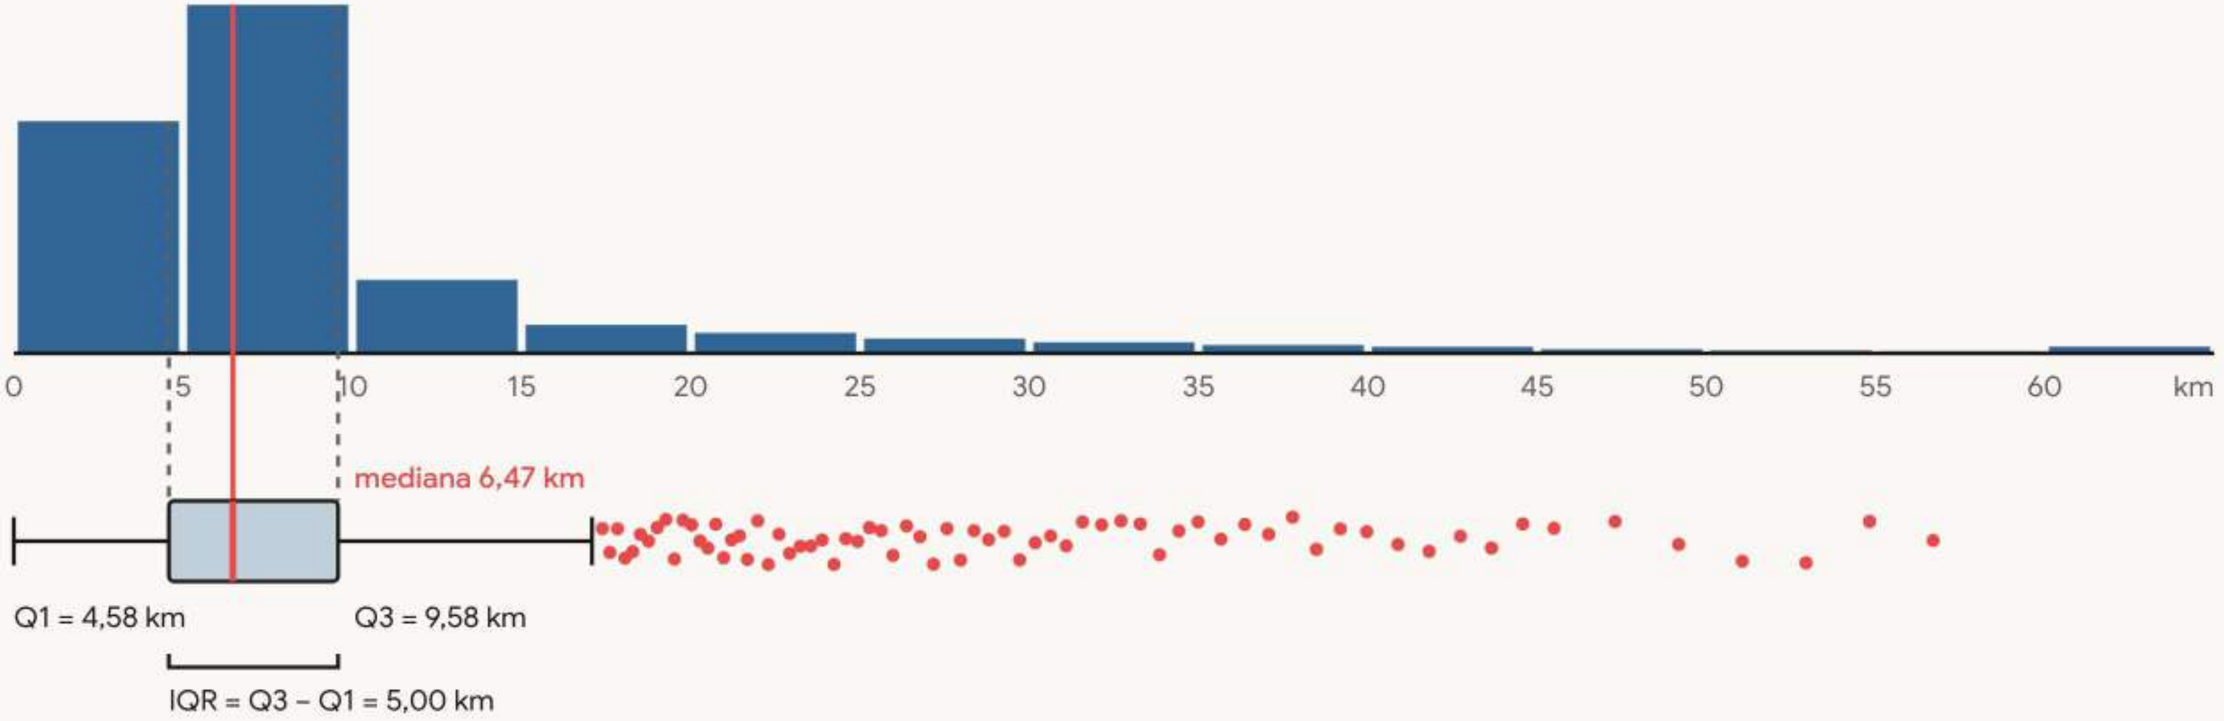
$$\text{posição} = p \times (n - 1) + 1$$

n = 679.640 treinos

	posição	km
p25 · Q1	169.910,75	4,58
p50 · mediana	339.820,50	6,47
p75 · Q3	509.730,25	9,58
p99	672.843,61	57,64

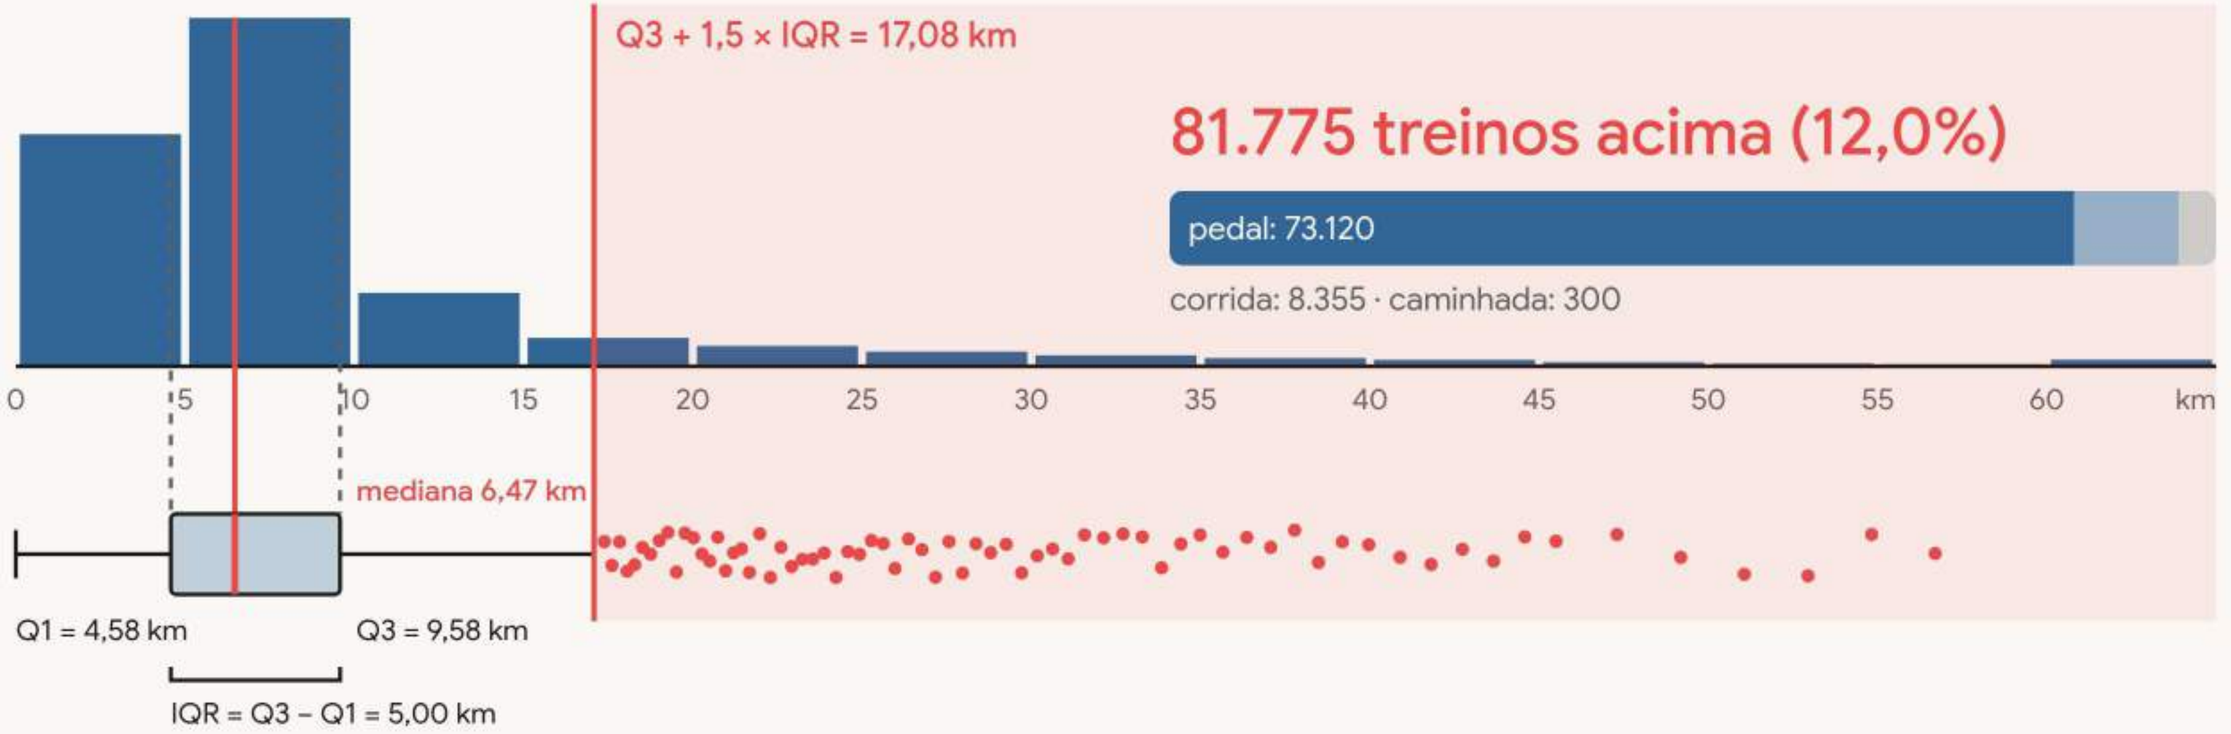
O boxplot nasce do histograma

Quartis, intervalo interquartil e os treinos além do limite.



A regra marca; o grupo decide

Quase todos os treinos acima do limite são de pedal.



$$z = \frac{x - \bar{x}}{s}$$

|z| > 3: 956 treinos

acima de 191,6 km

Histograma, quartis e extremos, pedidos ao agente

Distância dos 679.640 treinos com GPS, em atividades.parquet.

OBJETIVO

Ver a forma da distância dos treinos e marcar os extremos por duas regras, sem apagar nada.

PROMPT

```
Leia docs/dicionario_dados.md.
Mostre o plano antes de rodar.
Em dados/brutos/atividades.parquet, só treinos com distancia_km
preenchida:
1. conte os treinos;
2. faça a tabela de frequências e o histograma em classes de
5 km, a última com 60 km ou mais;
3. calcule Q1, mediana, Q3 e IQR;
4. marque os extremos pela regra Q3 + 1,5 × IQR e por |z| > 3,
com a contagem por tipo em cada regra.
Não remova nada nem altere dados/brutos/.
```

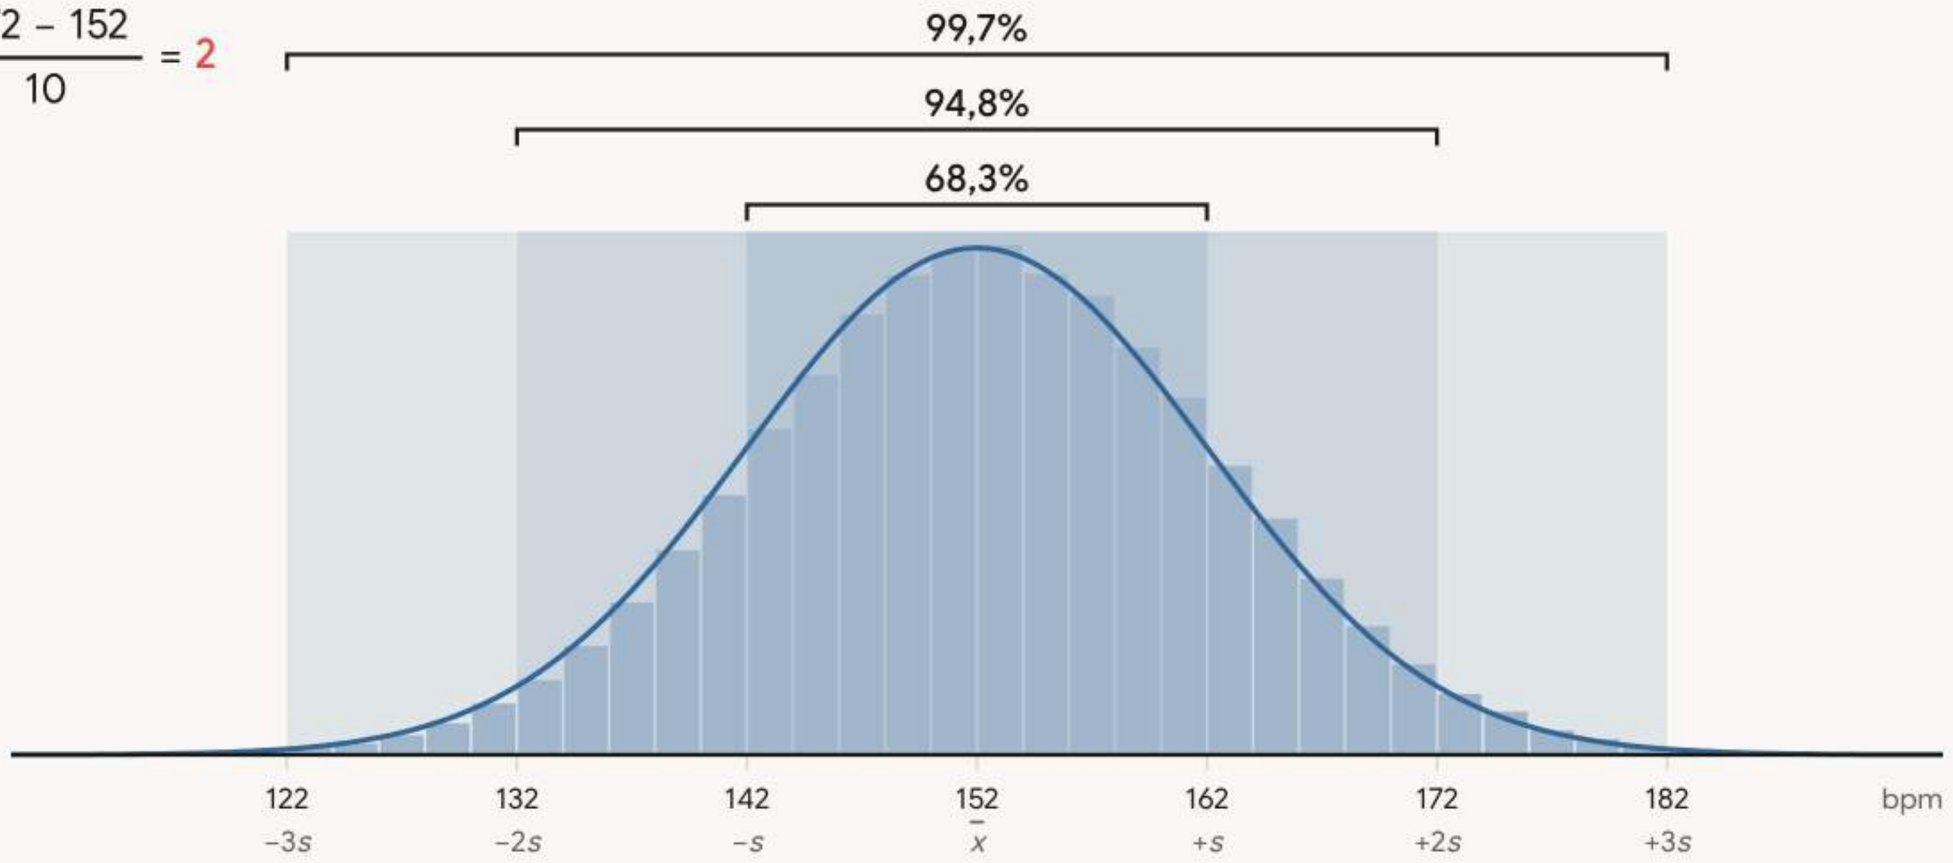
CONFIRA

- 679.640 treinos; 45,9% entre 5 e 10 km.
- Q1 4,58 km; mediana 6,47; Q3 9,58; IQR 5,00.
- 1,5 × IQR: 81.775 treinos acima de 17,08 km, 73.120 de pedal (com ride).
- |z| > 3: 956 acima de 191,6 km. A regra marca; o grupo decide.

Na curva normal, 68, 95 e 99,7

Frequência cardíaca média de 149.377 corridas: média 152 bpm, desvio padrão 10 bpm.

$$z = \frac{172 - 152}{10} = 2$$

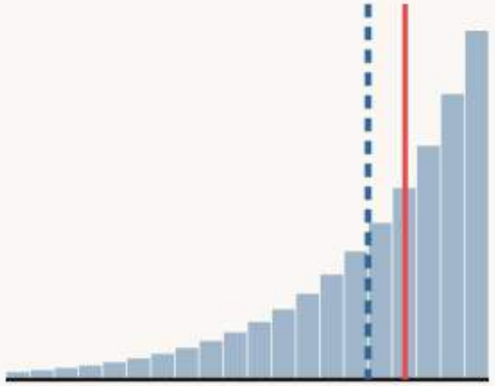


A média vai para o lado da cauda

Média e mediana em quatro distribuições; três são da base de setembro de 2026.

À esquerda

ilustração

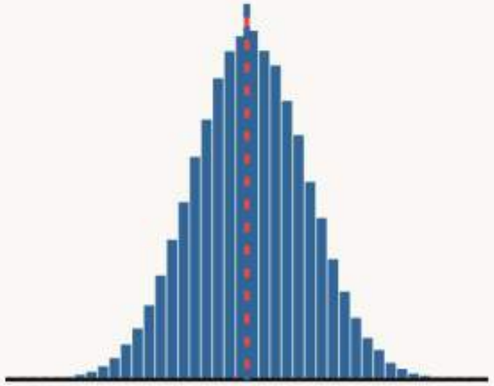


média < mediana

cauda para os valores baixos

Simétrica

frequência cardíaca, corridas



média = mediana

média 152, mediana 152 bpm

À direita

minutos por conta

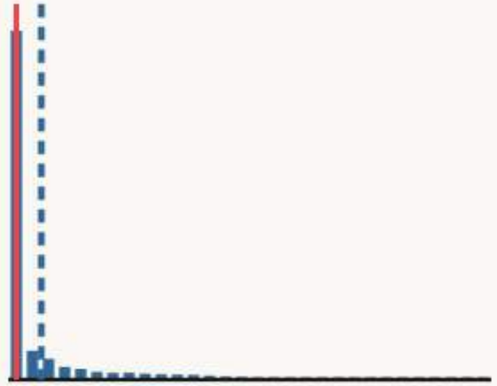


média > mediana

média 83, mediana 0 min

Contagem

dias ativos no mês



só valores inteiros

média 1,5, mediana 0 dia

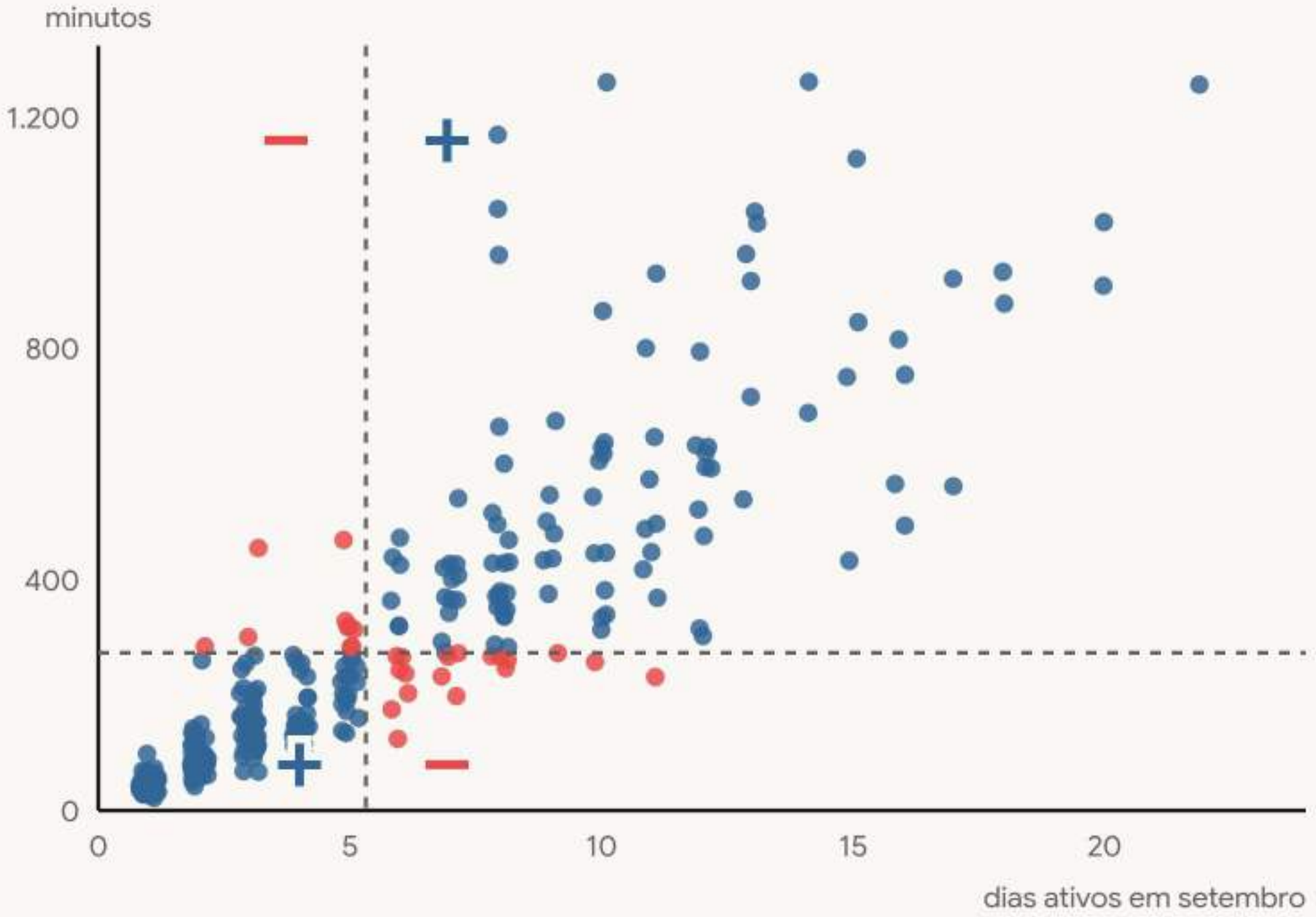
média — mediana

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

Mais dias ativos, mais minutos

Dias ativos e minutos de treino por conta em setembro de 2026; 320 contas sorteadas no gráfico.



$r = 0{,}86$

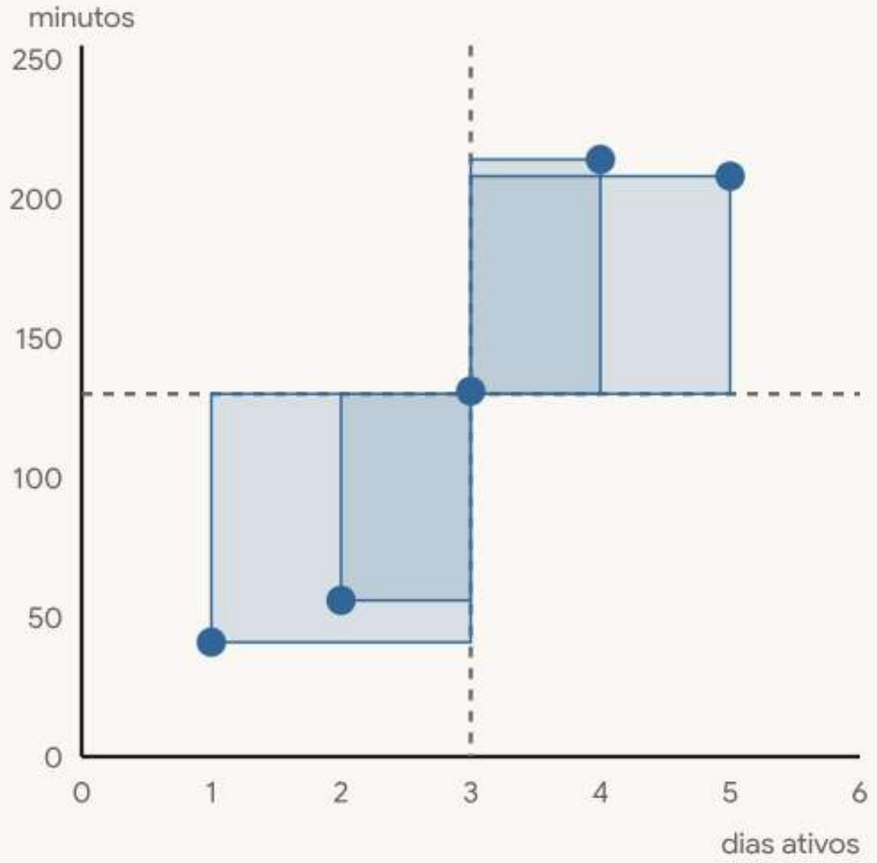
15.685 contas que treinaram em setembro de 2026

No gráfico, 292 de 320 contas estão nos quadrantes +: acima das duas médias ou abaixo das duas.

inteli

O r soma os produtos dos desvios

Cinco contas reais de setembro de 2026.



x	y	$x-\bar{x}$	$y-\bar{y}$	$(x-\bar{x})(y-\bar{y})$	$(x-\bar{x})^2$	$(y-\bar{y})^2$
1	41	−2	−89	178	4	7.921
2	56	−1	−74	74	1	5.476
3	131	0	1	0	0	1
4	214	1	84	84	1	7.056
5	208	2	78	156	4	6.084
Σ				492	10	26.538

$$r = \frac{\Sigma(x-\bar{x})(y-\bar{y})}{\sqrt{\Sigma(x-\bar{x})^2 \cdot \Sigma(y-\bar{y})^2}}$$

$$= \frac{492}{\sqrt{10 \times 26.538}} = 0{,}955$$

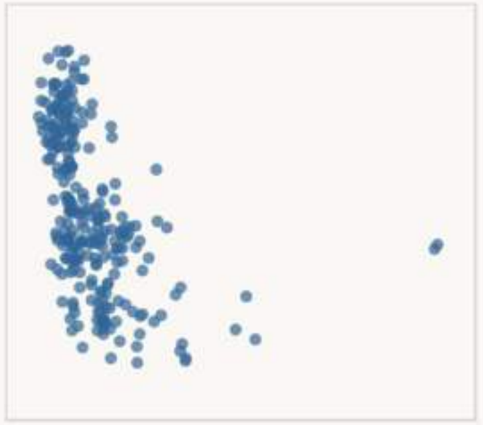
ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

O r vai de –1 a 1 e só vê reta

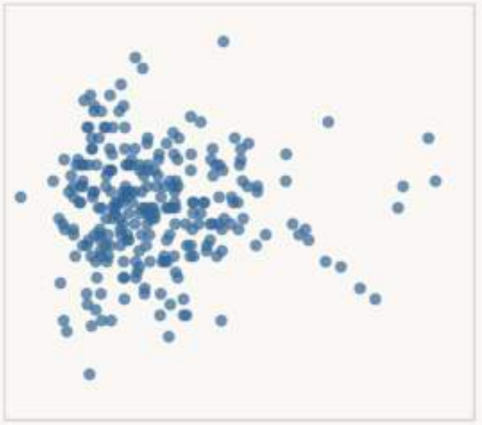
Quatro pares de variáveis dos treinos de 2026; 260 treinos sorteados em cada gráfico.





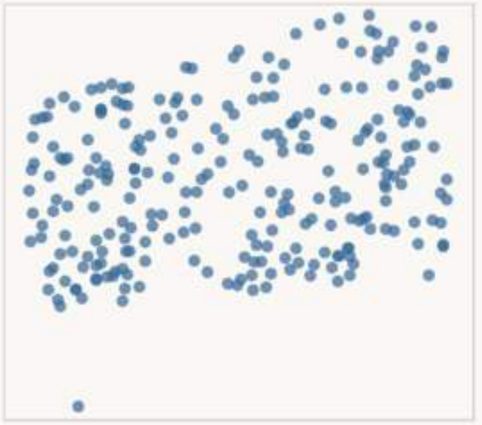
corrida: km × ritmo

r = –0,48



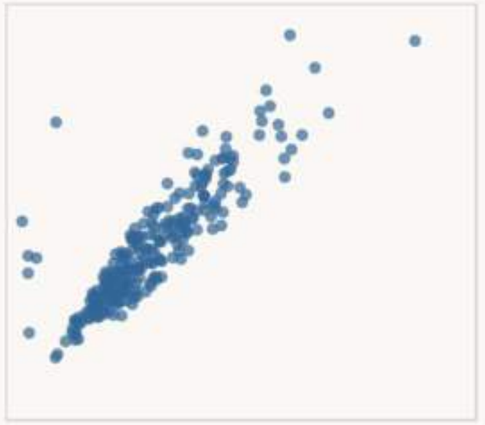
corrida: km × batimentos

r = 0,00



caminhada: ritmo × minutos

r = 0,28



corrida: km × minutos

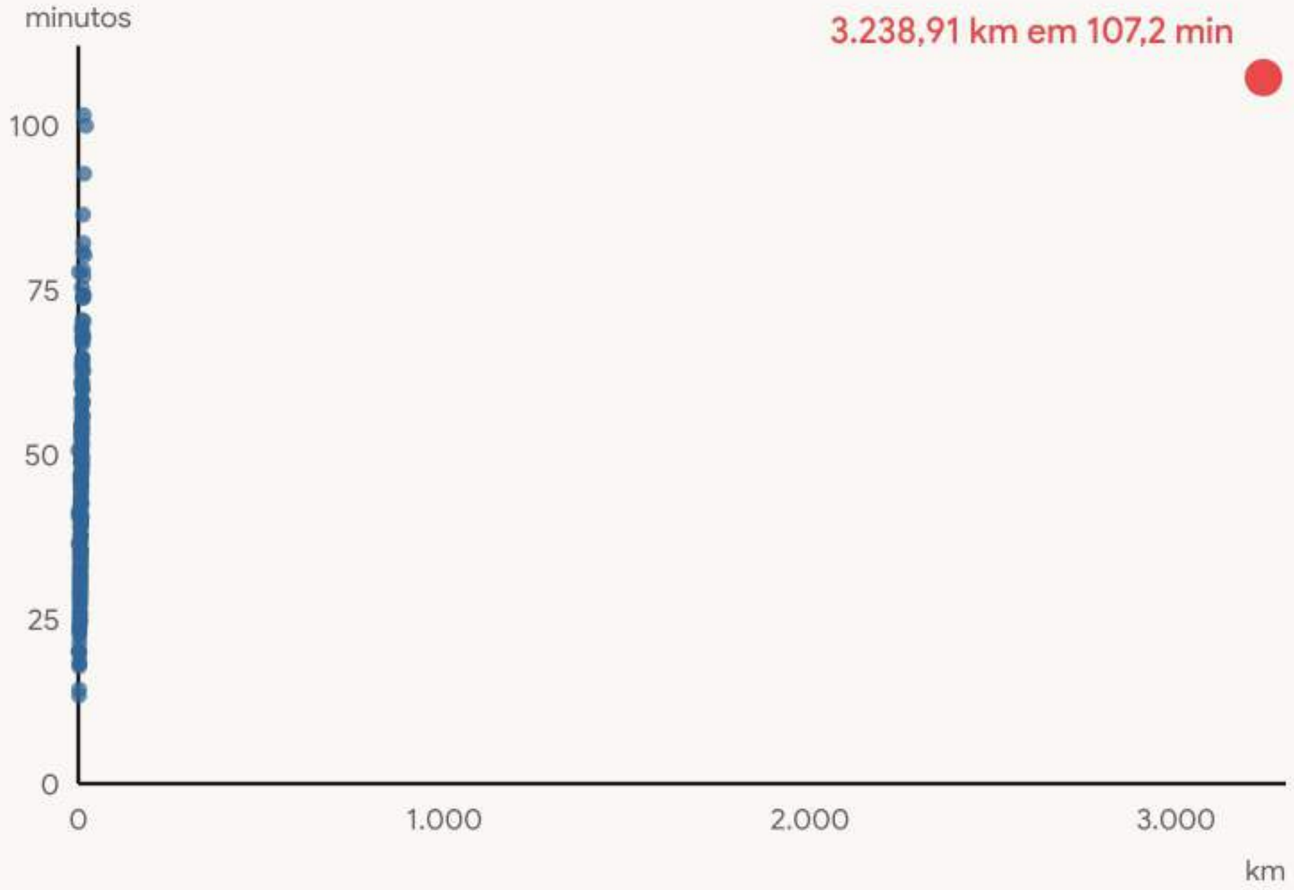
r = 0,88

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

Um punhado de erros derruba o r

Corridas: distância e duração, sem e com os treinos impossíveis.



$r = 0,12$

Com os 555 treinos de corrida acima de 200 km, o r da base cai de 0,88 para 0,12.

inteli

Correlação não é causa

Manchetes que viraram notícia e o que estava por trás.

1 **Países que comem mais chocolate ganham mais Nobel**
MESSERLI, 2012 — terceira variável

2 **Criança que resiste ao marshmallow vai melhor na escola**
WATTS; DUNCAN; QUAN, 2018 — terceira variável

3 **Uma taça por dia faz viver mais**
STOCKWELL et al., 2016 — seleção

4 **Fumante pega menos covid**
GRIFFITH et al., 2020 — seleção

5 **Refrigerante diet triplica o risco de AVC e demência**
PASE et al., 2017; WERSCHING; GARDENER; SACCO, 2017 — causalidade reversa

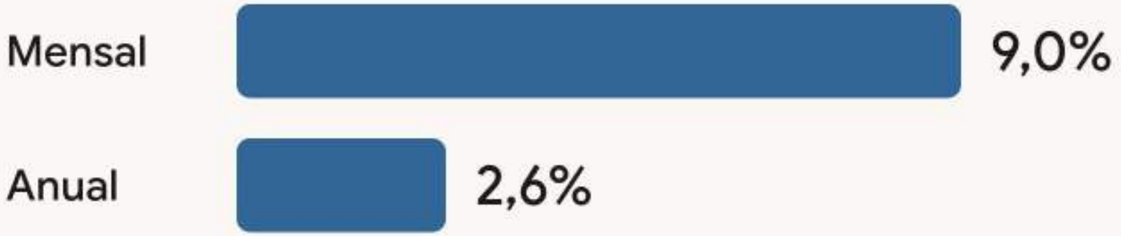
6 **As buscas no Google preveem a gripe**
LAZER et al., 2014 — coincidência

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

O cruzamento aponta suspeitos, não prova causa

Perda mensal média em 2025, por plano.



plano anual → ? → assinante fica

Números da aula 1, série mensal de 2025.

comparação

O anual só pode sair no aniversário; o mensal pode sair todo mês.

seleção

Quem escolhe o anual pode já ser quem pretendia ficar.

terceira variável

Preço, canal e cupom mudam junto com o plano.

ANÁLISE EXPLORATÓRIA · CORRELAÇÃO

Medir | Ler | Causa

A correlação sobrevive a uma terceira variável?

Sessões no app e minutos de treino em setembro de 2026, com as atividades como terceira variável.

OBJETIVO

Validar se quem abre mais o app treina mais minutos ou se os dois só seguem o número de treinos.

PROMPT

```
Leia dicionario_dados.md e me mostre o plano antes de rodar.
Em uso_mensal.csv, só mes = 2026-09 e dias_ativos > 0:
1. conte linhas e contas (user_id únicos);
2. calcule o r de Pearson entre sessoes_app e minutos;
3. calcule o mesmo r dentro de cada valor de atividades e a
média ponderada pelo número de contas;
4. calcule o r parcial de sessoes_app e minutos controlando
atividades.
Mostre as contagens de cada passo. Não altere nada em
dados/brutos/.
```

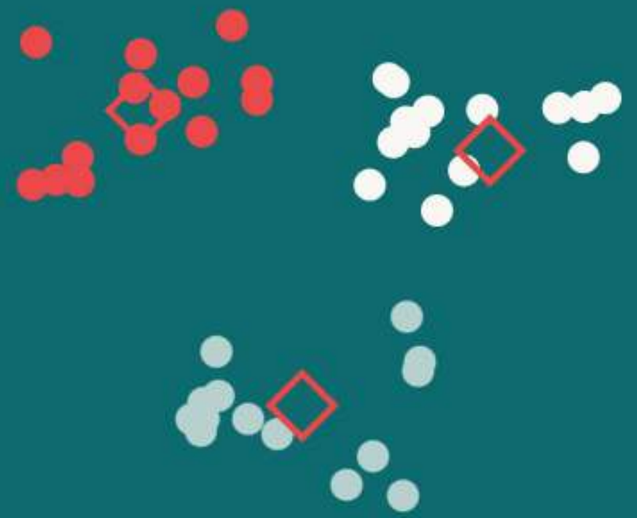
CONFIRA

- 15.685 contas com treino em setembro de 2026, de 56.565 linhas no mês.
- r de sessões e minutos: 0,88 (0,92 com quem não treinou).
- Por número de atividades e no r parcial, cai para 0,02: não sobrevive.
- Armadilha: faixas largas de atividades deixam a terceira variável vazar (r de 0,36 a 0,67).

2

Segmentação

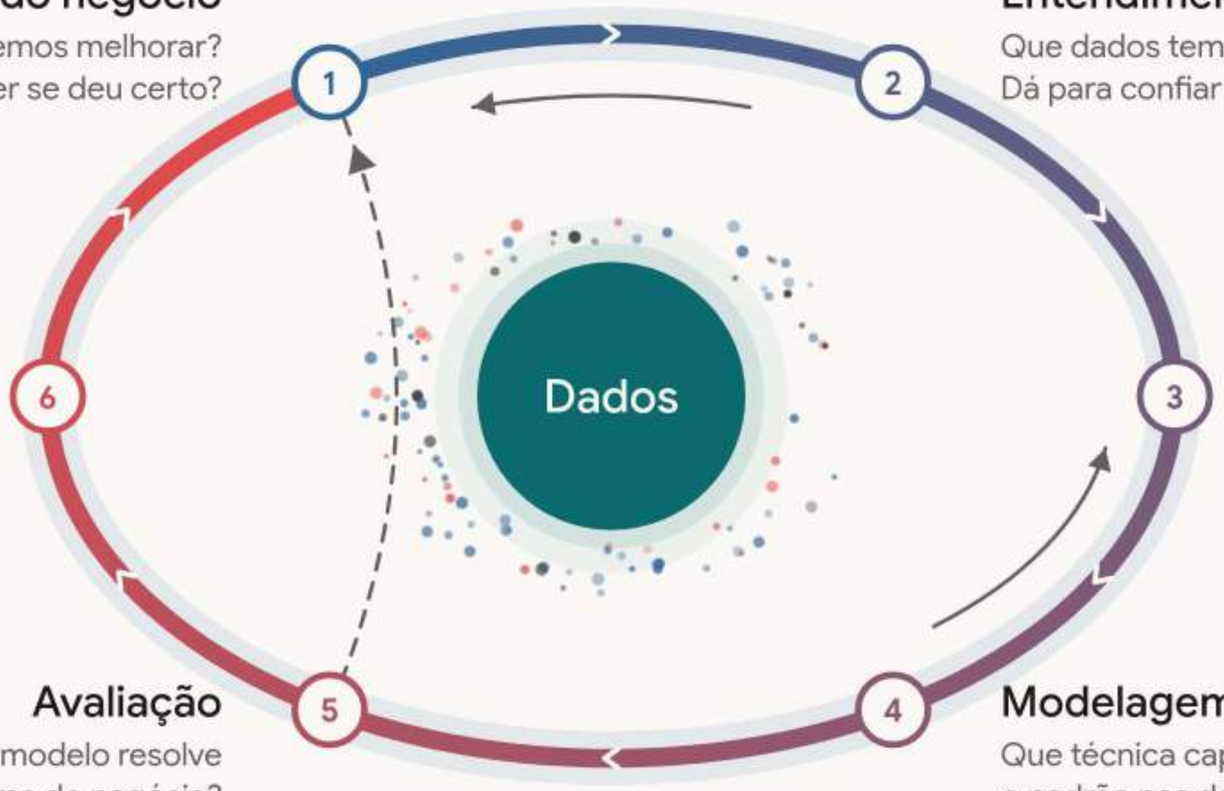
CRISP-DM, paradigmas de aprendizado e o k-means



inteli

CRISP-DM: seis fases que vão e voltam

Cross-Industry Standard Process for Data Mining (2000): um roteiro aberto de projeto de dados, para qualquer setor



1 Entendimento do negócio
Que decisão queremos melhorar?
Como saber se deu certo?

2 Entendimento dos dados
Que dados temos?
Dá para confiar neles?

3 Preparação dos dados
Como os arquivos viram
a tabela que o modelo lê?

4 Modelagem
Que técnica captura
o padrão nos dados?

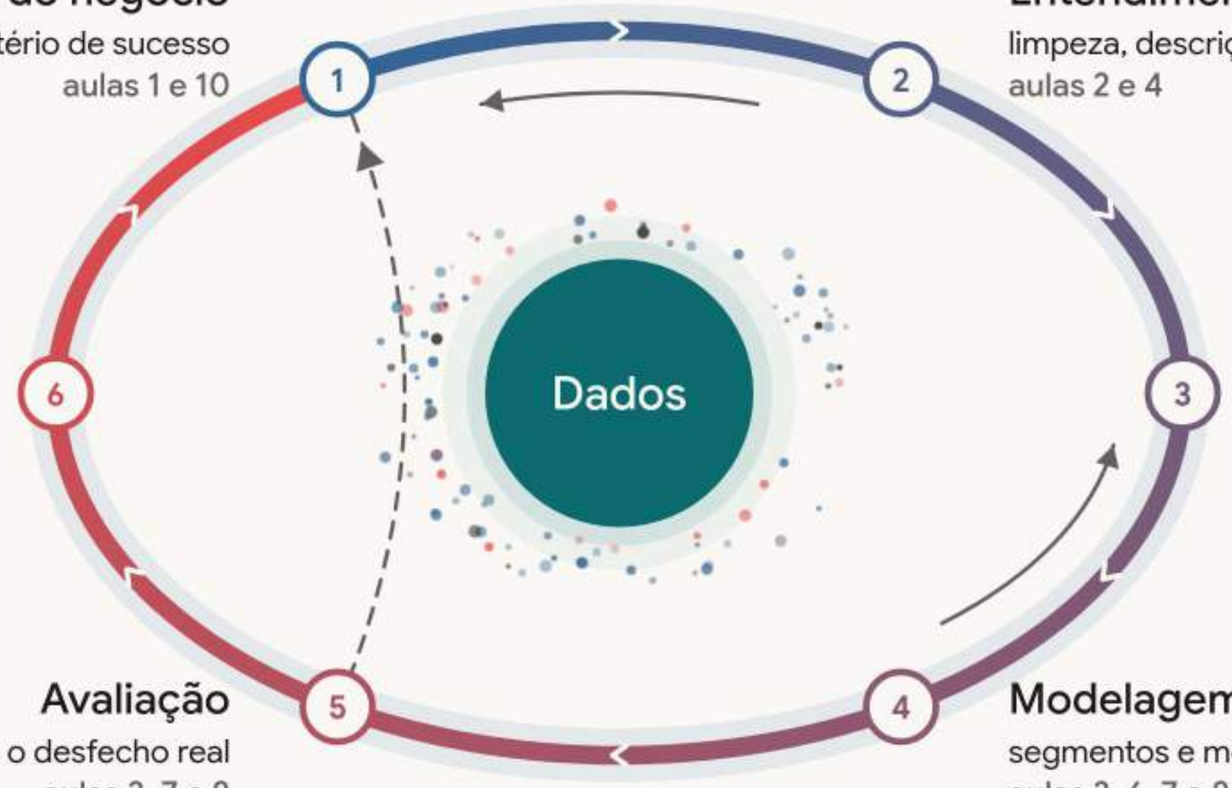
5 Avaliação
O modelo resolve
o problema do negócio?

6 Implantação
Como o resultado entra
na rotina da empresa?

CHAPMAN et al. (2000); WIRTH; HIPP (2000)

No módulo, cada fase produz um resultado

O que cada fase do CRISP-DM produz no projeto e em qual aula do módulo ela acontece



Entendimento do negócio
a pergunta e o critério de sucesso
aulas 1 e 10

Entendimento dos dados
limpeza, descrição e exploração
aulas 2 e 4

Preparação dos dados
integração, corte, rótulo e variáveis
aulas 2 e 5

Modelagem
segmentos e modelos preditivos
aulas 3, 6, 7 e 8

Avaliação
métricas e o desfecho real
aulas 3, 7 e 8

Implantação
o modelo disponibilizado
aula 9 · entrega 18/12

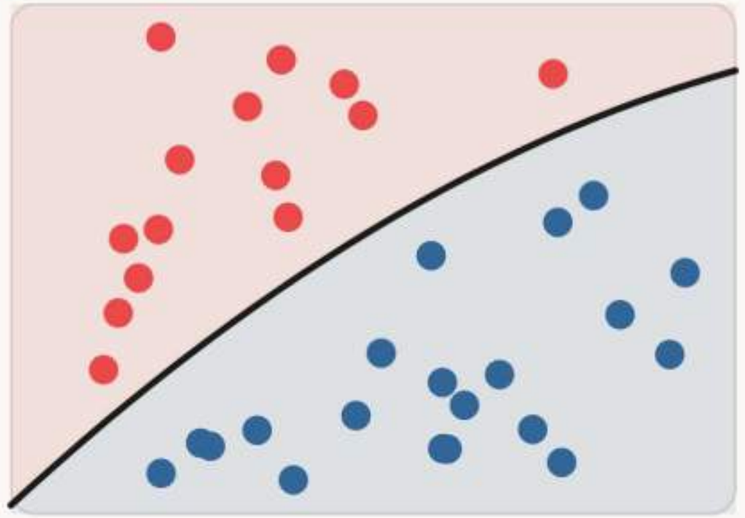
CHAPMAN et al. (2000); WIRTH; HIPP (2000)

Supervisionado: aprende com a resposta

Exemplos do passado já trazem o rótulo: quem saiu e quem ficou

Supervisionado

saiu ficou



- Regressão logística e árvores · aula 6
- Regressão e avaliação · aula 7
- Bagging e boosting · aula 8

inteli

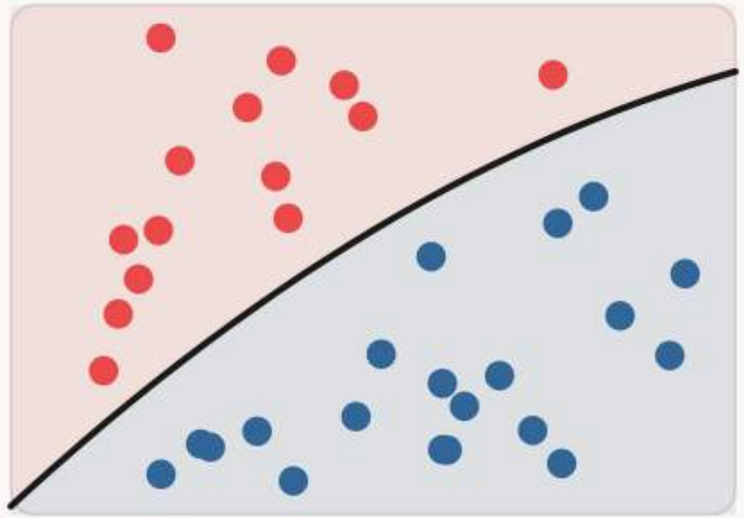
Hastie, Tibshirani e Friedman (2009)

Não supervisionado: acha grupos sem resposta

Sem rótulo, os pontos parecidos se juntam sozinhos

Supervisionado

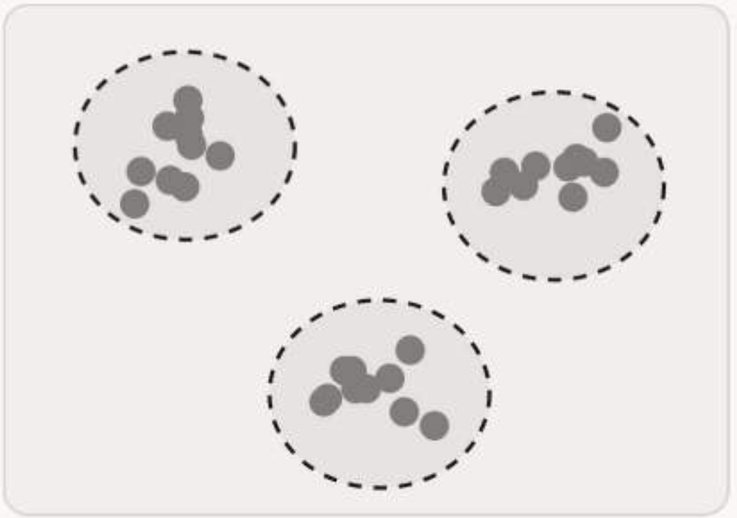
● saiu ● ficou



- Regressão logística e árvores · aula 6
- Regressão e avaliação · aula 7
- Bagging e boosting · aula 8

Não supervisionado

Sem rótulo: só as semelhanças



- Clusterização · aula 3

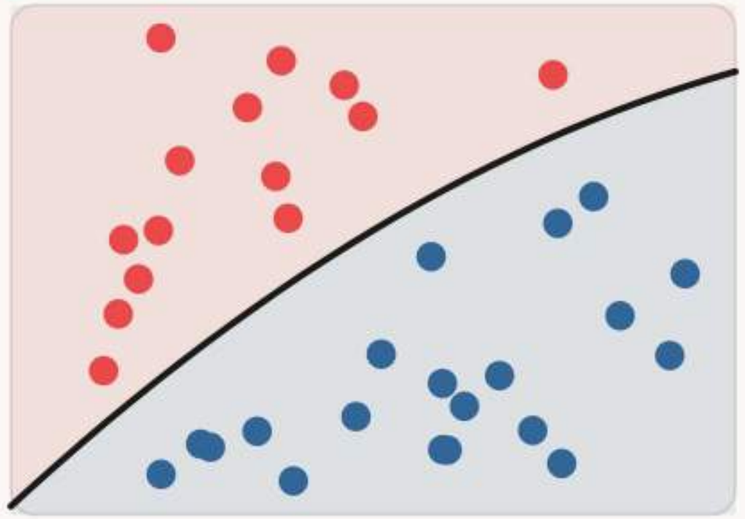
Hastie, Tibshirani e Friedman (2009)

Cada algoritmo aprende de um jeito

No módulo, os dois primeiros; os outros dois, só para o mapa

Supervisionado

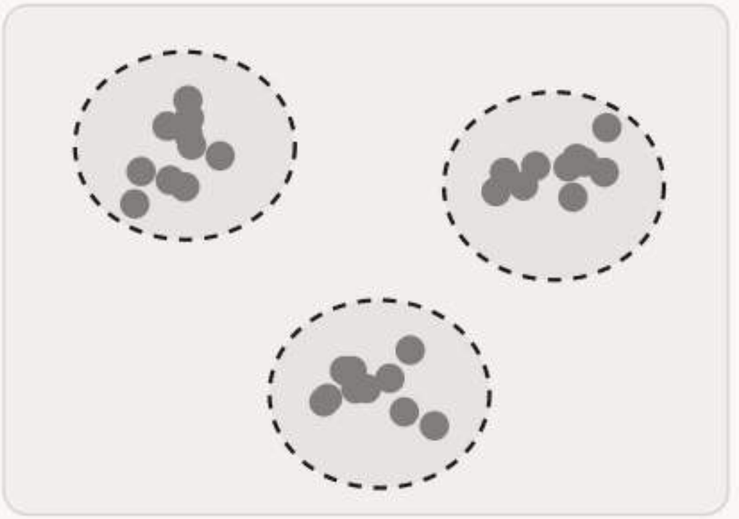
saiu ficou



- Regressão logística e árvores · aula 6
- Regressão e avaliação · aula 7
- Bagging e boosting · aula 8

Não supervisionado

Sem rótulo: só as semelhanças



- Clusterização · aula 3

Por reforço

Tentativa e recompensa

× × × +1

Fora do módulo

Autossupervisionado

O próprio texto vira o gabarito

Quem treina não cancela

É assim que os LLMs aprendem

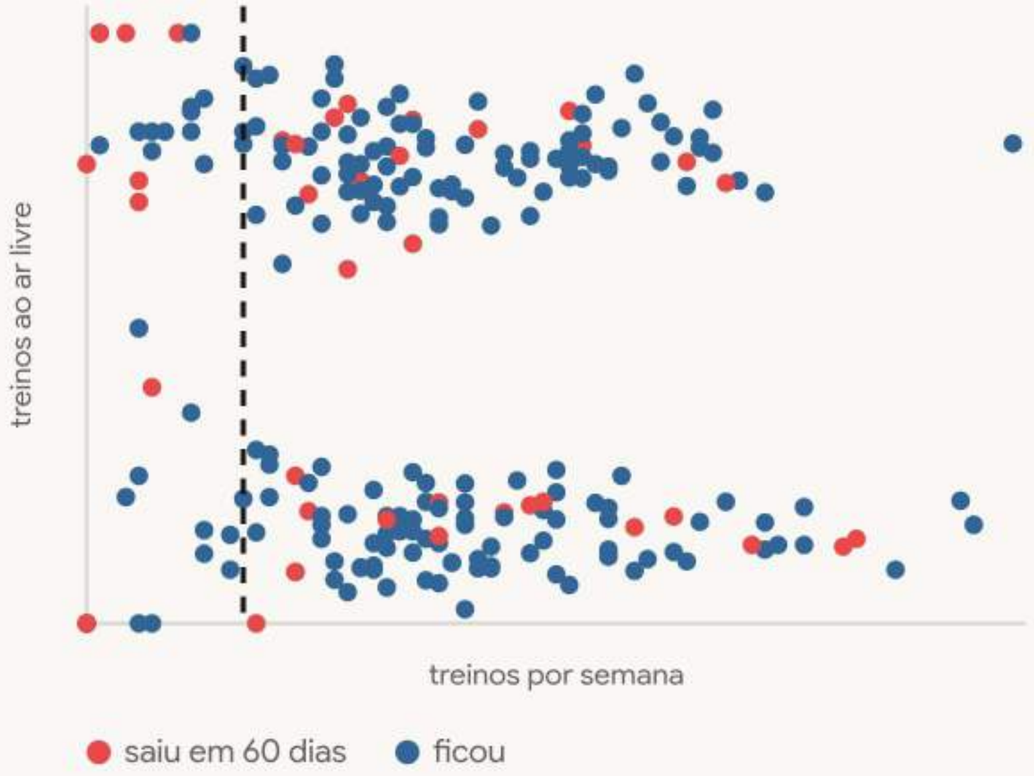
inteli

Hastie, Tibshirani e Friedman (2009); Sutton e Barto (2018)

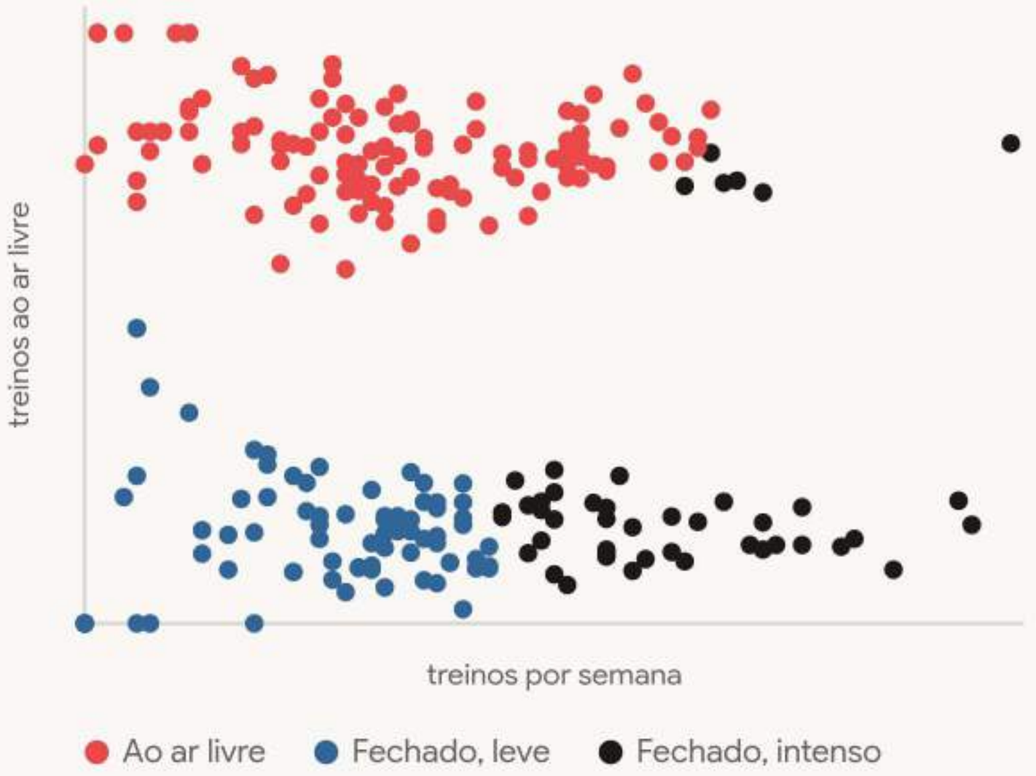
Supervisionado e não supervisionado

Os mesmos 240 assinantes, com e sem o rótulo de quem saiu

SUPERVISIONADO: APRENDE COM QUEM SAIU



NÃO SUPERVISIONADO: SÓ A DISTÂNCIA



inteli

Doze assinantes para separar em grupos

Plano, idade e comportamento de treino em 31/07/2026

	treinos/sem	ar livre	parado
A — Mensal, 57 anos	3,4	84%	1
B — Anual, 56 anos	2,4	18%	4
C — Anual, 41 anos	1,4	27%	0
D — Mensal, 35 anos	3,3	70%	0
E — Mensal, 56 anos	2,8	84%	0
F — Anual, 42 anos	0	0%	200
G — Anual, 33 anos	2,1	79%	1
H — Anual, 39 anos	0	0%	200
I — Anual, 62 anos	2,8	26%	1
J — Anual, 66 anos	2,4	23%	0
K — Anual, 46 anos	0	0%	200
L — Anual, 73 anos	1,1	4%	7

Os doze agrupados por comportamento

Treinos por semana, ar livre, dias parado e tempo de casa

ATIVOS, AR LIVRE

A
Mensal
57 anos

treinos/sem	ar livre	parado
3,4	84%	1

E
Mensal
56 anos

treinos/sem	ar livre	parado
2,8	84%	0

G
Anual
33 anos

treinos/sem	ar livre	parado
2,1	79%	1

ATIVOS, FECHADO

B
Anual
56 anos

treinos/sem	ar livre	parado
2,4	18%	4

C
Anual
41 anos

treinos/sem	ar livre	parado
1,4	27%	0

L
Anual
73 anos

treinos/sem	ar livre	parado
1,1	4%	7

PARADOS

F
Anual
42 anos

treinos/sem	ar livre	parado
0	0%	200

H
Anual
39 anos

treinos/sem	ar livre	parado
0	0%	200

K
Anual
46 anos

treinos/sem	ar livre	parado
0	0%	200

VETERANOS

D
Mensal
35 anos

treinos/sem	ar livre	parado
3,3	70%	0

I
Anual
62 anos

treinos/sem	ar livre	parado
2,8	26%	1

J
Anual
66 anos

treinos/sem	ar livre	parado
2,4	23%	0

Três decisões antes do algoritmo

O algoritmo só forma os grupos depois dessas três escolhas

1

Quais variáveis

Cadastro ou comportamento? Cada escolha conta uma história diferente sobre as mesmas pessoas.

o grupo

2

O que é parecido

Uma régua de distância entre dois assinantes. Depende da unidade de cada variável.

o grupo

3

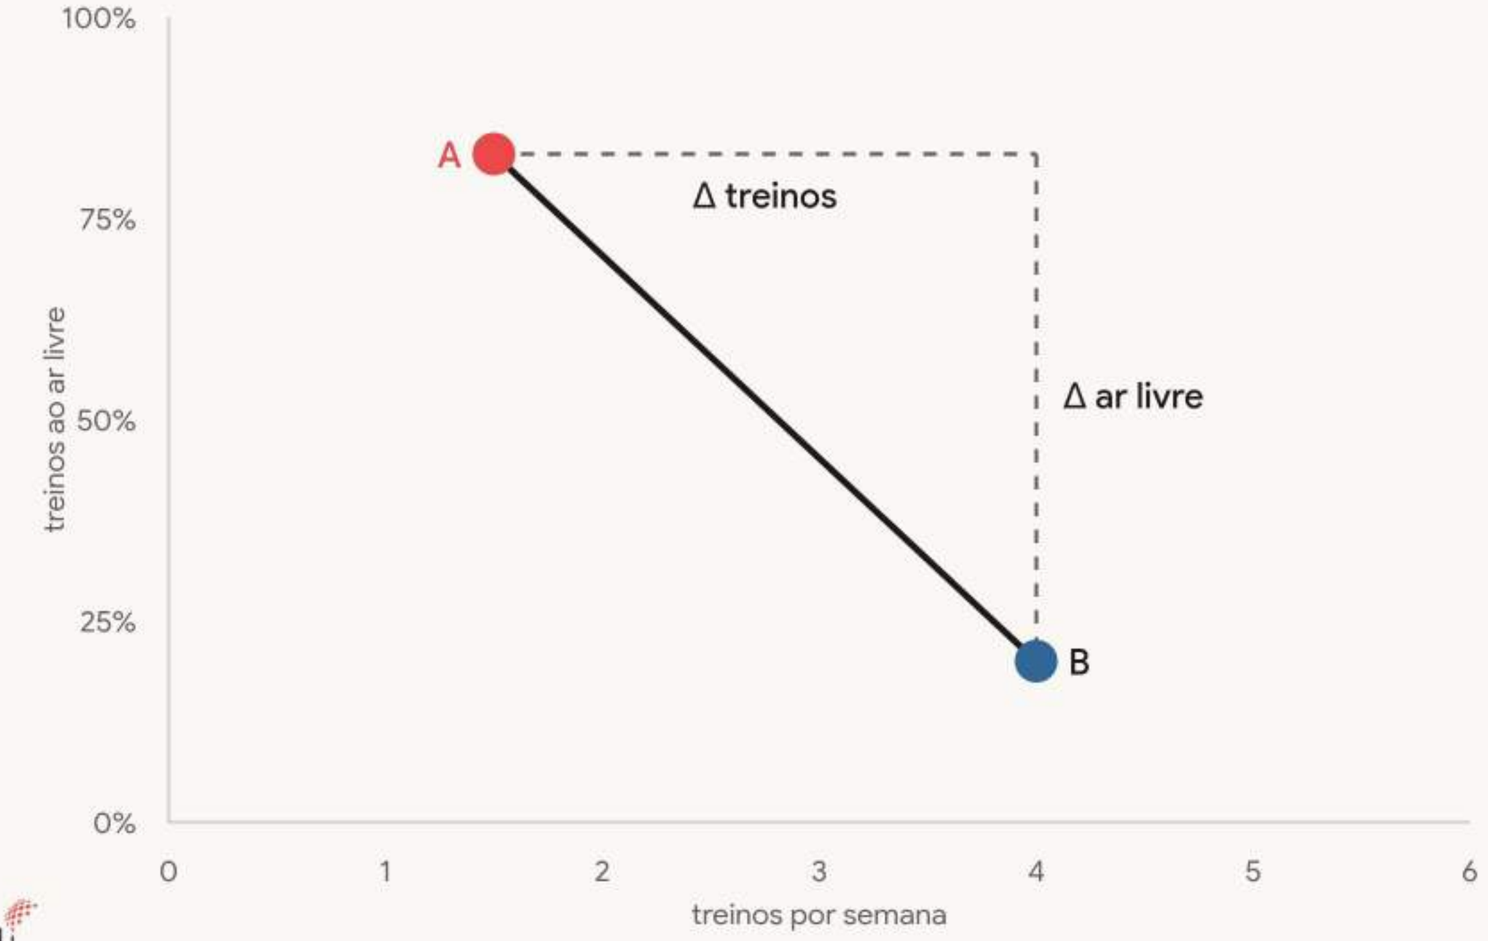
Quantos grupos

O k do k-means. O algoritmo forma os grupos; quantos, o grupo decide.

o grupo

A distância entre dois assinantes

Quanto menor a distância, mais parecidos o k-means considera os dois



DISTÂNCIA EUCLIDIANA

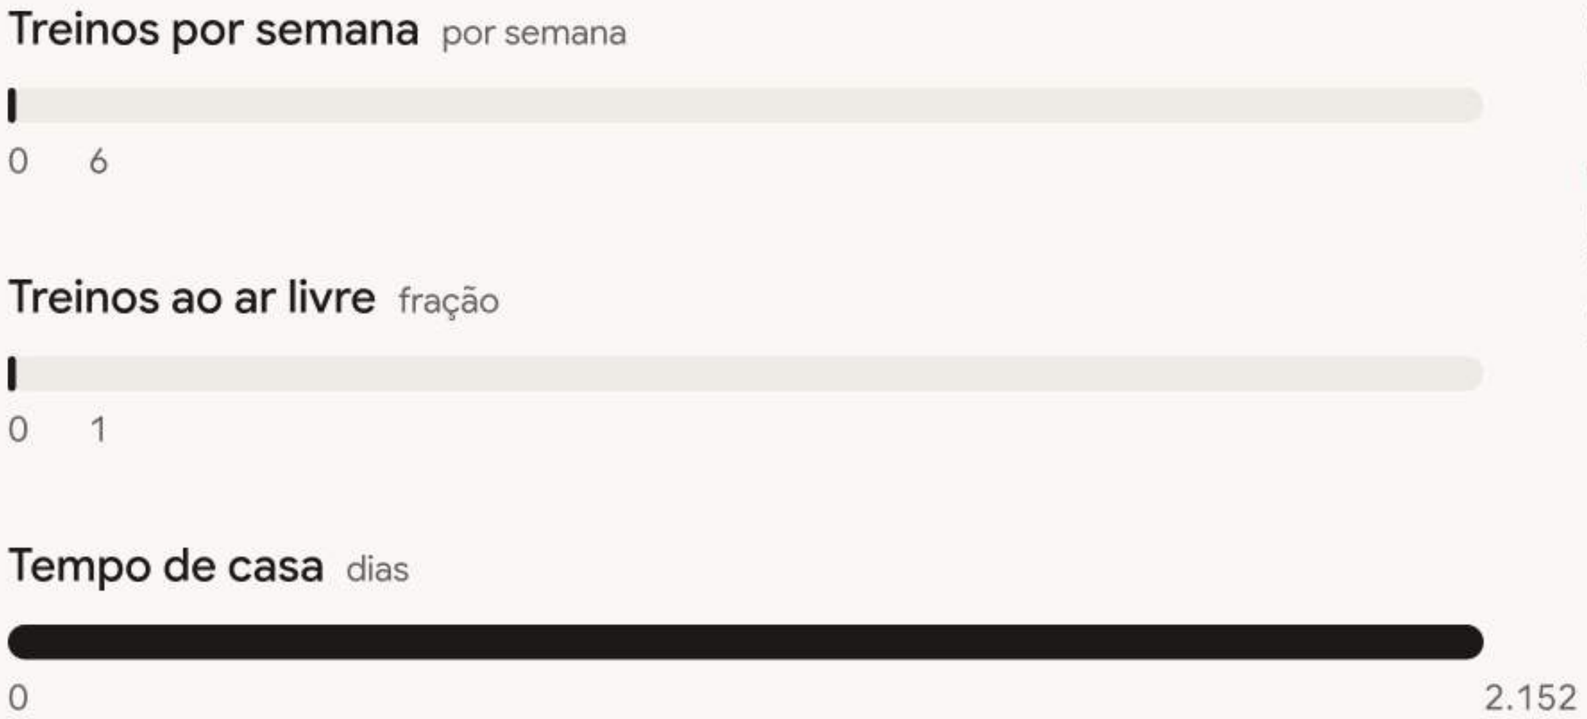
$$d = \sqrt{(\Delta x^2 + \Delta y^2)}$$

COM QUATRO VARIÁVEIS

A mesma conta, com quatro termos dentro da raiz. O algoritmo só enxerga essa distância.

Cada variável tem uma escala diferente

Treinos vão de 0 a 6 por semana; tempo de casa, de 0 a 2.152 dias



0 a 6 treinos por semana

0 a 1 fração ao ar livre

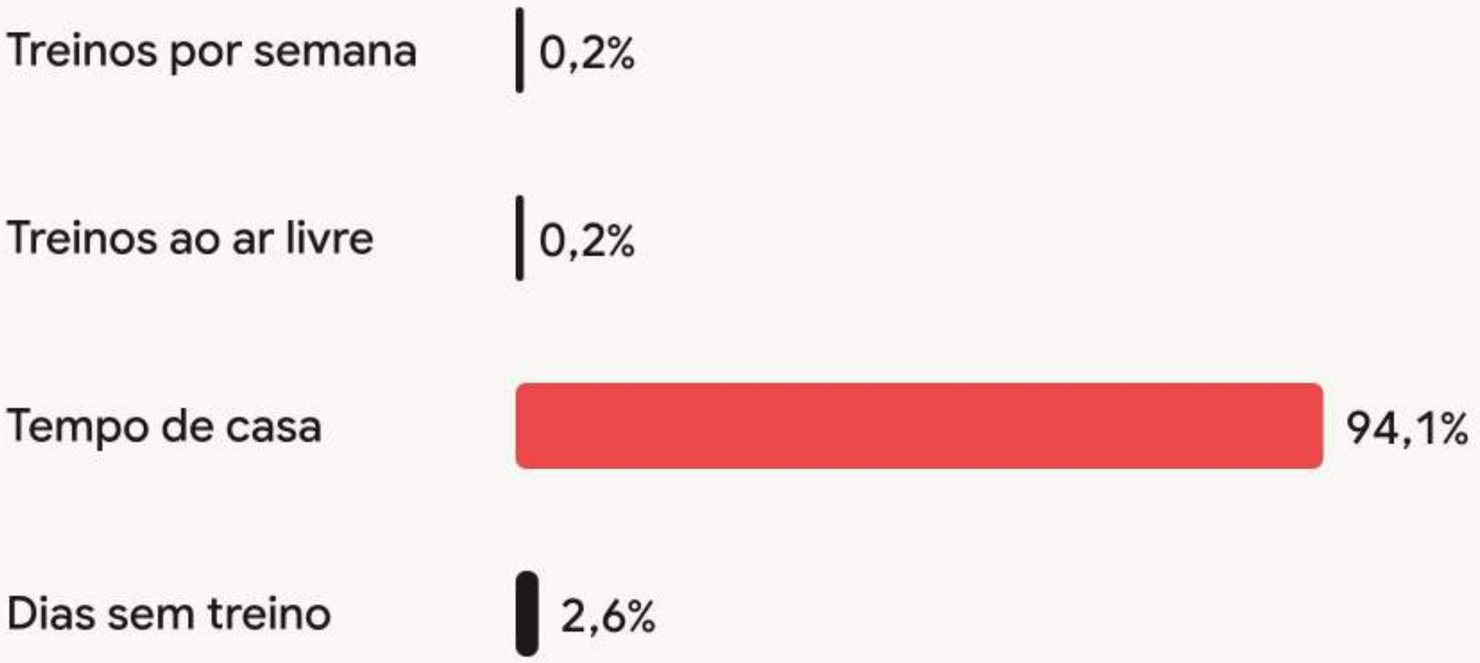
0 a 2.152 dias de casa

O PROBLEMA

Na mesma régua, uma diferença de 1 treino por semana pesa o mesmo que 1 dia de casa. Dois mil dias contra seis treinos: a distância vira só tempo de casa.

Sem padronizar, o tempo de casa decide sozinho

k = 4 na base inteira, com as variáveis na unidade original

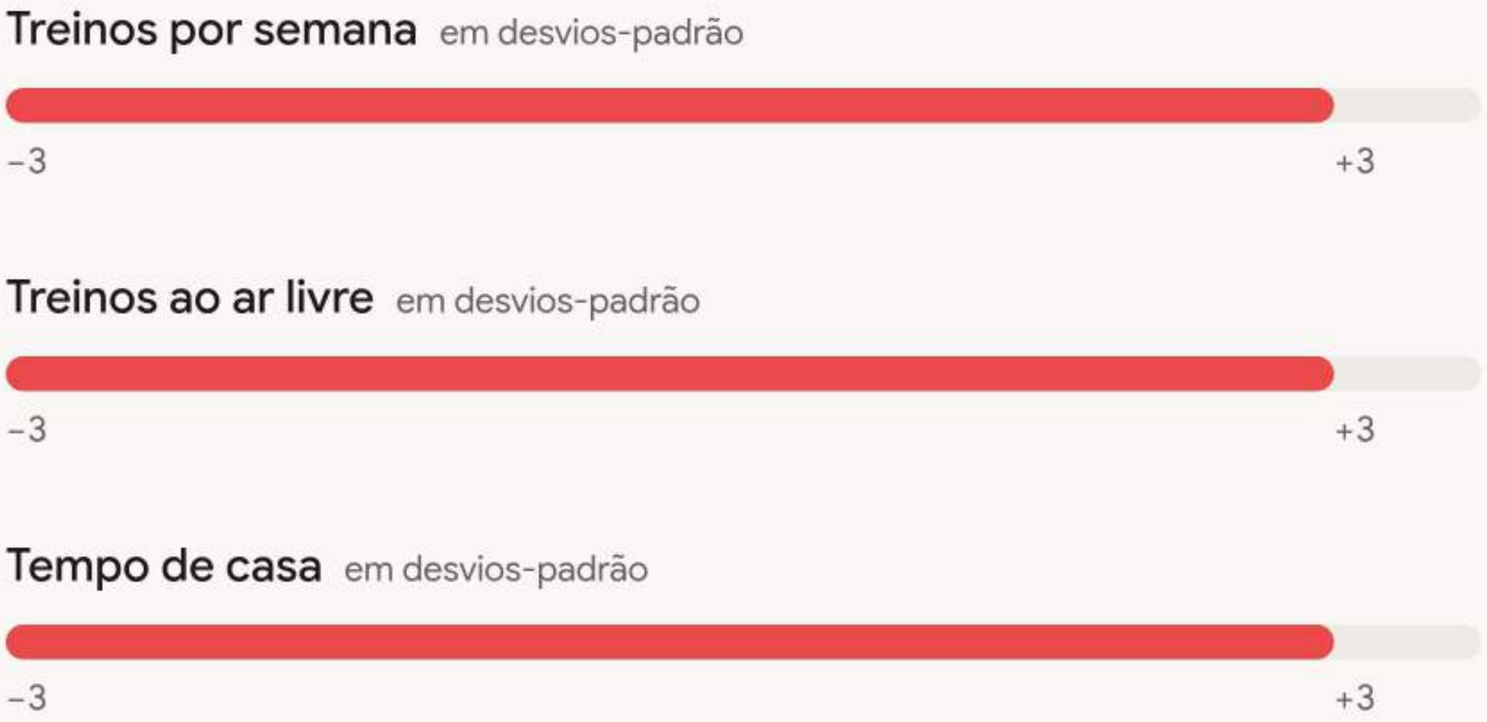


OS QUATRO GRUPOS

Os quatro grupos são faixas de tempo de casa: até 343 dias, de 338 a 876, de 879 a 1.554 e de 1.552 a 2.152. Treinos e ar livre não contam.

Padronizar põe as variáveis na mesma escala

Cada variável em desvios-padrão a partir da própria média



PADRONIZAR

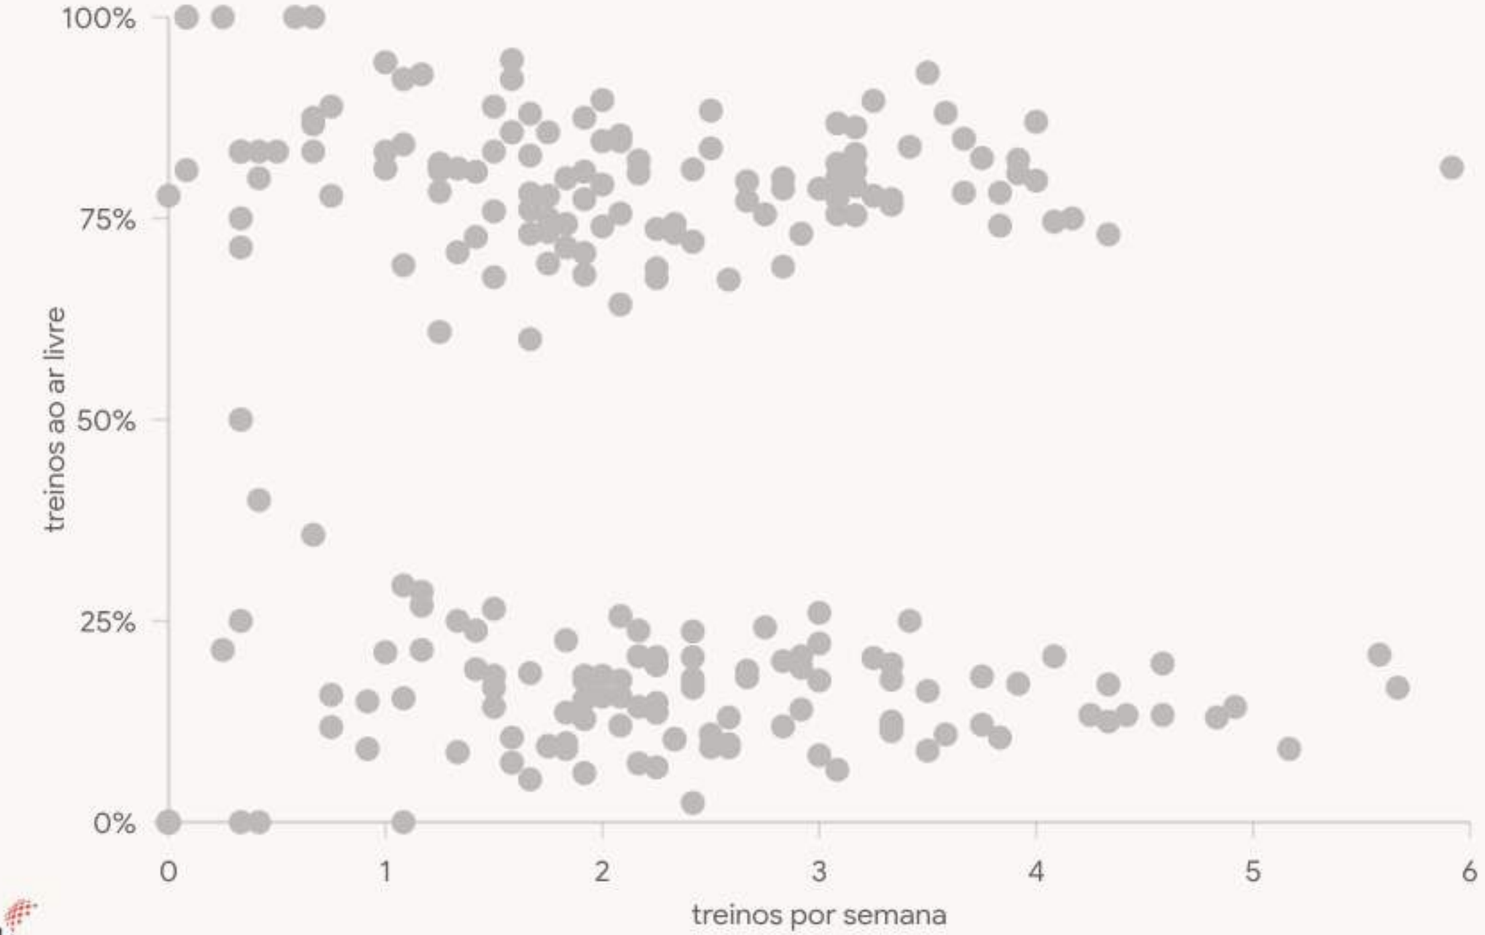
$$z = (x - \text{média}) / \text{desvio}$$

NO DECISOES.MD

O desvio-padrão da aula 2 volta aqui. Log ou teto em variáveis de cauda longa (dias sem treino, km) é decisão do grupo, e vai para o decisoes.md.

240 assinantes, duas variáveis

Treinos por semana e % dos treinos ao ar livre, nas 12 semanas até 31/07/2026



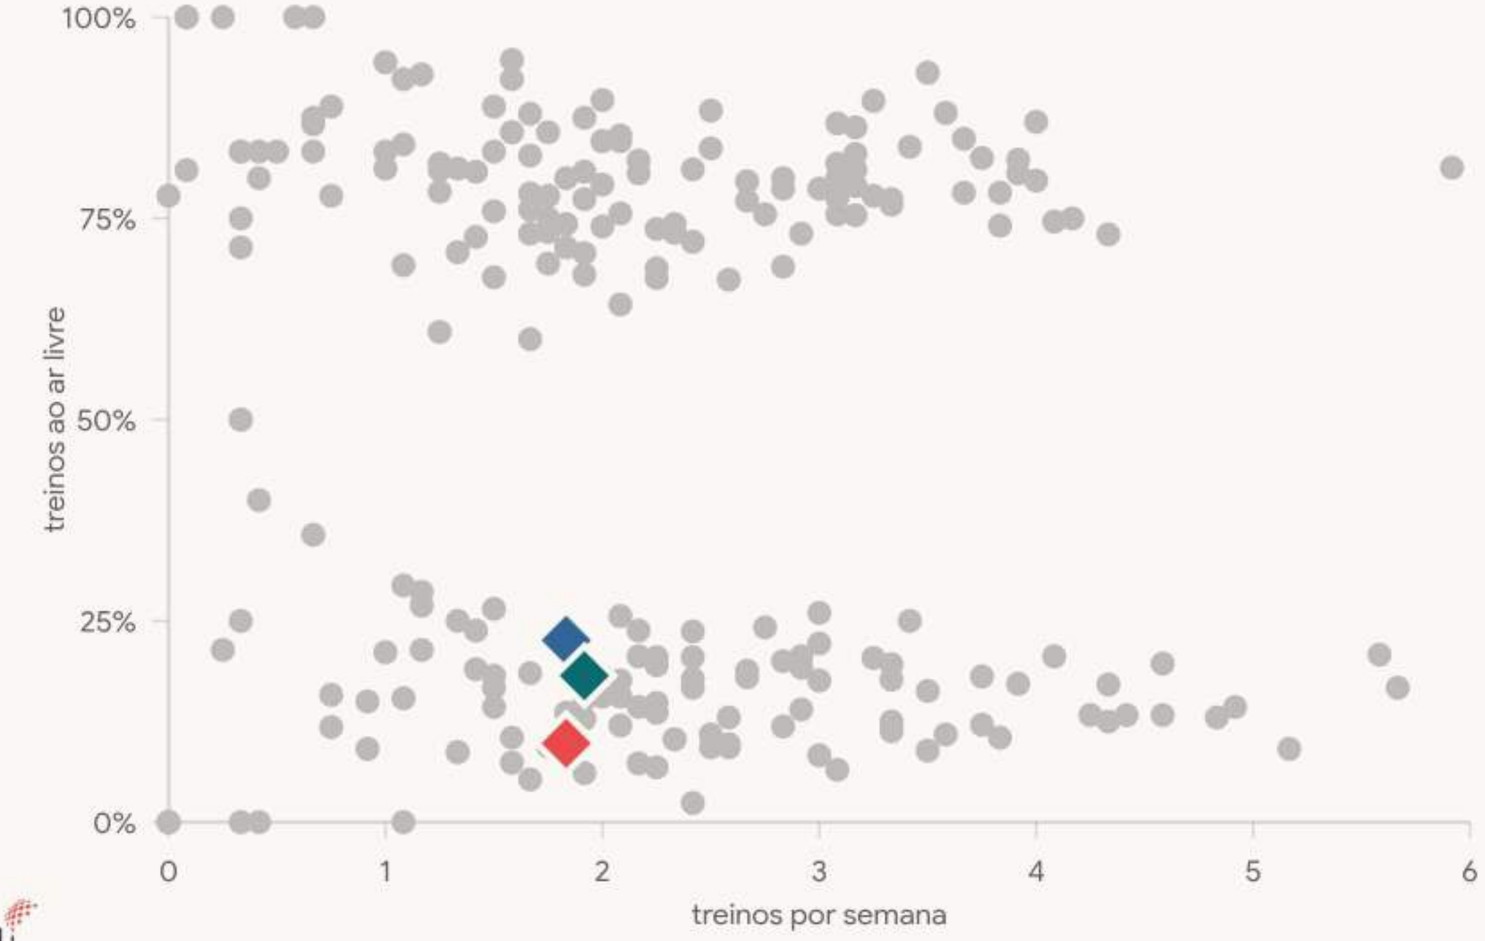
OS PONTOS

Cada ponto é um assinante, nas 12 semanas até o corte.

inteli

Três centros sorteados

k = 3 é escolha nossa; o lugar inicial de cada centro é sorteio



K

3

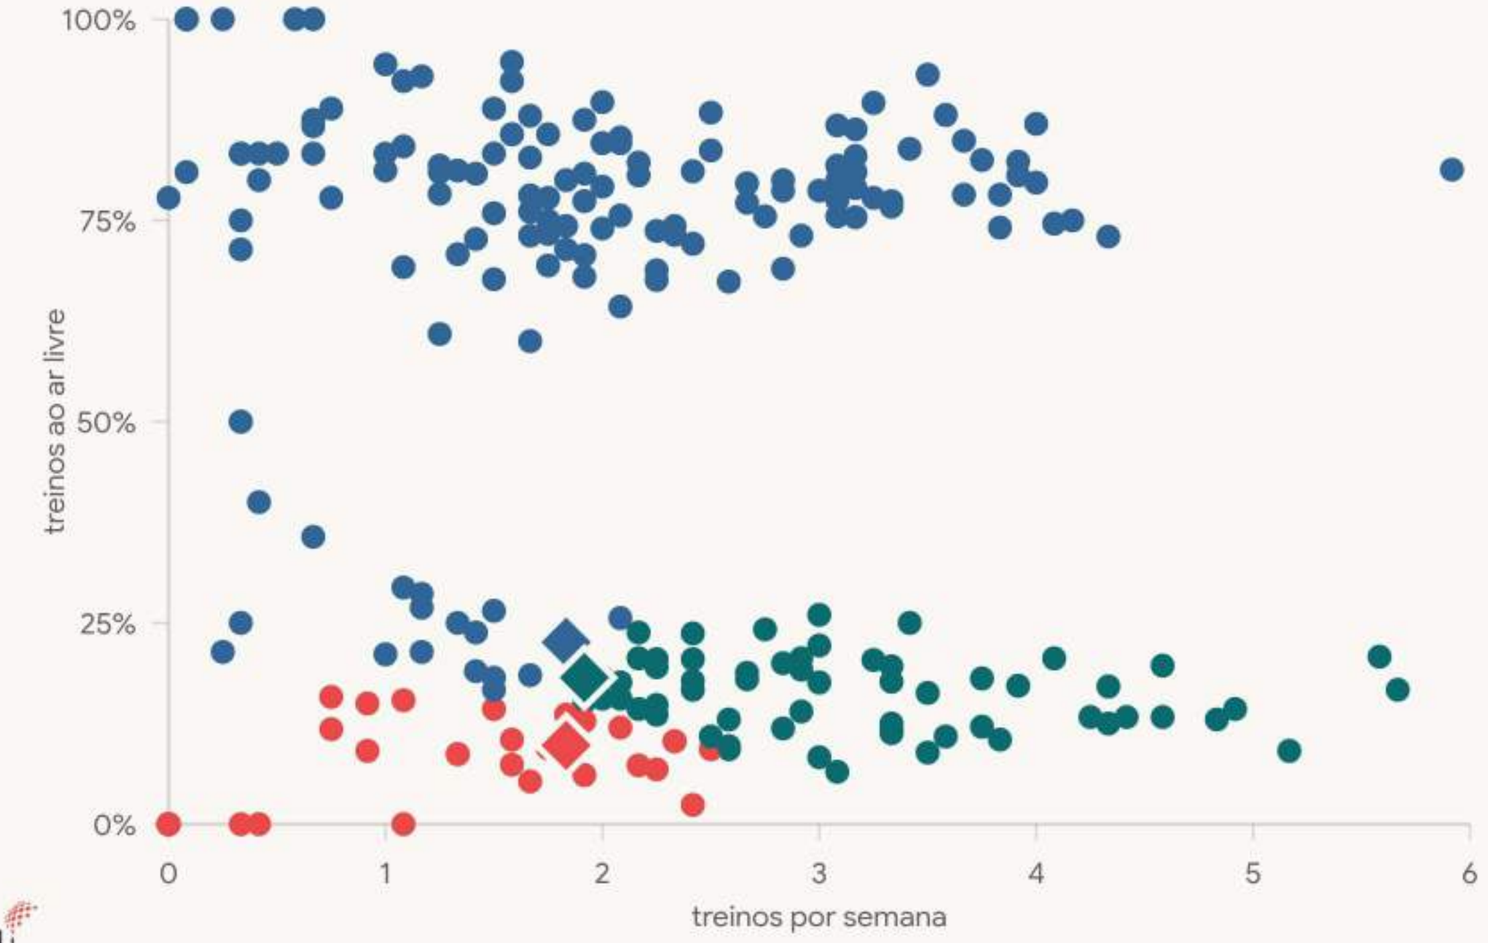
ANTES DE COMEÇAR

O número de grupos é nosso. O lugar inicial dos centros é sorteado.

inteli

Passo 1: cada ponto, ao centro mais próximo

A cor é o centro mais próximo; a inércia soma as distâncias ao quadrado



K

3

INÉRCIA

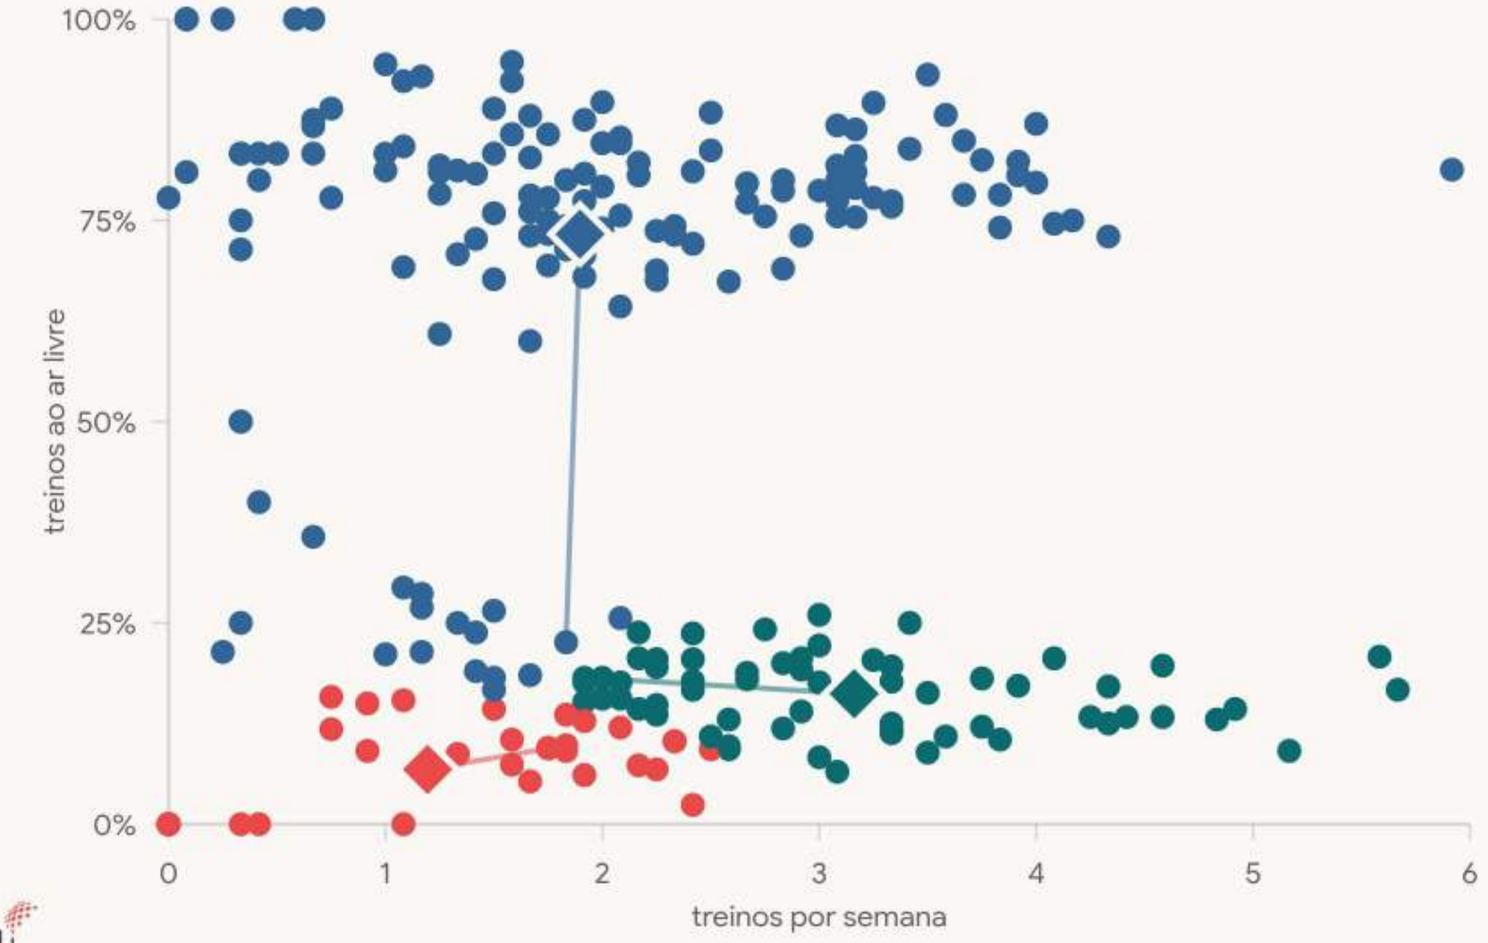
613,7

O QUE ELA MEDE

A soma, para todos os pontos, da distância ao quadrado até o próprio centro.

Passo 2: cada centro, à média do seu grupo

O centro desliza até a média dos seus pontos



K

3

INÉRCIA

613,7

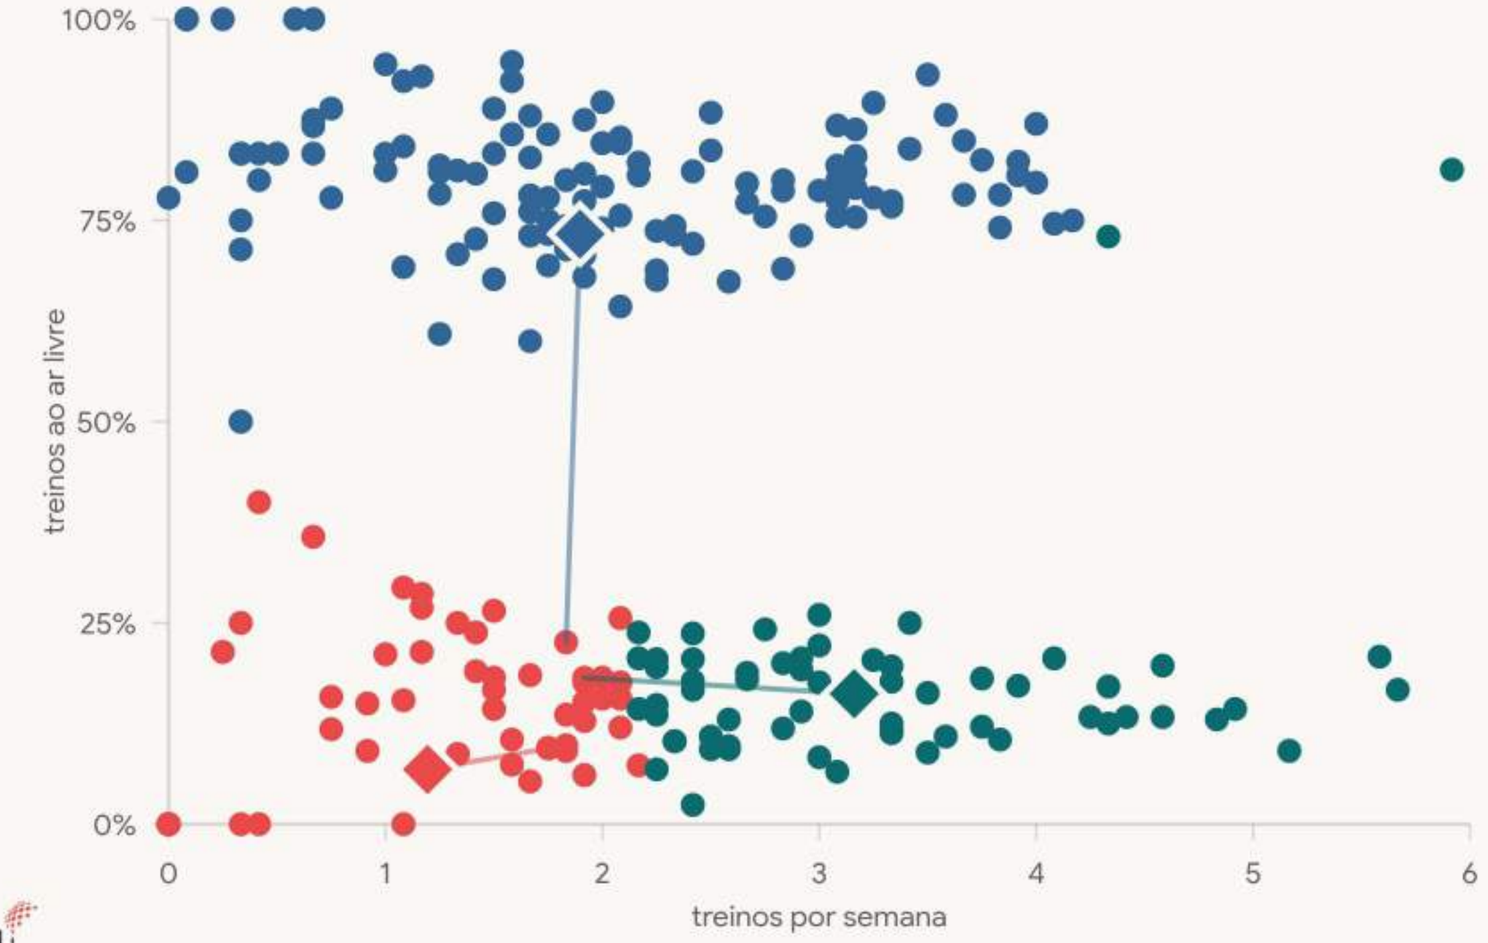
MOVER

Cada centro vai para a média dos pontos que ficaram com ele.

inteli

Volta 2: atribuir e mover de novo

Alguns pontos trocam de grupo; a inércia cai de novo



K

3

VOLTA

2

INÉRCIA

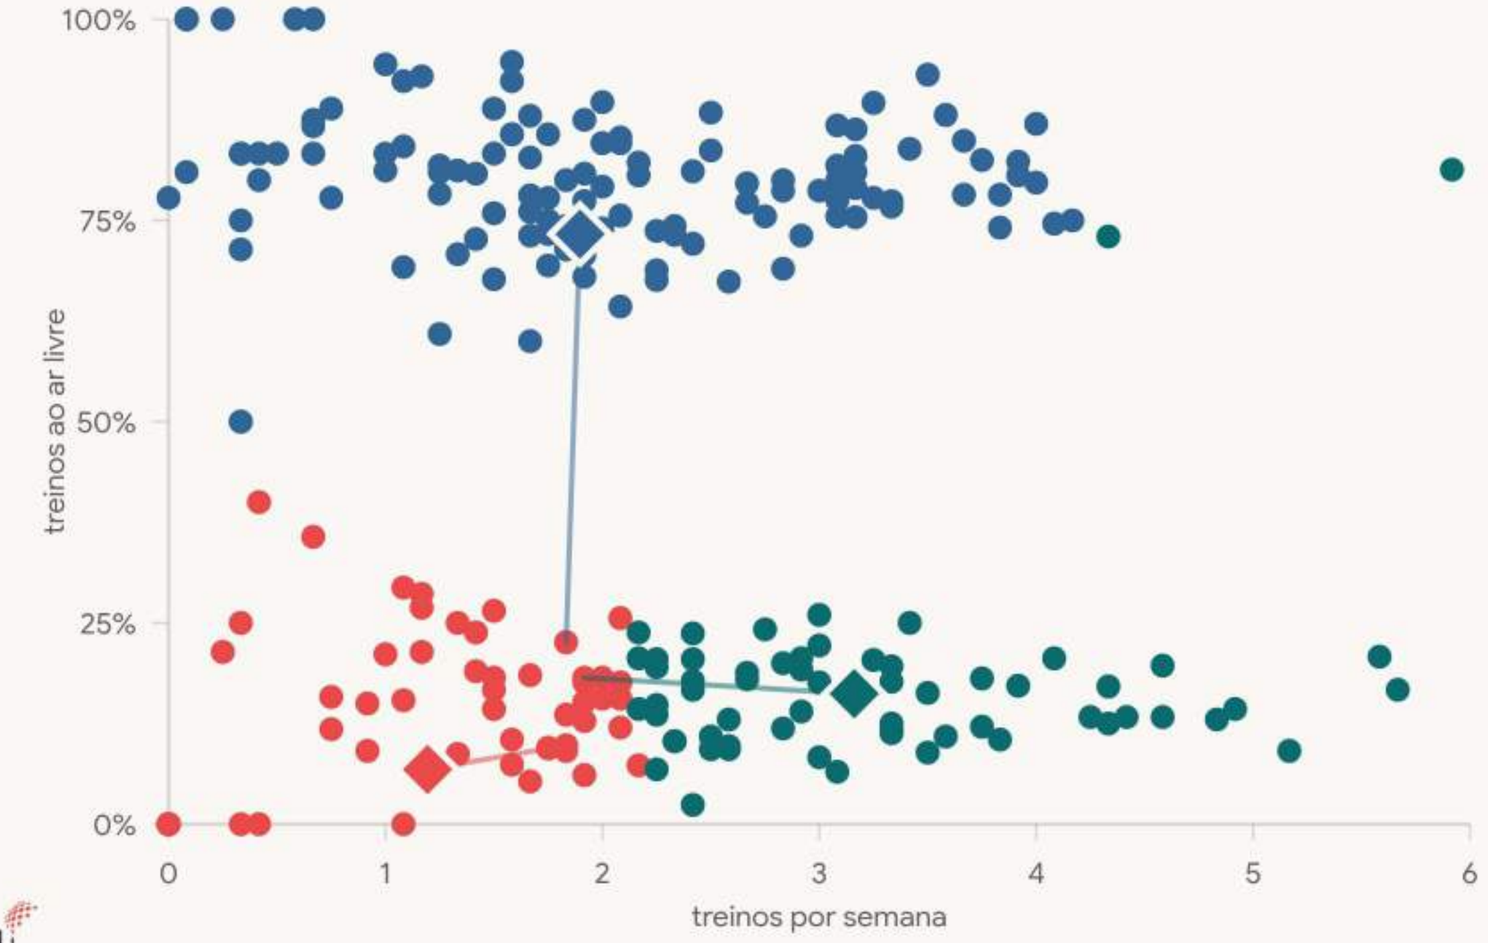
182,1

REPETIR

Com os centros no lugar novo, alguns pontos ficam mais perto de outro centro.

O algoritmo repete até nenhum ponto trocar

A cada volta, menos pontos mudam de grupo



K

3

VOLTA

2

INÉRCIA

182,1

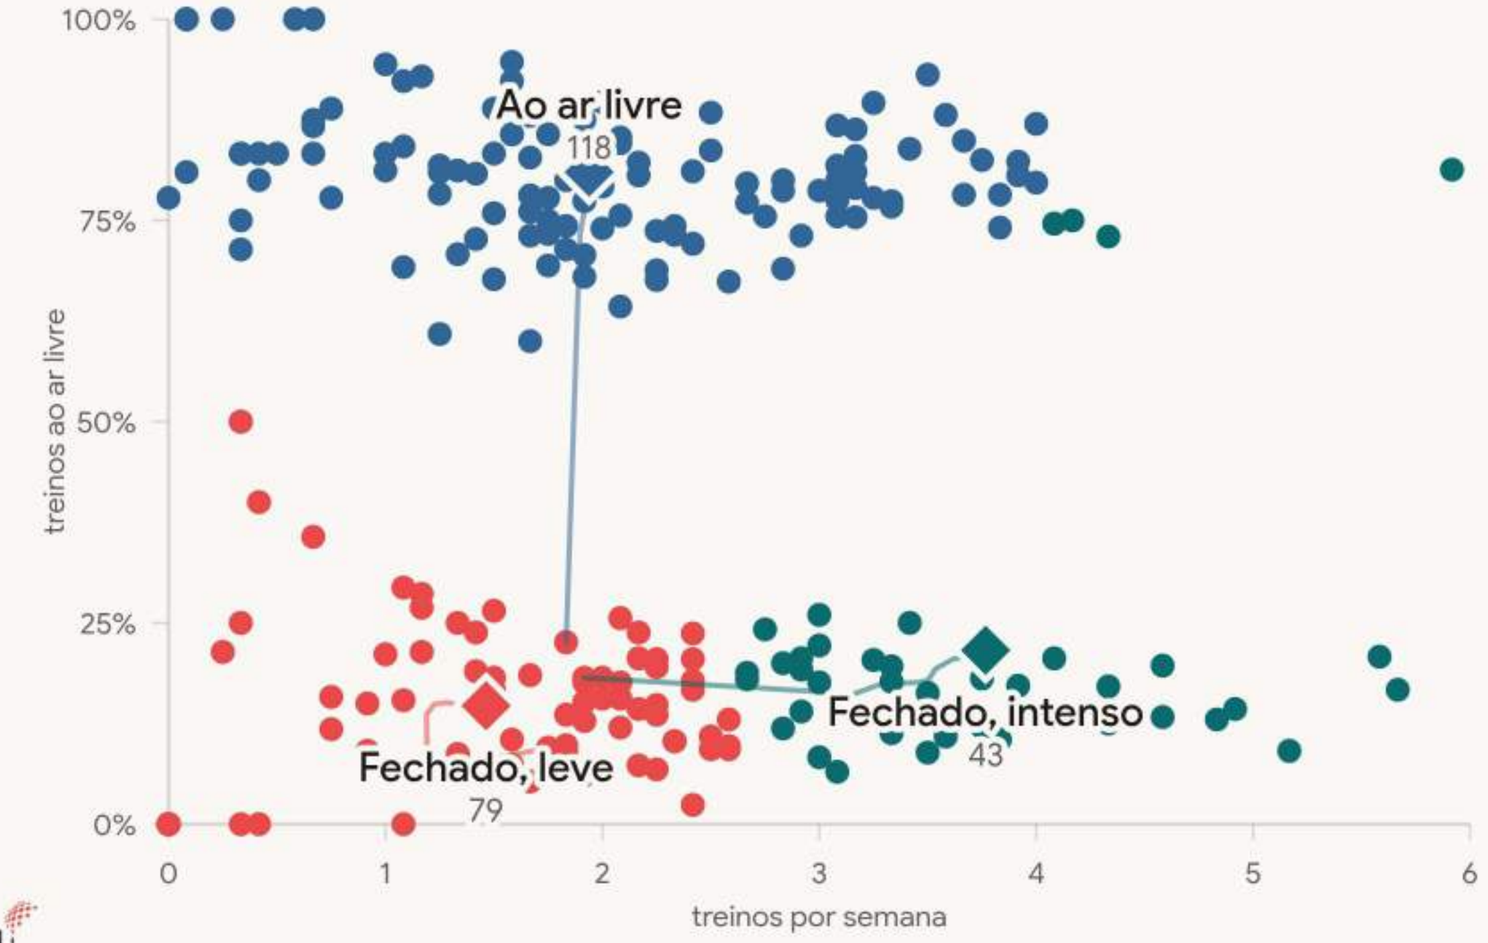
CONVERGIR

A cada volta, menos pontos trocam e a inércia cai menos.

inteli

Na volta 11, nenhum ponto troca de grupo

O k-means devolve números; os nomes no gráfico são leitura do grupo



K

3

VOLTA

11

INÉRCIA

167,8

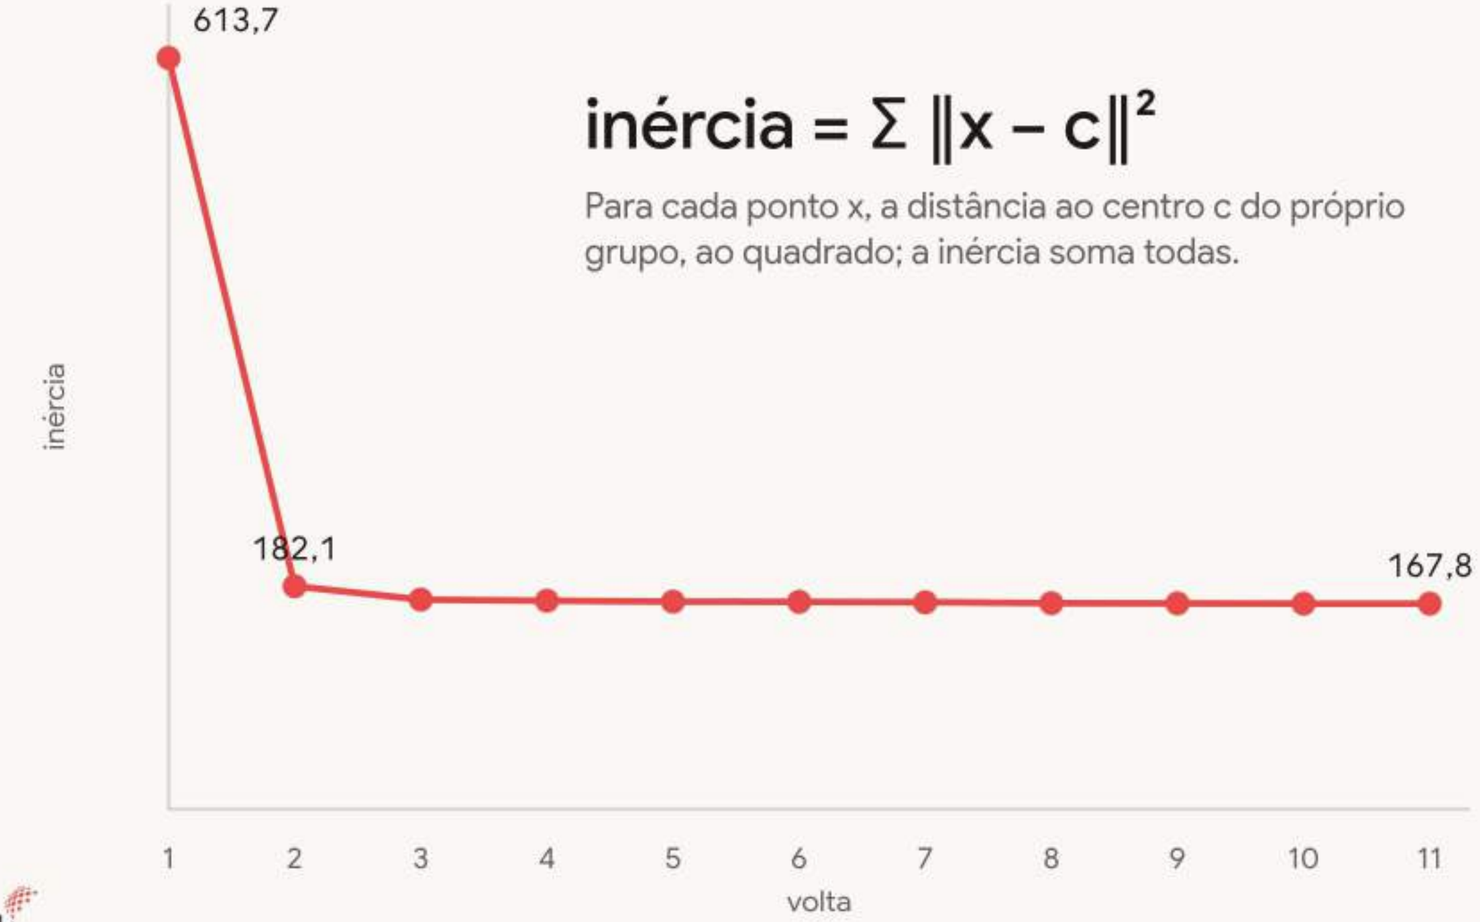
PAROU

Nenhum ponto troca de centro. O algoritmo devolve o número do grupo de cada assinante.

inteli

A inércia cai a cada volta

Onze voltas, de 613,7 a 167,8



$$\text{inércia} = \Sigma \, \|x - c\|^2$$

Para cada ponto x, a distância ao centro c do próprio grupo, ao quadrado; a inércia soma todas.

K

3

VOLTA

11

INÉRCIA

167,8

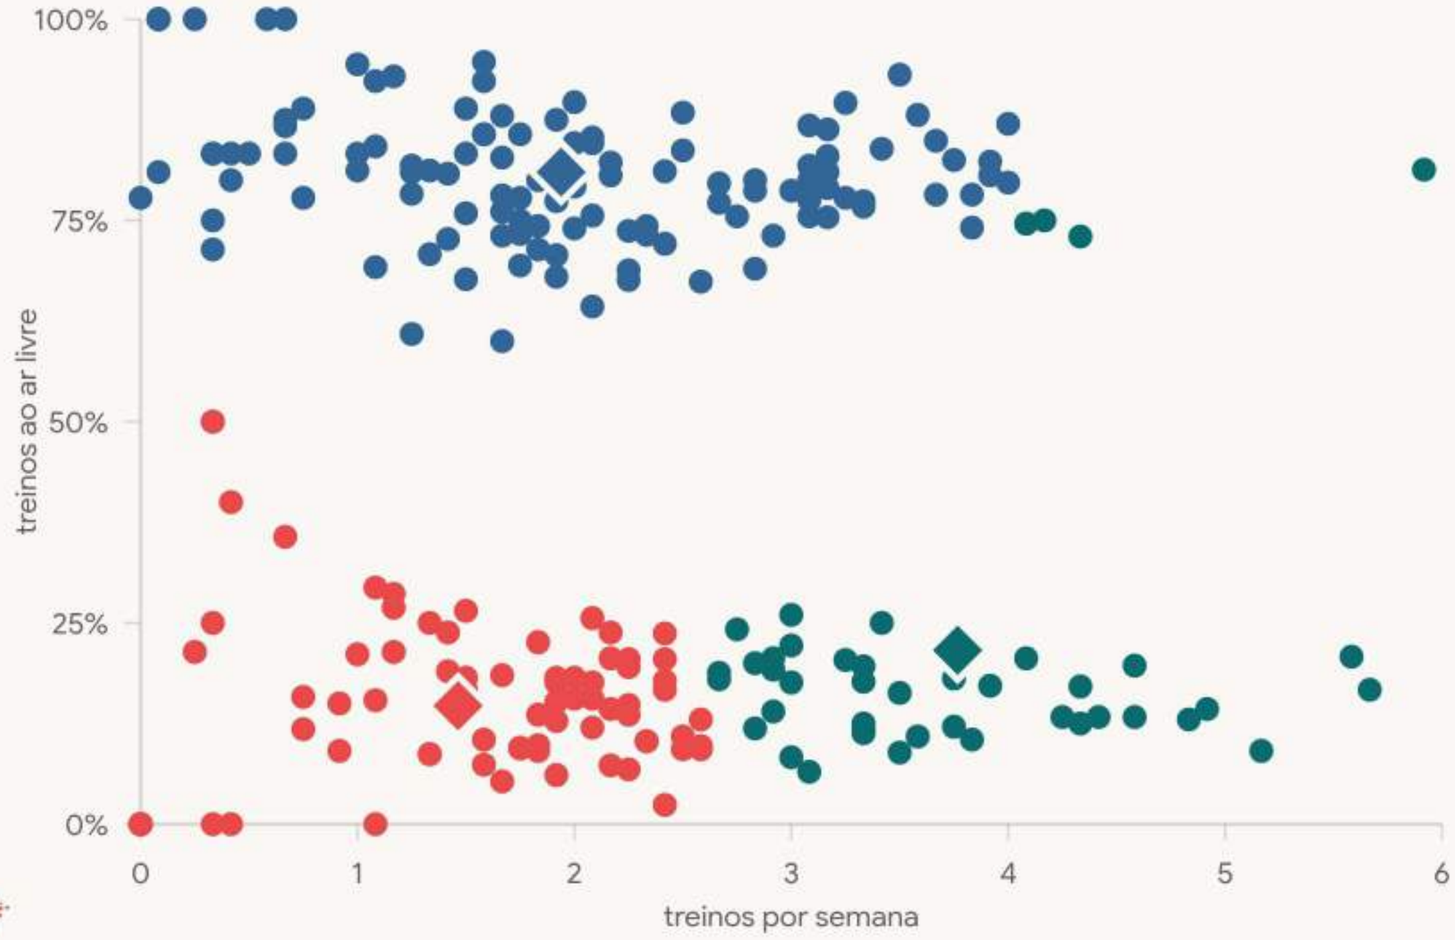
O QUE O K-MEANS GARANTE

A inércia nunca sobe entre uma volta e a seguinte. Ele não garante que parou no melhor resultado possível.

inteli

O sorteio inicial muda o resultado

30 inícios com os mesmos 240 pontos e k = 3: oito inércias finais



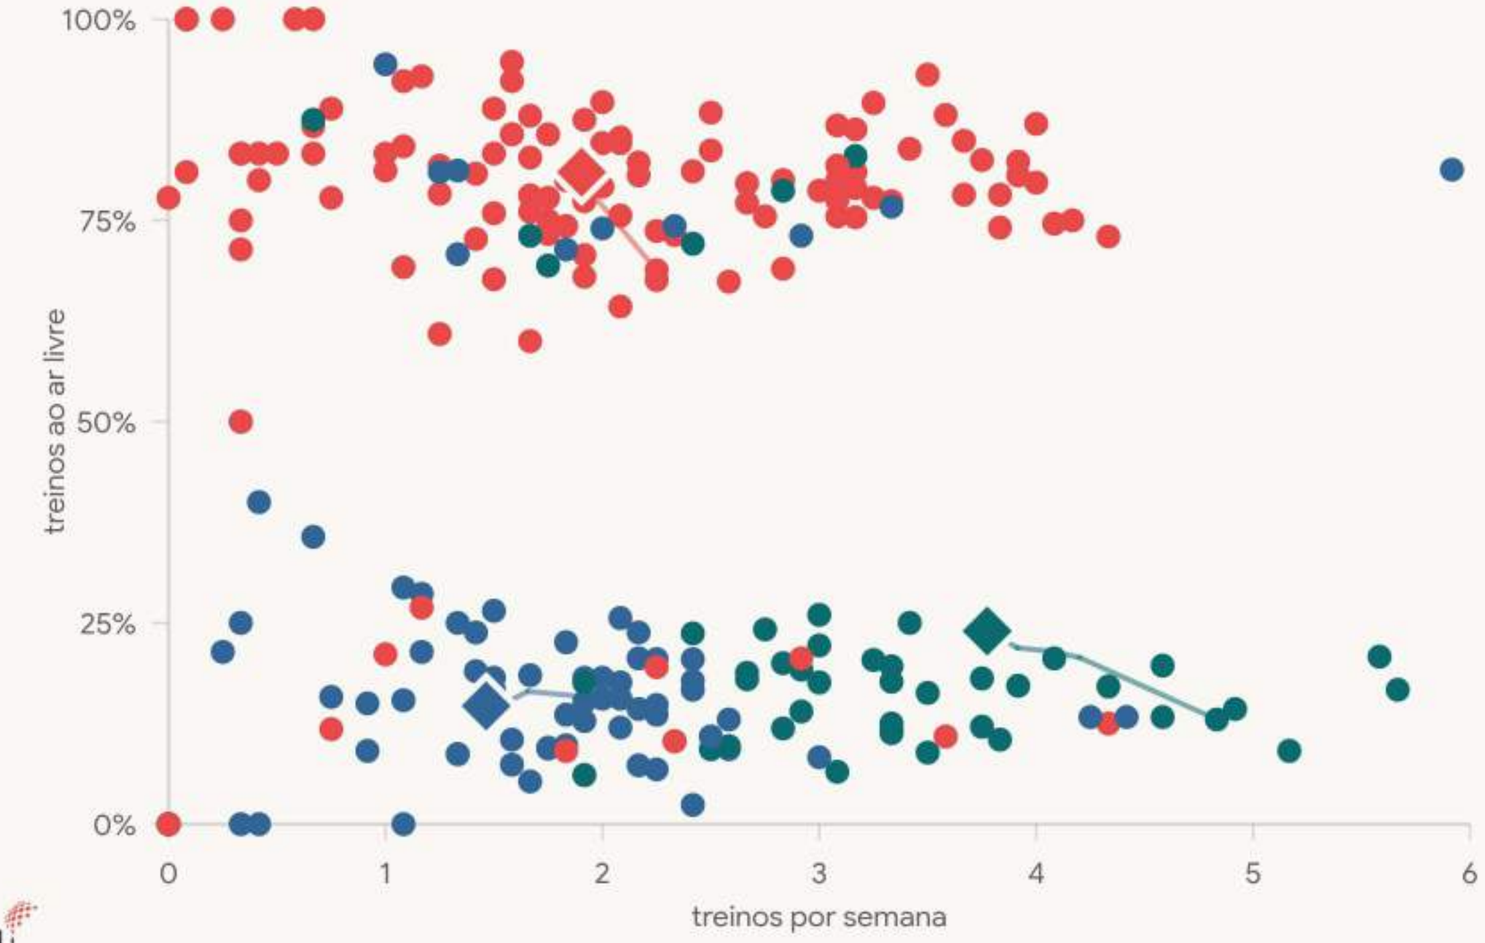


MÍNIMO LOCAL

O algoritmo para onde não consegue melhorar; não no melhor resultado possível. 30 inícios, 8 inércias finais, de 166,8 a 194,1.

O k-means++ sorteia centros afastados

O primeiro centro é sorteado; os seguintes, longe dos já escolhidos

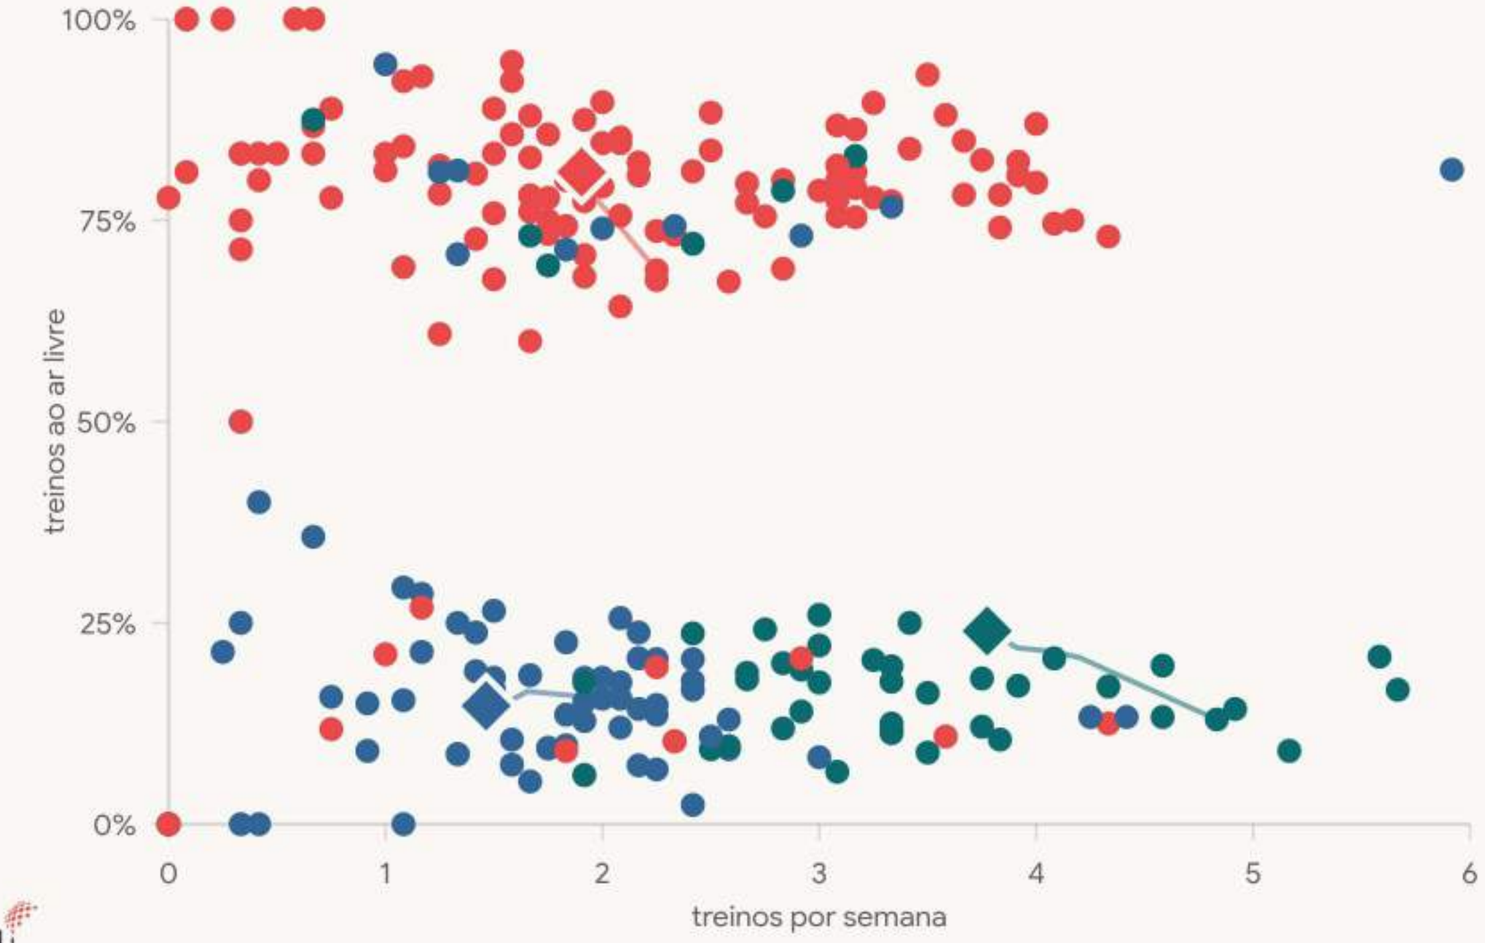


O QUE MUDA

Com centros afastados desde o início, 7 voltas em vez de 11, e o resultado de menor inércia. É o padrão do scikit-learn.

Rodar várias vezes e guardar a menor inércia

Com random_state fixo, quem roda de novo chega ao mesmo resultado



n_init = 10 roda dez sorteios e guarda o de menor inércia

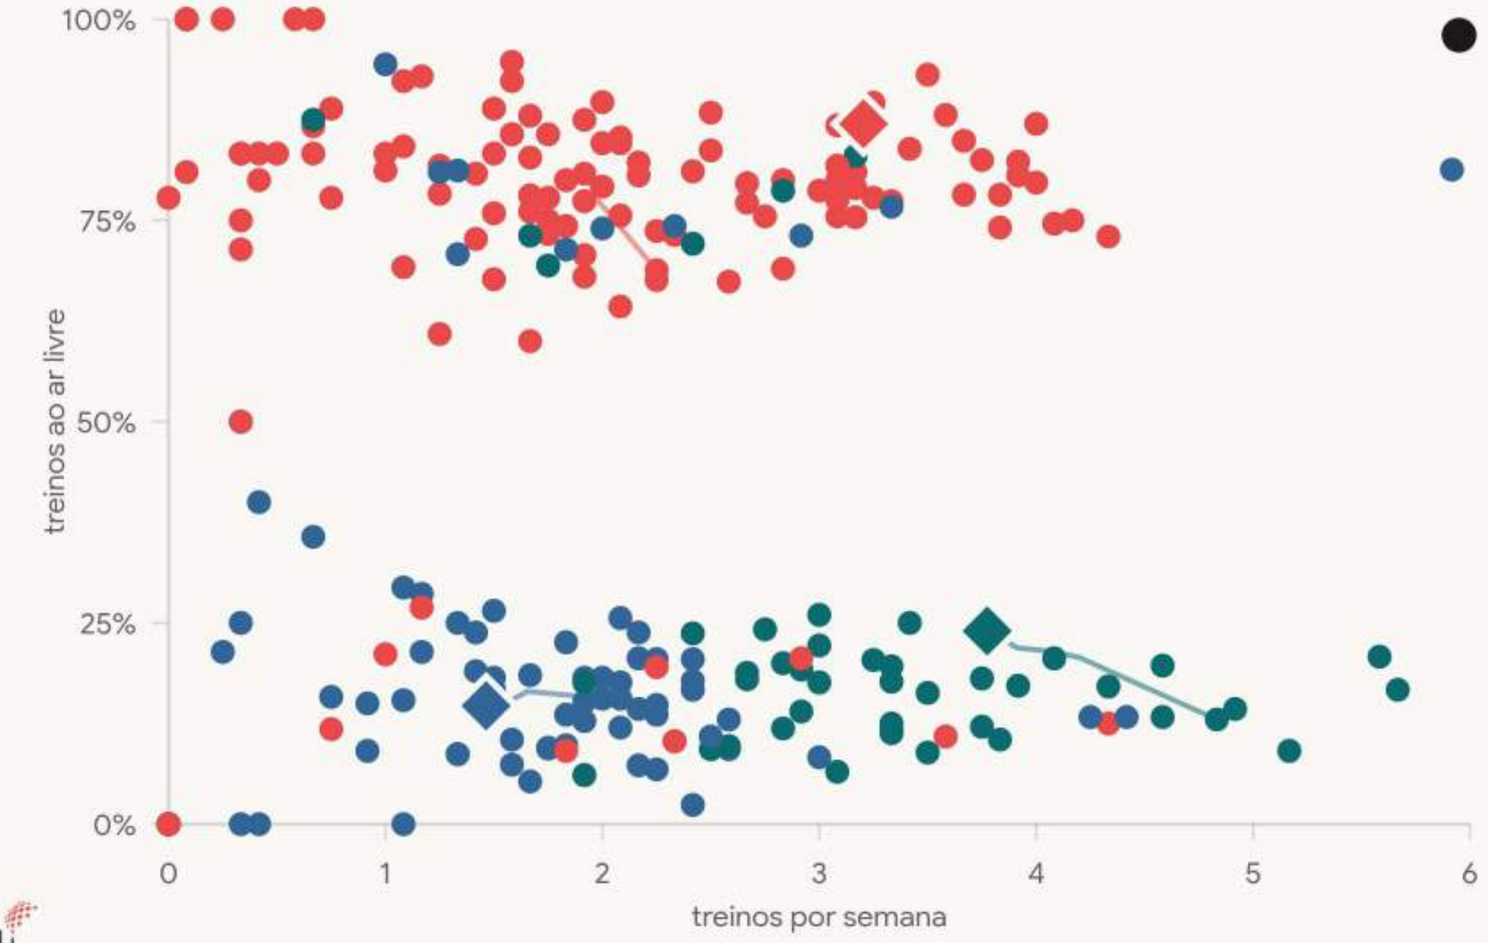
random_state = 0 fixa o sorteio: quem rodar de novo chega ao mesmo resultado

NO DECISOES.MD

O random_state vai para o decisoes.md. Sem ele, o grupo não consegue repetir o próprio resultado.

Dois limites do k-means

Valores extremos puxam o centro; variáveis 0/1 pesam demais na distância



Valor extremo um treino de 10.013 km puxa o centro do seu grupo para longe de todo mundo; teto ou log antes de agrupar

Variável 0/1 padronizada, pesa muito na distância: os grupos passam a coincidir com a categoria

OUTRA FORMA

O k-means procura grupos redondos em torno de médias. Grupos alongados ou de densidade pedem outros métodos, fora do escopo de hoje.

Quatro das seis etapas são decisões do grupo

O agente escreve o código de todas; padronizar e rodar não pedem escolha

1

Escolher as variáveis

Quais colunas contam a história que a pergunta pede

decisão

2

Transformar

Teto ou log nas variáveis de cauda longa; 0/1 entra ou não

decisão

3

Padronizar

`StandardScaler()`

Cada variável em desvios-padrão

código

4

Rodar

`KMeans(k, n_init=10, random_state=0)`

De k = 2 a 8, com várias partidas e semente fixa

código

5

Escolher o k

Inércia, silhueta, estabilidade e leitura de negócio

decisão

6

Registrar

Cada escolha e o motivo no decisoes.md

decisão

Padronizar e rodar são código que o agente escreve em minutos.

O pedido ao agente

Pergunta, arquivos, regras e prompt, e o que o auditor confere

PERGUNTA

Em quantos grupos os pagantes ativos em 31/07/2026 se dividem, e o que distingue cada grupo?

ARQUIVOS

dados/processados/variaveis_z.csv (uma linha por assinante, quatro variáveis padronizadas)

REGRAS

Não altere nada em dados/brutos/. Mostre o plano antes de rodar. Semente fixa.

PROMPT

```
Lê o AGENTS.md e usa o dados/processados/variaveis_z.csv.
Quero rodar o k-means de k = 2 a 8, com n_init=10 e
random_state=0, e ver a inércia e a silhueta de cada k.
Eu escolho o k olhando as duas curvas. Nesse k, me mostra o
tamanho de cada grupo e a mediana de cada variável na unidade
original, não em z.
Salva o gráfico em saidas/k.png e os perfis em
saidas/perfis.md, com um commit por rodada.
```

O AUDITOR CONFERE

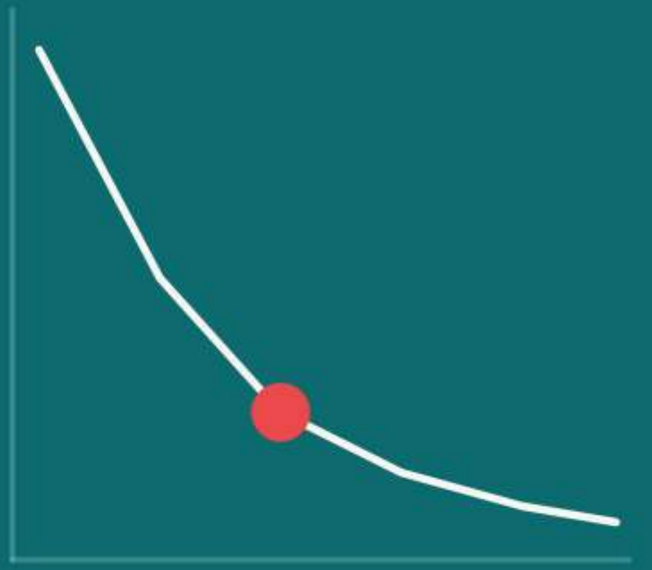
- **Tamanho de cada grupo**
  Os tamanhos somam a base; nenhum grupo com meia dúzia de pessoas
- **Perfil médio**
  Cada grupo cabe numa frase; se não cabe, o k está alto
- **Outra semente**
  random_state diferente, os mesmos grupos

Cada experimento num branch (cluster-v1, cluster-v2); um commit por rodada; o PR no fim.

3

Avaliar o agrupamento

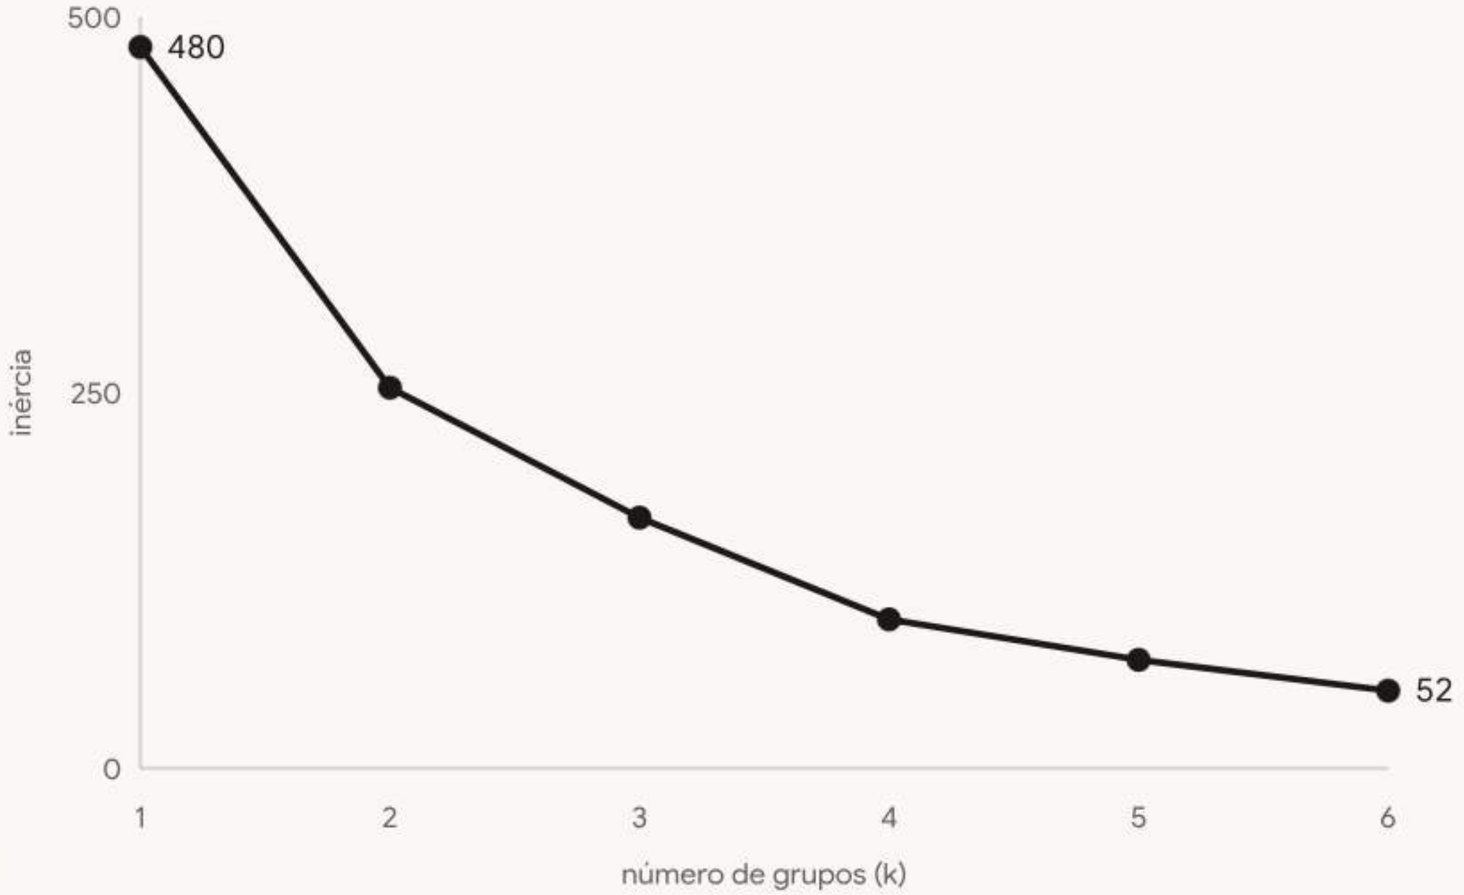
Inércia, silhueta, estabilidade e leitura de negócio



inteli

A inércia cai quando o k aumenta

Nos 240 assinantes, de k = 1 a 6; com k = 240, zero

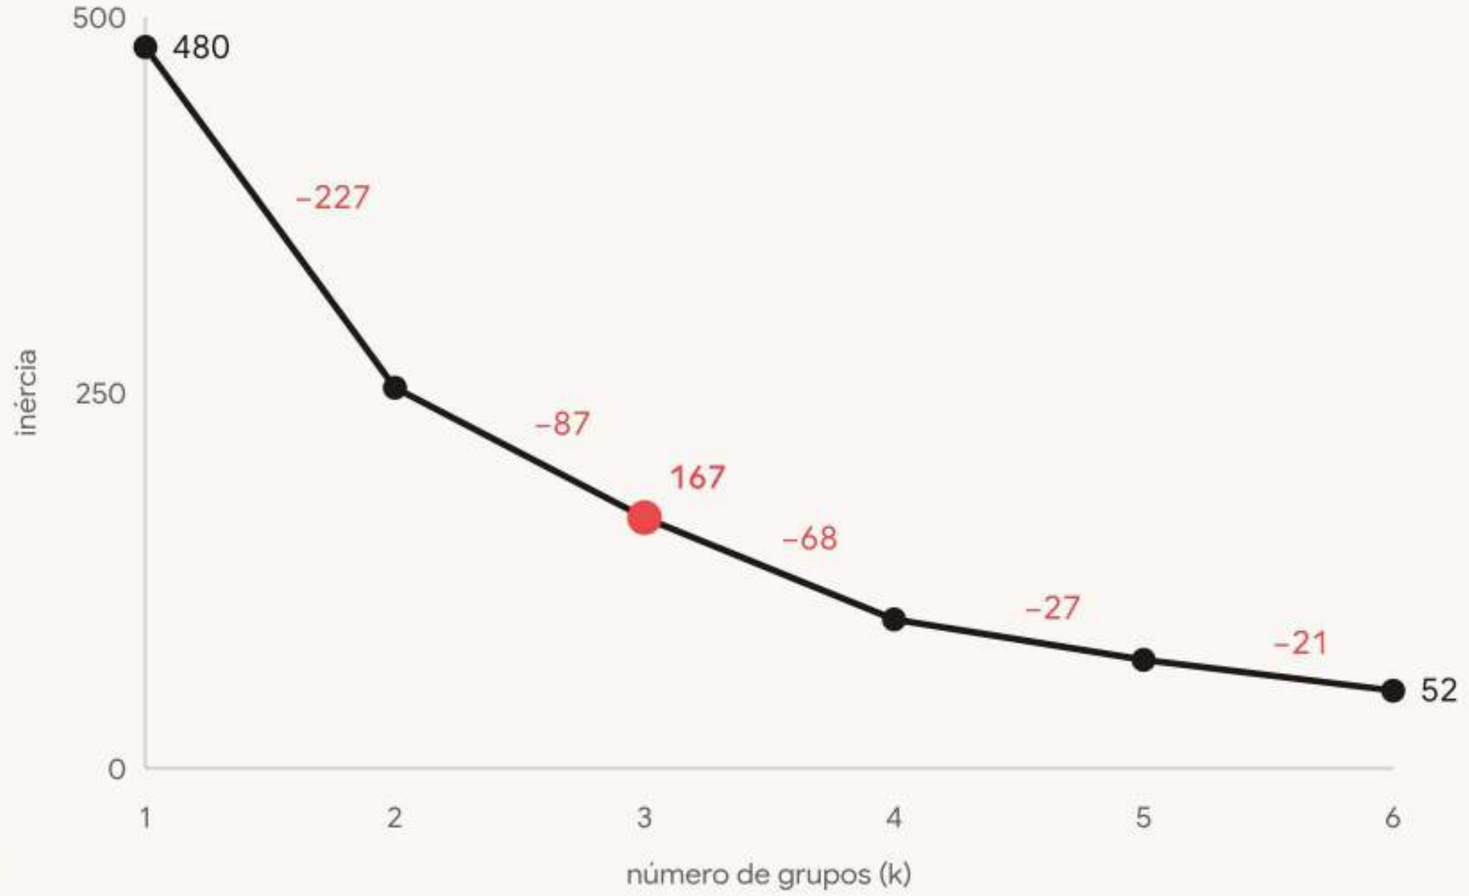


POR QUE ELA SEMPRE CAI

Com mais centros, cada ponto fica mais perto de algum. Com k igual ao número de pontos, cada um é o próprio centro e a inércia é zero. Inércia menor não quer dizer agrupamento melhor.

No cotovelo, o grupo seguinte reduz pouco a inércia

Cada grupo a mais reduz a inércia menos que o anterior



GANHO DO 4º GRUPO

−68

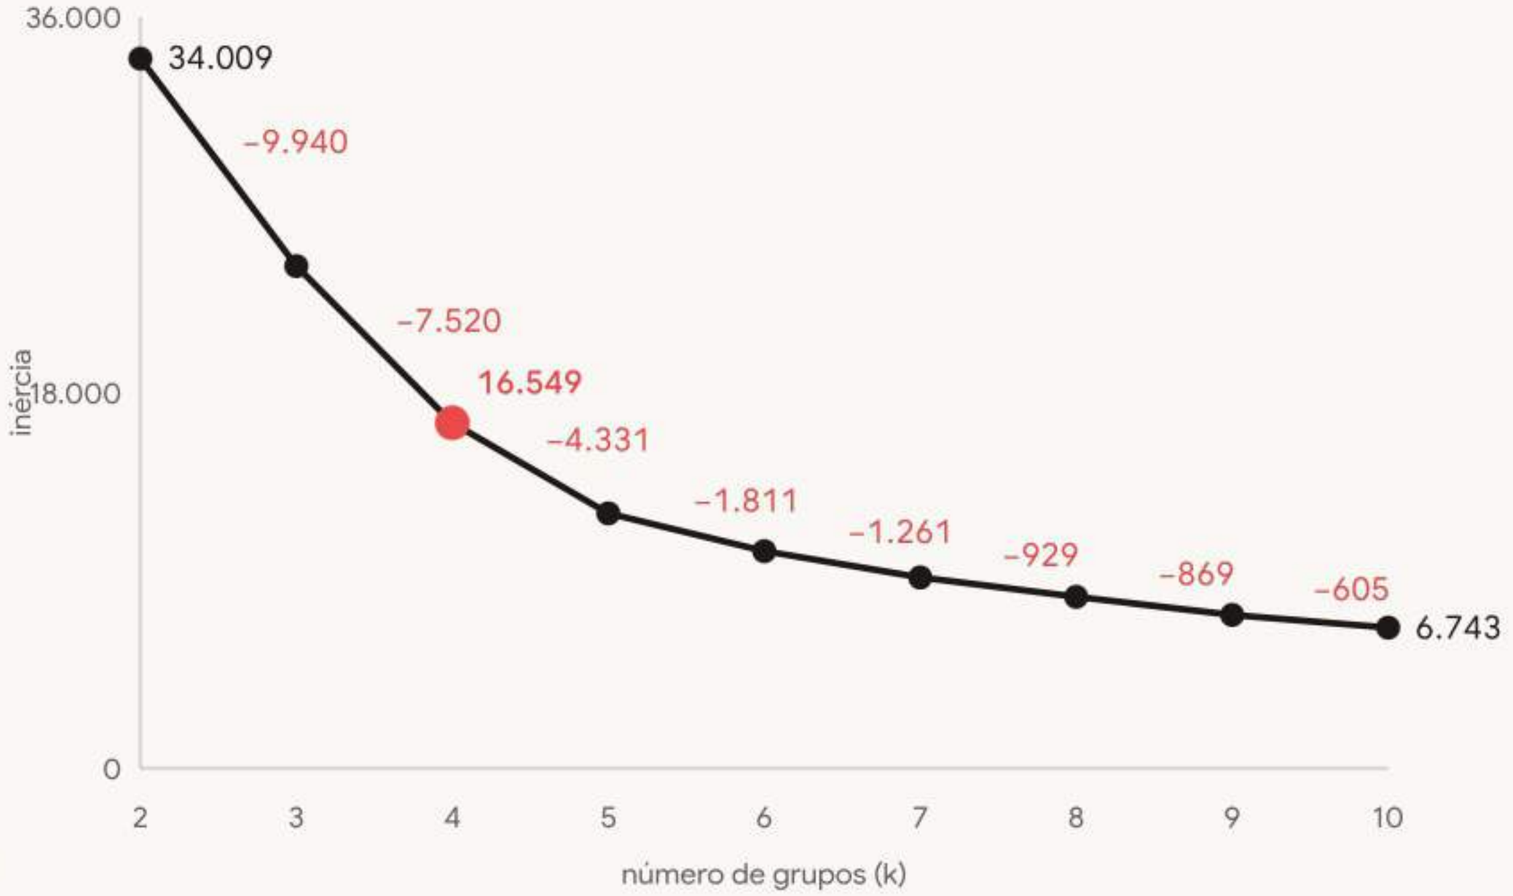
O COTOVELO

De 1 para 2 grupos a inércia cai 227; de 3 para 4, 68; de 5 para 6, 20. O cotovelo é onde a curva dobra: o próximo grupo já rende pouco.

inteli

Na base inteira, a dobra fica entre 4 e 5

11.688 pagantes, quatro variáveis padronizadas



GANHO DO 5º GRUPO

−4.331

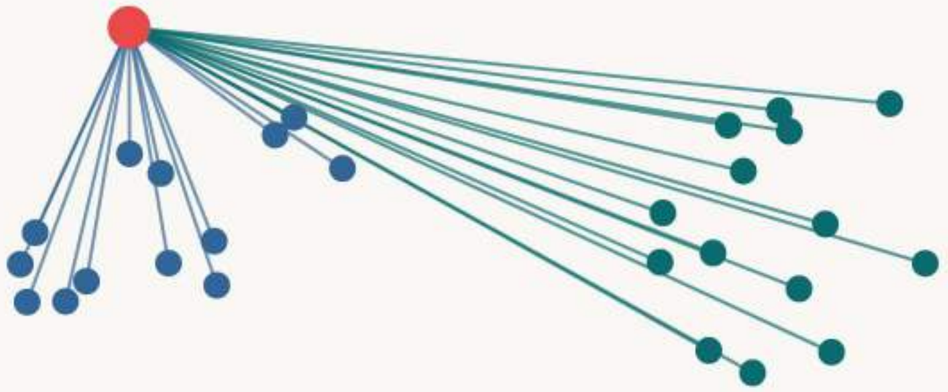
NA VITALIZA

De 3 para 4, a inércia cai 7.520; de 4 para 5, 4.331; de 5 para 6, 1.811. A dobra fica entre 4 e 5. A inércia sugere; não decide.

inteli

A silhueta compara o próprio grupo com o vizinho

Para cada ponto: a, a distância média ao próprio grupo; b, ao grupo vizinho mais próximo



a

distância média ao próprio grupo

b

distância média ao grupo vizinho

SILHUETA DO PONTO

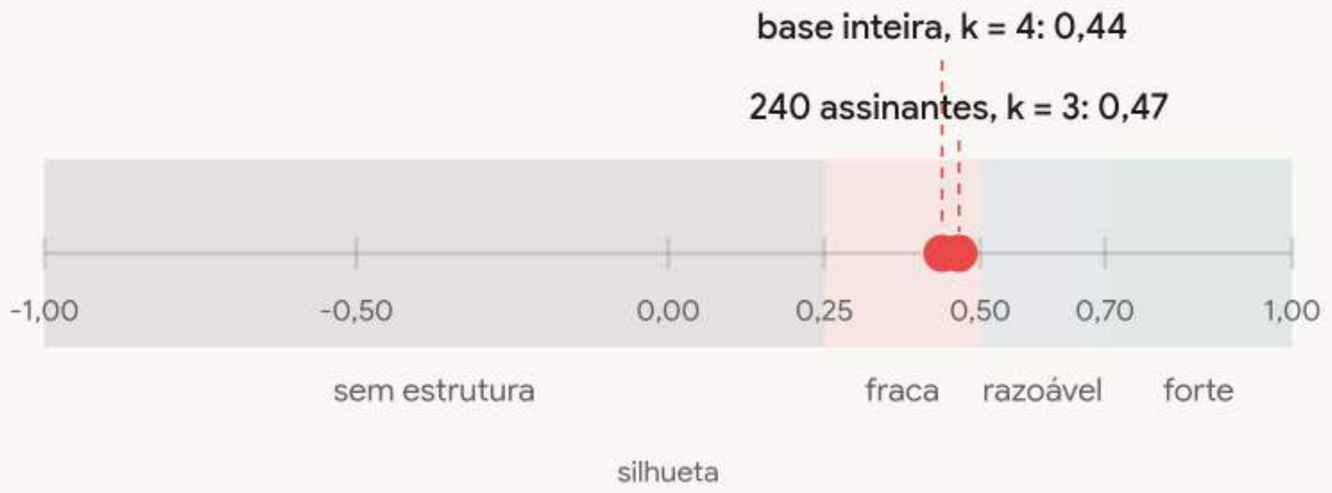
$$s = (b - a) / \max(a, b)$$

COMO LER

Perto de 1: bem colocado no seu grupo. Perto de 0: na fronteira. Negativo: provavelmente no grupo errado.

A silhueta vai de −1 a 1

A média de todos os pontos é a silhueta do agrupamento



240 ASSINANTES, K = 3

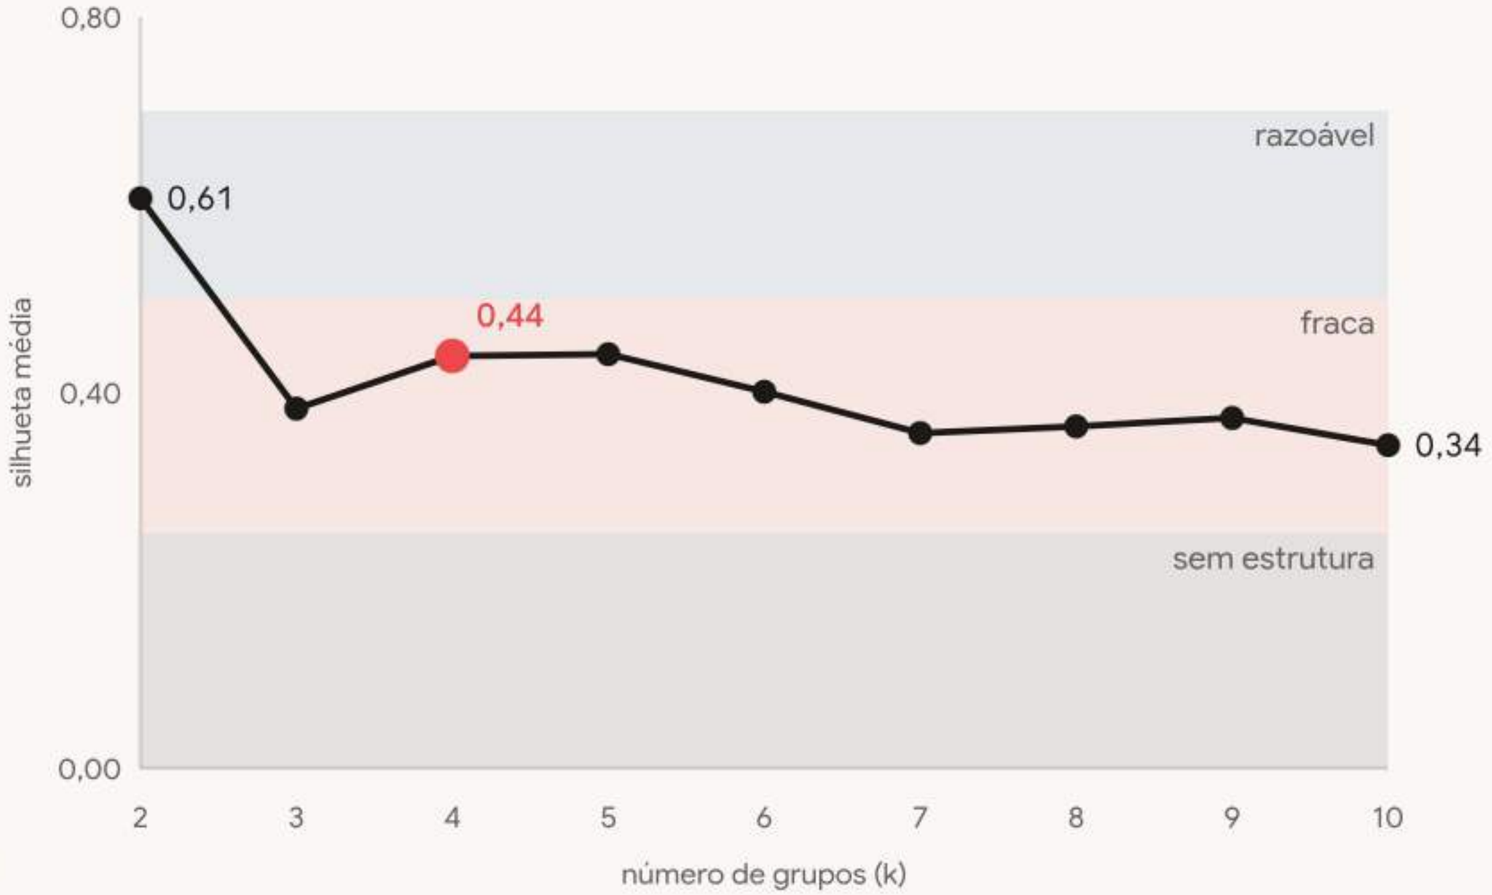
0,47

A RÉGUA

A média das silhuetas de todos os pontos. As faixas são as de Kaufman e Rousseeuw: até 0,25, sem estrutura substancial; até 0,50, fraca; até 0,70, razoável; acima, forte.

Na base inteira, a silhueta é 0,44 em k = 4

k = 2 tem a maior silhueta: quem treina e quem parou



K = 2

0,61

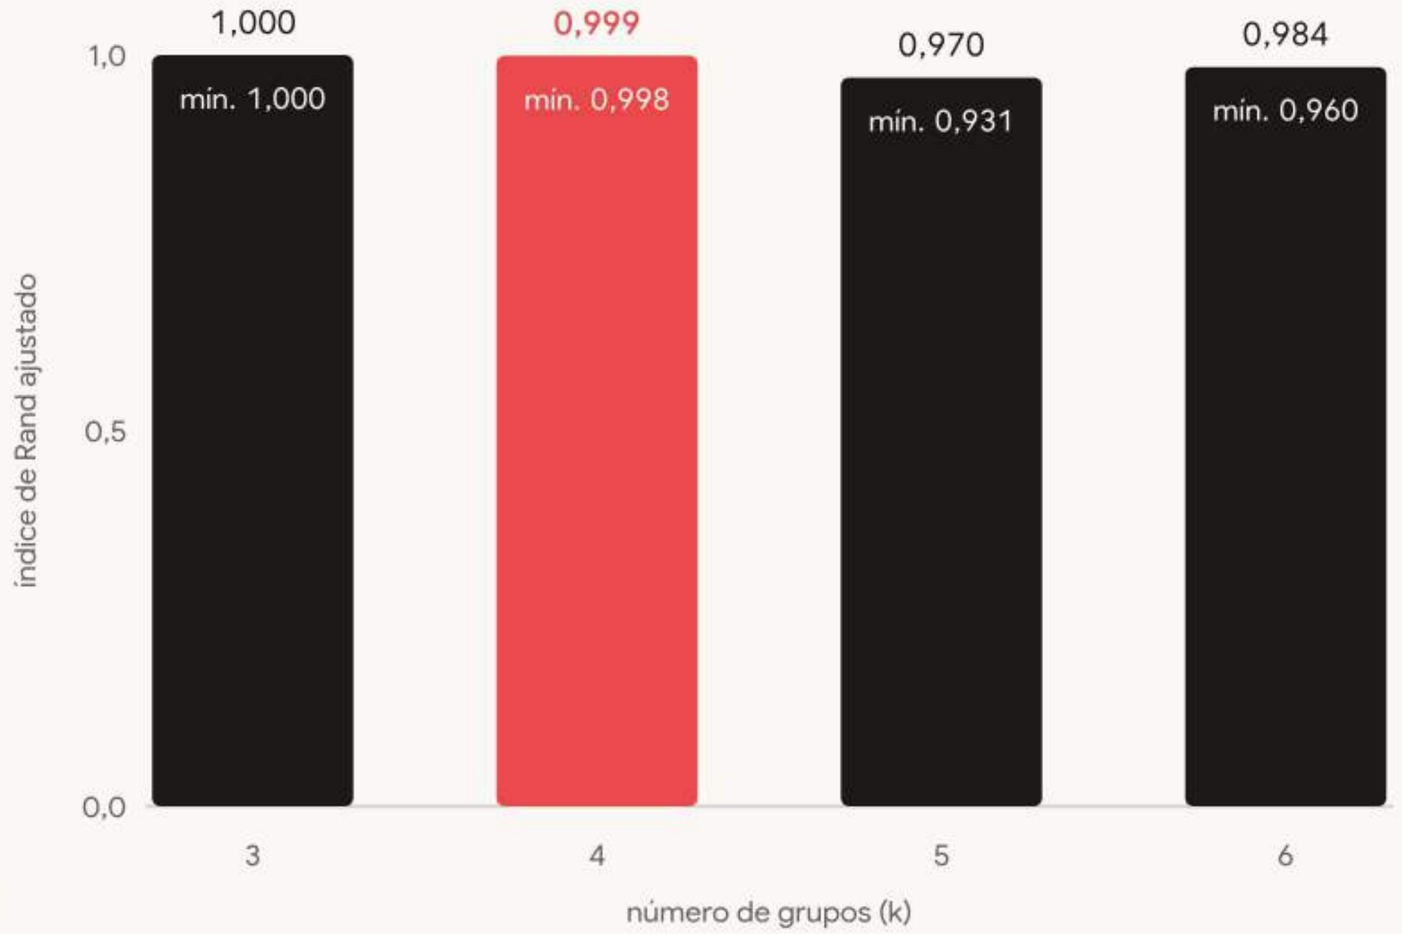
K = 2 OU K = 4

Com dois grupos, a base se divide em quem treina e quem parou: silhueta 0,61. Com quatro, 0,44, estrutura fraca; mas são quatro grupos que o negócio trata diferente.

inteli

Até k = 4, os grupos se repetem em outras amostras

Dez reamostras da base, comparadas com a original pelo índice de Rand ajustado



1,00 idêntico à original
0,00 o que o acaso daria

COMO LER

Sortear a base de novo, com reposição, e agrupar outra vez. Até k = 4 os cortes se repetem quase sempre; a partir de k = 5 a partição começa a oscilar entre sorteios.

inteli

Outras distâncias formam outros grupos

Os mesmos pagantes, as quatro variáveis em z e k = 4

Euclidiana

$\sqrt{\Sigma(x - y)^2}$

a da aula

Eleva cada diferença ao quadrado: a diferença grande pesa muito.

Separa os parados (28,6% de saída) e os veteranos (5,5%), com Rand de 0,999.

Manhattan

$\Sigma|x - y|$

Soma as diferenças sem elevar ao quadrado: o extremo pesa menos. Pede k-medianas.

Divide o ar livre em intenso (11,2% de saída) e leve (14,6%), mas some com os veteranos; Rand de 0,80.

Cosseno

$1 - \cos(x, y)$

Compara a direção, não o tamanho: o perfil, não o volume. Pede linhas normalizadas.

Tem a maior silhueta, 0,56, mas junta parados e veteranos: a saída dos grupos fica entre 11% e 15%.

A RÉGUA TAMBÉM É DECISÃO

Cada distância pede seu algoritmo: Manhattan vira k-medianas; cosseno, linhas normalizadas antes do k-means. A silhueta de uma régua não se compara com a de outra: quem decide é a estabilidade e a leitura de negócio, e a escolha vai para o decisoes.md.

O perfil de cada grupo em k = 4

k = 4 em 11.688 pagantes ativos em 31/07/2026; medianas por grupo

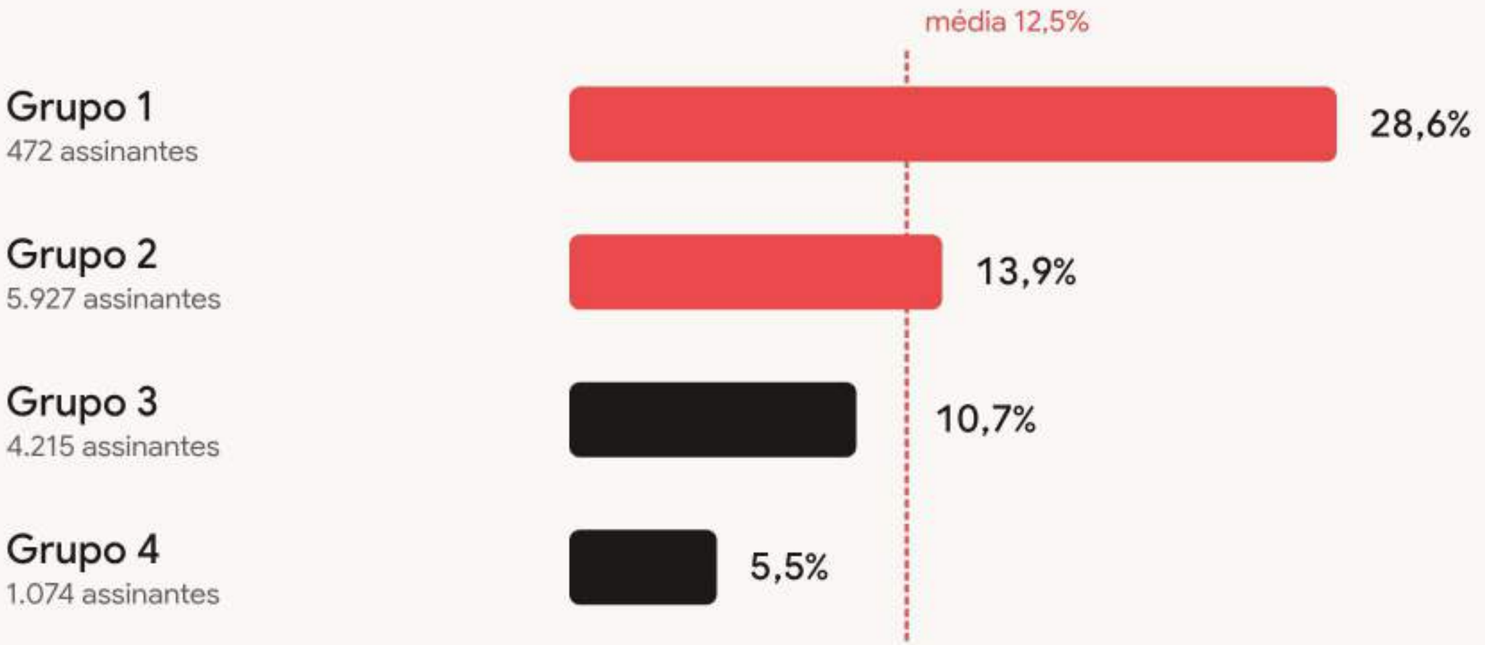
GRUPO	ASSINANTES	TREINOS/SEMANA	DIAS SEM TREINO	TEMPO DE CASA (DIAS)	AO AR LIVRE
Grupo 1	472	0,0	200	558	1%
Grupo 2	5.927	2,0	2	207	81%
Grupo 3	4.215	2,0	2	212	15%
Grupo 4	1.074	2,2	2	1.750	56%

COMO LER

Medianas, não z-scores: o perfil se lê na unidade original. Os parados têm 200 dias sem treino; os veteranos, 1.750 dias de casa.

Saída em 60 dias por grupo

Contra a média da base, de 12,5%

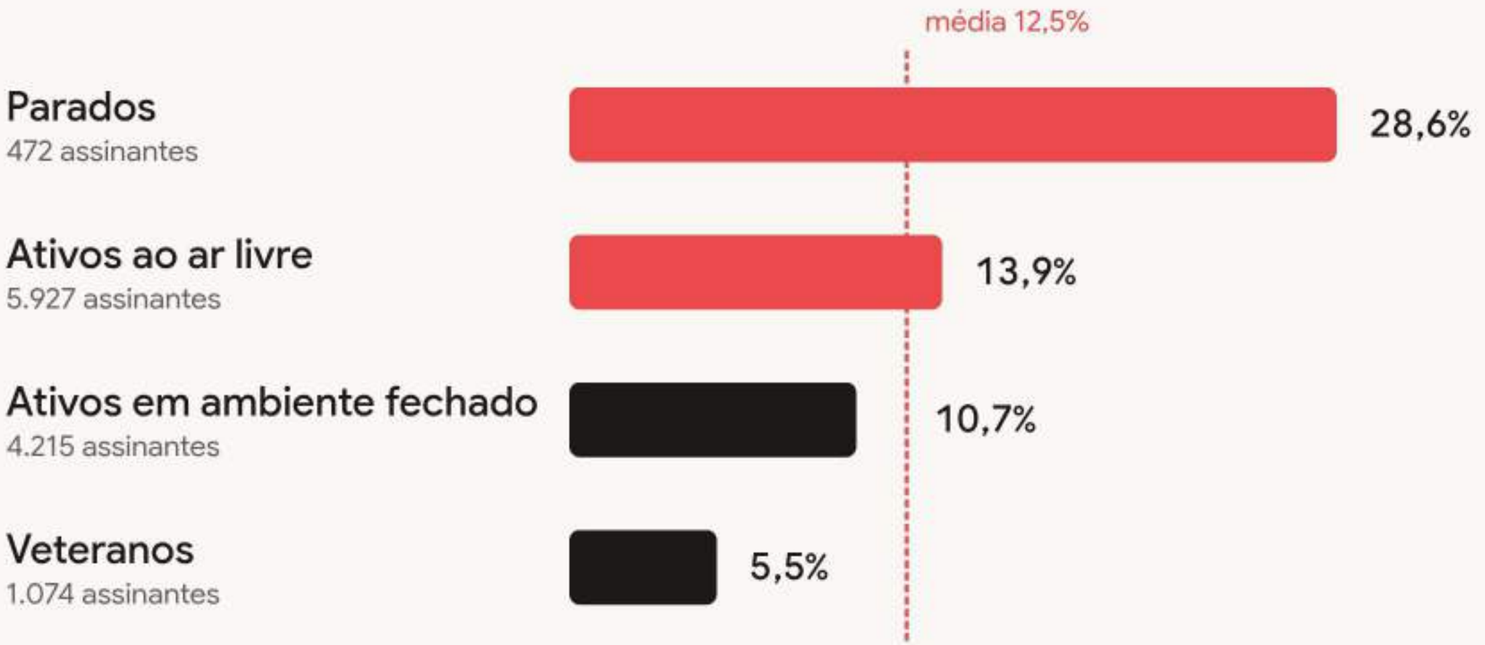


TAXA HISTÓRICA

Quem saiu nos 60 dias após o corte, pelos eventos. É descrição, não previsão: o modelo de risco vem nas aulas 6 a 8.

Um nome por grupo, com a evidência ao lado

O nome resume o perfil e é uma hipótese a testar



NOMES SÃO HIPÓTESES

O nome resume a evidência. A persona, com história e motivação, é a terça com o Fábio e a entrega S5.

Cluster vira segmento quando tem consequência

Distinto, estável, grande o bastante, acionável

Distinto

O perfil se lê em uma frase e não se confunde com o vizinho.

Parados: 200 dias sem treino.

Estável

Os cortes se repetem com outra amostra.

k = 4: índice de Rand 0,999.

Grande o bastante

Vale uma ação própria.

472 parados; 1.074 veteranos.

Acionável

A Vitaliza faria algo diferente com ele.

Parados: 28,6% de saída.

O que a Vitaliza faria diferente com cada grupo?

Escolher o k com as quatro lentes

Nenhuma lente decide sozinha; a decisão vai para o decisoes.md

	K = 2	K = 3	K = 4	K = 5	K = 6
Inércia (cotovelo)	·	~	✓	✓	~
Silhueta	✓	~	~	~	~
Estabilidade	✓	✓	✓	~	~
Leitura de negócio	·	~	✓	~	·

4

Na prática

Sete passos em 30 minutos, num branch do grupo



A pergunta

30 minutos, em grupo, com o agente do grupo, num branch novo

Entre os pagantes ativos em 31/07/2026, em quantos grupos os assinantes se dividem, o que distingue cada grupo, e o que a Vitaliza faria diferente com cada um?

POPULAÇÃO

Quem pagava a assinatura em 31/07/2026

VARIÁVEIS

As quatro da aula, mais até duas do grupo, padronizadas

SAÍDA

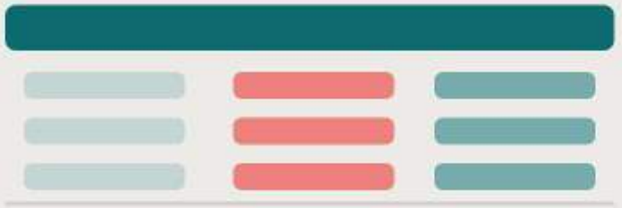
Quem saiu nos 60 dias após o corte, pelos eventos

VARIÁVEIS

treinos por semana | dias sem treino | tempo de casa | % ao ar livre | km por treino | canal de aquisição | plano

O que entregar no fim

O mínimo; o k e as variáveis são do grupo, sempre justificados



Uma tabela

O perfil de cada grupo em medianas, o tamanho e a saída histórica em 60 dias



Um gráfico

Inércia e silhueta de k = 2 a 8, com o k escolhido marcado



Um nome por grupo

Com uma frase de negócio cada, e o k defendido pelas quatro lentes numa frase

- E o `decisoes.md`: variáveis, escala, random_state e o k, com o motivo

Três funções

Uma tela por grupo, um papel por pessoa

Piloto

Escreve os pedidos ao agente e aprova o plano antes de rodar

Auditor

Confere o tamanho de cada grupo, o perfil e roda com outra semente

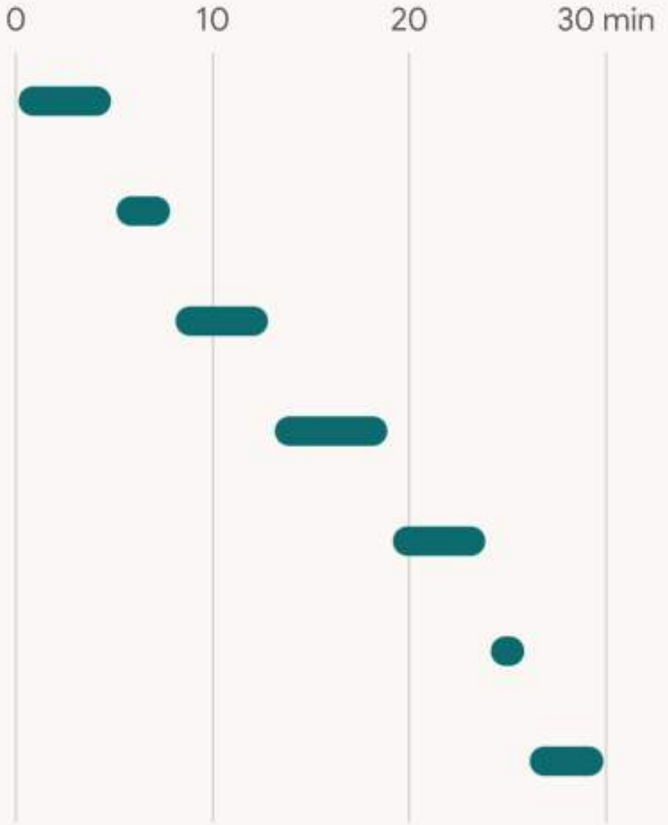
Relator

Registra cada decisão no decisoes.md e escreve o pull request

Sete passos em 30 minutos

Um commit por passo; o pull request no fim

1	Escolher as variáveis	5 min	As quatro da aula, mais até duas; o motivo de cada uma
2	Padronizar	3 min	Cada variável em desvios-padrão; teto ou log só se o grupo decidir
3	Rodar de k = 2 a 8	5 min	n_init = 10 e random_state fixo; inércia e silhueta por k
4	Ler as duas curvas	6 min	Onde a inércia dobra e onde a silhueta cai
5	Estabilidade e perfis	5 min	Reamostrar no k escolhido; medianas e saída por grupo
6	Registrar as decisões	2 min	Variáveis, escala, semente e k no decisoes.md
7	Nomear e abrir o PR	4 min	Um nome e uma frase por grupo; o k em uma frase



Passo 1: as variáveis

Objetivo, prompt e o que conferir

1	Escolher as variáveis	5 min
2	Padronizar	3 min
3	Rodar de k = 2 a 8	5 min
4	Ler as duas curvas	6 min
5	Estabilidade e perfis	5 min
6	Registrar as decisões	2 min
7	Nomear e abrir o PR	4 min

OBJETIVO

Montar a tabela de variáveis por assinante, padronizada

PROMPT

```
Lê o AGENTS.md antes de tudo e cria o branch cluster-v1.
Quero uma linha por user_id dos pagantes ativos em 31/07/2026,
pelos eventos (horário com Z vira Brasília), com quatro
variáveis tiradas de atividades.parquet e assinaturas.csv:
treinos por semana nas 12 semanas até o corte, dias desde o
último treino, tempo de casa em dias e % dos treinos ao ar
livre (corrida, caminhada e pedal).
Me mostra o plano antes de rodar. Depois, quantas linhas deu, a
mediana de cada variável e quantos têm zero treino.
Padroniza com StandardScaler e salva
dados/processados/variaveis.csv e variaveis_z.csv. Faz um
commit e não mexe em dados/brutos/.
```

CONFIRA

Perto de 11.700 linhas. Medianas que fazem sentido: 2 treinos por semana, 2 dias sem treino. Três user_id abertos no arquivo.

Passo 5: estabilidade e perfis

Objetivo, prompt e o que conferir

1	Escolher as variáveis	5 min
2	Padronizar	3 min
3	Rodar de k = 2 a 8	5 min
4	Ler as duas curvas	6 min
5	**Estabilidade e perfis**	5 min
6	Registrar as decisões	2 min
7	Nomear e abrir o PR	4 min

OBJETIVO

Ver se os grupos se repetem e o que cada um é

PROMPT

```
Usa o dados/processados/variaveis_z.csv.
No k que a gente escolheu, roda o KMeans(n_init=10,
random_state=0) e depois mais cinco vezes, em reamostras com
reposição da base. Compara cada uma com a original pelo
adjusted_rand_score e me dá a média e o mínimo.
Para cada grupo da rodada original, quero o tamanho, a mediana
de cada variável na unidade original e a taxa de saída em 60
dias depois de 31/07, pelos eventos.
Salva em saidas/perfis.md. Plano antes de rodar, um commit no
fim e nada alterado em dados/brutos/.
```

CONFIRA

Rand acima de 0,9. Os tamanhos somam a base. Um grupo que você consegue descrever em uma frase; se não conseguir, o k está alto.

Quem são os assinantes da Vitaliza?

Entrega: uma tabela, um gráfico e um nome por grupo

1	Escolher as variáveis	5 min
2	Padronizar	3 min
3	Rodar de k = 2 a 8	5 min
4	Ler as duas curvas	6 min
5	Estabilidade e perfis	5 min
6	Registrar as decisões	2 min
7	Nomear e abrir o PR	4 min



O que levar da aula 3

Cinco ideias da aula de hoje

Descrever a base antes de agrupar qualidade, granularidade e estatística descritiva; média sem distribuição engana	DESCREVER
O k-means depende de três decisões do grupo variáveis, distância e k; depois, atribuir e mover até parar	SEGMENTAÇÃO
Padronizar e fixar a semente antes de rodar desvios-padrão, n_init = 10 e random_state no decisoes.md	SEGMENTAÇÃO
Um agrupamento se avalia por quatro lentes inércia, silhueta, estabilidade e leitura de negócio; nenhuma decide sozinha	AVALIAR
O cluster vira segmento quando tem consequência distinto, estável, grande o bastante e acionável	AVALIAR

Aula 4, 05/11: visualização de dados

Trazer o branch com os clusters e o pull request revisado

HOJE · 29/10 · AULA 3

Clusterização

os clusters do grupo, num branch, com o PR aberto

05/11 · AULA 4

Visualização de dados

cada cluster vira gráfico; na terça, personas com o Fábio

inteli

Cesar Almiñana

cesar@prof.inteli.edu.br

cesar@almn.ai

WhatsApp
+55 11 999 018 180

LinkedIn
linkedin.com/in/ccalminana

Referências da aula 3

As 10 obras e páginas que sustentam as telas, em ordem alfabética (ABNT NBR 6023:2018)

Obras de A a C	Na aula
ABDULLAHI, Aminu. 'Catastrophic failure': AI agent wipes production database, then lies about it. **eWeek**, 22 jul. 2025. Disponível em: https://www.eweek.com/news/replit-ai-coding-assistant-failure/. Acesso em: 28 out. 2026.	**Caso Replit** O Git do grupo
ANTHROPIC. **Common workflows**: run parallel Claude Code sessions with Git worktrees. Claude Code Docs, [2026]. Disponível em: https://code.claude.com/docs/en/common-workflows. Acesso em: 28 out. 2026.	**Worktrees** O Git do grupo
ARTHUR, David; VASSILVITSKII, Sergei. k-means++: the advantages of careful seeding. *In*: ANNUAL ACM-SIAM SYMPOSIUM ON DISCRETE ALGORITHMS, 18., 2007, New Orleans. **Proceedings** [...]. Philadelphia: SIAM, 2007. p. 1027-1035.	**k-means++** O início importa
CHACON, Scott; STRAUB, Ben. **Pro Git**. 2. ed. Berkeley: Apress, 2014. Disponível em: https://git-scm.com/book/pt-br/v2. Acesso em: 28 out. 2026.	**Commit, branch, merge** O Git do grupo · leitura prévia

Referências da aula 3

As 10 obras e páginas que sustentam as telas, em ordem alfabética (ABNT NBR 6023:2018)

Obras de H a L	Na aula
HUBERT, Lawrence; ARABIE, Phipps. Comparing partitions. **Journal of Classification**, v. 2, n. 1, p. 193-218, 1985. DOI: https://doi.org/10.1007/BF01908075.	**Índice de Rand ajustado** Avaliar o agrupamento
JAMES, Gareth; WITTEN, Daniela; HASTIE, Trevor; TIBSHIRANI, Robert; TAYLOR, Jonathan. **An introduction to statistical learning**: with applications in Python. Cham: Springer, 2023. Disponível em: https://www.statlearning.com/. Acesso em: 28 out. 2026.	**k-means (cap. 12)** Não supervisionado · leitura prévia
KAUFMAN, Leonard; ROUSSEEUW, Peter J. **Finding groups in data**: an introduction to cluster analysis. New York: Wiley, 1990. 342 p.	**Faixas da silhueta** Avaliar o agrupamento
LLOYD, Stuart P. Least squares quantization in PCM. **IEEE Transactions on Information Theory**, v. 28, n. 2, p. 129-137, mar. 1982. DOI: https://doi.org/10.1109/TIT.1982.1056489.	**O algoritmo** O k-means passo a passo

Referências da aula 3

As 10 obras e páginas que sustentam as telas, em ordem alfabética (ABNT NBR 6023:2018)

Obras de R a S	Na aula
ROUSSEEUW, Peter J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53-65, nov. 1987. DOI: https://doi.org/10.1016/0377-0427(87)90125-7.	**Silhueta** Avaliar o agrupamento
SOTO, Juan; CARMENATY, Rafael; LASTRA, Miguel; FERNÁNDEZ-LUNA, Juan M.; BENÍTEZ, José M. Sports center customer segmentation: a case study. **arXiv**, 2405.17467, 2024. DOI: https://doi.org/10.48550/arXiv.2405.17467.	**Segmentação de academia** Do cluster ao segmento · leitura prévia



Apresentação feita com

applaude

applaude.studio